

Přírodou inspirované počítání

Shrnutí okruhu ke státní závěrečné zkoušce — jedna otázka na jednu stranu

SZZ Umělá inteligence, zaměření Intelligentní agenti, MFF UK · srpen 2026

Oficiální znění okruhu (zdroj pravdy, 2025/2026):

<https://www.mff.cuni.cz/cs/studenti/bc-a-mgr-studium/studijni-plany/2025-2026/informatika/mgr/umela-inteligence>

Okruh má šest vět a toto shrnutí jim věnuje šest stran. Podrobný výklad je v [02-prirodou-inspirovane-pocitani.pdf](#) (anglicky [ENG/02-nature-inspired-computing.pdf](#)), zdrojové slidy leží v [materialy/](#) (EVA I je NAIL025, EVA II je NAIL086, obojí Neruda).

1. Genetické algoritmy, genetické a evoluční programování. str. 2
2. Teorie schémat, pravděpodobnostní modely jednoduchého genetického algoritmu. str. 3
3. Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce. str. 4
4. Rojové optimalizační algoritmy. str. 5
5. Memetické algoritmy, hill climbing, simulované žhání. str. 6
6. Aplikace evolučních algoritmů (evoluce expertních systémů, neuroevoluce, řešení kombinatorických úloh, vícekritériální optimalizace). str. 7

Jednotlící pohled — tímhle lze začít kteroukoli odpověď. Všechny probírané metody dělají totéž: *stochastické black-box hledání*. K dispozici jsou jen hodnoty f ve zvolených bodech, gradient nikoli, a cenou je počet vyhodnocení. Algoritmus si drží *rozdělení* p_θ nad prostorem řešení a opakuje **vzorkuj** → **vyhodnoť** → **aktualizuj** θ . Mezi iteracemi přechází jediná informace, totiž θ — co se algoritmus naučil a kde má hledat dál. Metody se pak liší už jen tím, co do θ ukládají: **EA** rodičovskou populaci, **ES** gaussian se středem a σ , **CMA-ES** pětici $(\bar{m}, \sigma, C, \bar{p}_\sigma, \bar{p}_c)$, **EDA** parametry modelu (marginály, bayesovskou síť), **PSO** pozice, rychlosti a paměť, **ACO** feromonovou matici, **SA** aktuální bod s teplotou a **tabu** aktuální bod se seznamem zakázaných tahů.

alg.	reprezentace	variace	selekce	co si zapamatovat
SGA	binární řetězec	1-bod. křížení, bit-flip	ruleta, generační	teorie schémat, BBH
ES	$\mathbb{R}^n + \sigma$	gaussovská mutace, rekombinace	náhodní rodiče, $(\mu, \lambda)/(\mu + \lambda)$	pravidlo 1/5, samoadaptace
CMA-ES	$\mathbb{R}^n$, model $\mathcal{N}(\bar{m}, \sigma^2 C)$	vzorkování z rozdělení	pořadová, μ nejlepších	evoluční cesty, rank-1/rank- μ
DE	$\mathbb{R}^n$	$\vec{x}_a + F(\vec{x}_b - \vec{x}_c)$, binom. křížení	souboj rodič-potomek	měřítka kroku z populace
EP	doménová (automat)	jen mutace	turnaj rodiče + potomci	genotyp = fenotyp
GP	syntaktický strom	výměna podstromů, mutace	turnaj	bloat, ADF
PSO	$\mathbb{R}^n$ + rychlost	pohybové rovnice	žádná (jen paměť)	$w, c_1, c_2, gbest/lbest$
ACO	konstrukce cesty	feromon + heuristika	implicitní	$\tau^\alpha \eta^\beta$, odpařování
SA	jedno řešení	soused	Metropolis	rozvrh chlazení
MA	libovolná	EA operátory + lokální hledání	libovolná	Lamarck vs. Baldwin
NSGA-II	libovolná	SBX + polynom. mutace	fronty + crowding	elitismus, crowding distance
NEAT	seznam hran	mutace struktury, křížení dle ID	sdílená fitness v druhu	inovační čísla, speciace

Průřezová témata — ptají se napříč otázkami

- **Explorace a exploatace** — u každého algoritmu vědět, čím se poměr obou řídí: v GA křížením proti selekčnímu tlaku, v ES parametrem σ a pravidlem 1/5, v SA teplotou, v PSO vahou w a topologií, v ACO prahem q_0 a odpařováním, v tabu search délkou tabu listu; novelty search jen exploruje.
- **Diverzitu** udržují fitness sharing, crowding, speciace, ostrovní model, nenáhodné páření, restart a hypermutace.
- **Parametry** se buď ladí před během, nebo řídí za běhu, a to pevně, adaptivně či samoadaptivně.
- **Omezení** se řeší penalizací, opravou, dekodérem, uzavřenými operátory nebo vícekritériální formulací.
- **Lamarckismus proti baldwinismu** se objeví u memetických algoritmů, opravy jedinců a neuroevoluce s doučováním vah.
- Z **teorie** se ptají na větu o schématech a její kritiku, Voseho model, Markovovy řetězce s konvergencí elitistického GA, No Free Lunch a konvergenci SA.

Co se chce spočítat u tabule

- Ruletovou selekci pro zadanou populaci a jeden krok DE s konkrétními čísly.
- PMX a OX na devítiprvkovém příkladu, inverzi (2-opt) na permutaci.
- Z věty o schématech $o(S)$ a $d(S)$, případně celé odvození nerovnosti.
- Crowding distance v NSGA-II, dominanci a Pareto frontu z tabulky kritérií.
- Metropolisovo kritérium pro konkrétní Δ a T , jeden krok samoadaptace σ .

Zařazení oboru — na úvodní otázku

Umělá inteligence se dělí na „tvrdé“ logicko-formální metody a „měkké“ metody inspirované přírodou. Do **computational intelligence** (dříve soft computing) patří neuronové sítě, fuzzy přístupy a **evoluční výpočty (EC)**. EC zastřešuje biologicky motivované metaheuristiky a **EVA** je jeho podmnožina, která staví na principech evoluce: na populaci, stochastičnosti, fitness, mutaci a křížení. Biologickou inspiraci naopak postrádají tabu, scatter a novelty search.

Nejčastější chyby

- Pravidlo 1/5 je řízení *adaptivní*; *samoadaptivní* je až σ uložené v genomu.
- Při samoadaptaci se mutuje nejdřív σ a teprve pak x , aby se nový krok hned otestoval.
- Věta o schématech nedokazuje konvergenci GA: je to nerovnost na *jeden* krok a jen o *střední hodnotě*.
- (μ, λ) a $(\mu + \lambda)$ se liší elitismem, a právě to se plete nejčastěji.
- No Free Lunch není argument proti EA, ale argument *pro* doménovou specializaci reprezentace a operátorů.
- Lineární skalarizace nenajde celou Pareto frontu — nekonvexní části jí uniknou.
- Pareto *množina* leží v prostoru řešení, Pareto *fronta* v prostoru kritérií.

Otázka 1. Genetické algoritmy, genetické a evoluční programování

Osnova odpovědi

1) obecné schéma EA a role variace vs. selekce 2) selekce 3) SGA a binární kódování 4) reprezentace + operátory = fitness krajina 5) GP a jeho patologie 6) varianty GP 7) EP a srovnání čtyř historických větví.

Obecné schéma EA

Evoluční algoritmus je populační stochastické prohledávání. Opakuje cyklus *inicializace* → *ohodnocení* → *rodičovská selekce* → *rekombinace* → *mutace* → *ohodnocení* → *environmentální selekce*. Dvě síly v něm stojí proti sobě: **variace** (křížení a mutace) diverzitu *tvorí*, kdežto **selekce** ji *odebírá* a směřuje hledání. Navrhnout EA proto znamená najít rovnováhu mezi **explorací** a **exploatací**. **No Free Lunch** (Wolpert & Macready 1995–97) říká, že průměrně přes všechny úlohy si všechny algoritmy vedou stejně. Smysl má tedy jen *doménová specializace* reprezentace a operátorů.

Selekce

Ruleta dává jedinci pravděpodobnost $p_i = f_i / \sum_j f_j$; má vysoký rozptyl a je citlivá na škálování fitness. **SUS** losuje jediné náhodné místo a dál se posouvá po $1/n$, takže při stejných středních hodnotách má nižší rozptyl — je to „spravedlivější ruleta“. V **turnaji** řídí selekční tlak velikost k , typicky 2–5. Turnaj je invariantní vůči *monotónním* transformacím fitness a explicitní fitness vůbec nepotřebuje, protože mu stačí dva jedince porovnat; proto je jediný použitelný, když se hraje hra nebo běží simulace. **Pořadová selekce** drží tlak konstantní, **Boltzmannova** jej v čase zvyšuje. **Elitismus** zaručuje, že nejlepší fitness nikdy neklesne. **Generační** a **steady-state** model se liší podílem populace, který se v jednom kroku nahradí. **Škálování fitness** — lineární, sigma truncation, mocninné, pořadové a Boltzmannovo — opravuje dvě slabiny ruletové selekce: dominanci „supermanů“ na začátku a ztrátu tlaku na konci běhu.

SGA a binární kódování

SGA pracuje s binárními řetězci a kombinuje ruletu, 1-bodové křížení, bit-flip mutaci a generační náhradu; nastavuje se u něj velikost populace n a pravděpodobnosti $p_C \approx 0,7$ a $p_M \approx 1/m$. Reálné číslo se do řetězce převede vztahem $x = a + z(b - a)/(2^k - 1)$, přičemž **Hammingovy útesy** odstraní **Grayův kód**. Hollandův argument pro binární abecedu (nejvíce schémat na jeden bit) dnes *neobstojí*, protože binární kódování je pro řadu úloh nepřírozené. Křížení má tři podoby. **1-bodové** rozbije schéma s pravděpodobností $d(S)/(m - 1)$ a má poziční bias, **2-bodové** se okrajového biasu zbaví a **uniformní** je nejvíce disruptivní, zato bez pozičního biasu. Mutace hraje v GA *sekundární* roli: brání nevratné ztrátě alel. **Inverze** je historický operátor, kterým se mělo evolvovat uspořádání genů.

Reprezentace a operátory

Fitness krajina určuje *teprve* reprezentace spolu s operátory. U *celo-*

číselné reprezentace je mutace buď *nezaujatá* (nová hodnota se losuje z celé domény), nebo *zaujatá* (*creep*, normálně rozdělený posun); *zaujatá* dává smysl jen u ordinálních atributů, u nominálních ne. V *reálné* reprezentaci se mutuje *gaussovsky*, $x' = x + \sigma N(0, 1)$, a křížení je buď *strukturní* (1-bodové, uniformní), nebo *aritmetické*, $\alpha \bar{x} + (1 - \alpha)\bar{y}$. Aritmetické však *zmenšuje rozptyl* populace, a proto vznikly BLX- α a SBX. Pro **permutace** zachovává PMX pozice pomocí mapování, OX relativní pořadí, CX absolutní pozice pomocí cyklů a ER hrany, což je nejlepší volba pro TSP. Mutací jsou swap, insert, inverze (2-opt) a scramble. *Umět předvést PMX a OX na devítiprvkovém příkladu.*

Stromové GP (Koza 1989)

Jedinec je strom sestavený z terminálů a neterminálů. Množina symbolů musí splnit **uzavřenost** (každý neterminál zpracuje každou hodnotu) a **dostatečnost** (řešení je v prostoru vůbec vyjádřitelné). Populace se inicializuje metodou *grow*, *full* nebo *ramped half-and-half*. Křížení vyměňuje podstromy a neterminály je přitom nutné volit s vyšší pravděpodobností, jinak se mění jen listy; mutací je několik typů včetně mutace konstant. Fitness se získá tak, že se program spustí na datech. **Bloat** je růst velikosti bez zlepšení fitness (přibývají *introny*). Vysvětlují jej tři teorie — *replication accuracy*, *removal bias* a *crossover bias* — a bránit se lze limity velikosti, penalizací (*parsimony pressure*), anti-bloat operátory (*hoist*, *shrink*, *size-fair*) a vícekritériálním přístupem. **ADF** jsou evolvované podprogramy, které do řešení vnášejí modularitu; operátory pak pracují na jednotlivých větvích odděleně. Typované a gramatické GP omezují prostor na smysluplné programy.

Varianty GP

Lineární GP zapisuje program jako byte kód: operátory jsou jednodušší a emulace rychlá, zato mutace snadno vyrobí nesmysl. Oblíbené je v a-life a pro boty ve hrách. **Grafové GP** pracuje s DAG, tedy s obvody, automaty a neuronovými sítěmi. **Cartesian GP** mapuje lineární genotyp na dvourozměrnou mřížku uzlů, mutuje bodově a běží jako (1 + 4)-ES; část uzlů přitom zůstává neaktivní. Ve **vývojovém GP** je strom program, který teprve staví výsledný graf. **Gramatická evoluce** má lineární genom celých čísel a pravidlo gramatiky vybírá *modulem*; z derivačního stromu pak vznikne fenotyp. Kódování je robustní a operátory standardně jako v GA, platí se za to ale nelokálním mapováním genotypu na fenotyp.

Evoluční programování a poučení

EP evolvuje konečné automaty a ztotožňuje *genotyp* s *fenotypem*; odtud jeho heslo „křížení je zlo“. Pracuje tedy jen s mutací a s turnajovou selekcí z rodičů i potomků, školním příkladem je predikce prvočísel. Umět vyjmenovat čtyři historické větve **GA** / **ES** / **EP** / **GP** a jejich charakteristické volby. **Headless chicken test** porovná skutečné křížení s křížením, v němž je partner náhodně vygenerovaný. Vyhraje-li náhodný partner, křížení nekombinuje stavební bloky a funguje jen jako *makromutace*; na vině je špatné kódování, špatný operátor, nebo úloha bez stavebních bloků.

Otázka 2. Teorie schémat, pravděpodobnostní modely jednoduchého genetického algoritmu

Osnova odpovědi

1) schéma a jeho tři charakteristiky 2) věta o schématech a její odvození ve třech krocích 3) BBH, implicitní paralelismus, bandita 4) kritika 5) Voseho model (nekonečná populace) 6) Markovův řetězec (konečná populace) 7) EDA jako praktický důsledek.

Schéma

Schéma je slovo nad abecedou $\{0, 1, *\}$. Jeho **řád** $o(S)$ udává počet pevných pozic, **definující délka** $d(S)$ vzdálenost první a poslední pevné pozice a $F(S)$ je průměrná fitness jeho reprezentantů *v dané populaci*. Poslední veličina tedy závisí na populaci, ne na úloze. Počty vypadají takto: schémata délky m je 3^m , jeden jedinec je reprezentantem 2^m z nich, schéma s r hvězdičkami pokrývá 2^r jedinců a populace n jedinců obsahuje mezi 2^m a $n \cdot 2^m$ schémat.

Věta o schématech (TST)

$$\mathbb{E}[C(S, t+1)] \geq C(S, t) \frac{F(S)}{\bar{f}} \left[1 - p_C \frac{d(S)}{m-1} - p_M o(S) \right]$$

Odvozuje se ve třech krocích. *Selekce* dodá faktor $F(S)/\bar{f}$, takže nadprůměrná schémata rostou exponenciálně. *Křížení* schéma rozbije s pravděpodobností nejvýš $d(S)/(m-1)$. *Mutace* nechá schéma přežít s pravděpodobností $(1 - p_M)^{o(S)} \approx 1 - p_M o(S)$. Slovy Hollanda: v populaci exponenciálně rostou schémata *krátká, nízkého řádu a nadprůměrná*.

Příklad na dosazení ($m = 8$, $p_C = 0,7$, $p_M = 0,01$, $F(S)/\bar{f} = 1,5$)

Pro $S = 1**0***1$ je $o(S) = 3$ a $d(S) = 7$, závorka tedy vyjde $1 - 0,7 \cdot \frac{7}{7} - 0,01 \cdot 3 = 0,27$ a celkem $1,5 \cdot 0,27 = 0,41$. Schéma *ubývá*, přestože je nadprůměrné. Pro $S' = 110*****$ je $o = 3$ a $d = 2$, závorka dá $1 - 0,7 \cdot \frac{2}{7} - 0,03 = 0,77$ a celkem $1,5 \cdot 0,77 = 1,16$: schéma *roste*. Přesně tohle znamenají slova „krátká a nízkého řádu“ — rozhoduje $d(S)$, ne jen fitness.

BBH a implicitní paralelismus

Hypotéza stavebních bloků tvrdí, že GA skládá řešení z krátkých, nízkého řádu a nadprůměrných schémat. Plyne z toho, že záleží na *kódování* (příbuzné geny mají ležet blízko sebe) i na *velikosti populace* a že škodí předčasná konvergence. **Implicitní paralelismus** znamená, že populace n jedinců zpracovává 2^m až $n \cdot 2^m$ schémat, exponenciálně jich ale roste jen řádově n^3 . Bývá to označováno za „jediný případ, kdy je kombinatorická exploze na naší straně“.

Bandita

Dáno je N mincí a dvouruký bandita s výplatami o středech μ_1, μ_2 a rozptylech σ_1, σ_2 . Analytické řešení přiděluje dosud vítězné páce *exponenciálně* více pokusů, $N - n^* = O(e^{c n^*})$. Stejně alokuje GA sloty v populaci, a řeší tak dilema explorační a exploatační optimálně. Přesnější pohled: schémata řádu k soupeří o týchž k pevných pozic, hrají tedy 2^k -**rukého banditu**, nikoli jednu hru s 3^m pákami.

Kritika teorie schémat

- Nerovnost platí jen na *jeden* krok a jen o *střední hodnotě*. Iterovat ji nelze, protože $F(S)$ i $\bar{f}$ se mění, a v malé populaci navíc vznikají výběrové chyby (drift).
- Ramena bandity jsou nezávislá, kdežto schémata *nezávislá nejsou*: SGA je nevzorkuje nezávisle, a proto *špatně odhaduje jejich fitness*. Kanonický protipříklad je $f(x) = 2$ pro $111 \dots$, 1 pro $0 \dots$ a jinak 0 . Skutečně je $F(1 \dots) = 1/2 < F(0 \dots) = 1$, ale SGA odhadne $F(1 \dots) \approx 2$, protože v populaci převládnu zástupci $111 \dots$.
- Statickou BBH** zpochybnil Grefenstette (1991): lidé očekávají konvergenci ke schématům se skutečnou průměrnou fitness, GA však konverguje k fitness *pozorované v populaci*. Odtud plyne **kolaterální konvergence** (jakmile zkonverguje prefix, vzorkují se ostatní schémata zaujatě) a problém **velkého rozptylu fitness** uvnitř schématu.
- U **deceptivních úloh** vedou stavební bloky pryč od optima. TST navíc ignoruje *konstruktivní* efekty křížení a mutace a počítá jen s destruktivními.

Voseho model (nekonečná populace)

Řetězce ztotožníme s čísly $0..2^l - 1$. Populaci pak popisuje vektor relativních četností $p(t)$ ležící v simplexu a výběr vektor *selekčních pravděpodobností* $s(t)$. Hledá se operátor $\mathcal{G} = \mathcal{M} \circ \mathcal{F}$ takový, že $p(t+1) = \mathcal{G}(p(t))$:

- $\mathcal{F}$ (selekce) je dána diagonální maticí fitness, $s = \mathbf{F}p / \sum_j \mathbf{F}_{jj}p_j$;
- $\mathcal{M}$ (křížení + mutace) je kvadratický operátor $\mathbb{E}[p'_k] = \sum_{i,j} s_i s_j r(i, j, k)$; díky symetrii $r(i, j, k) = r(i \oplus k, j \oplus k, 0)$ stačí *jediná* míchací matice.

Pevným bodem samotné $\mathcal{F}$ je populace kopií nejlepšího jedince, pevným bodem $\mathcal{M}$ rovnoměrné rozdělení. Napětí mezi nimi vysvětluje *přerušované rovnováhy*; pevné body celého $\mathcal{G}$ známy nejsou.

Konečné populace: Markovův řetězec

Stavy řetězce jsou možné populace a je jich $N = \binom{n+2^l-1}{2^l-1}$; přechodová matice $\mathbf{Q}$ je *exaktní*, ale astronomicky velká. Je-li $p_M > 0$, je řetězec **ireducibilní**, protože z každé populace lze dosáhnout každé jiné. Optimum je proto navštíveno s pravděpodobností 1, jenže bez elitismu se zase ztratí. Odtud plyne, že **elitistický GA konverguje k optimu s pravděpodobností 1**. Nekonečné populace tedy dávají model deterministický, exaktní a nepraktický, konečné populace model stochastický, realistický a nezvládnutelný; spojuje je limitní přechod.

EDA — praktický důsledek

Algoritmy odhadu rozdělení berou pohled „GA je transformace rozdělení“ doslova: místo operátorů se *učí model* p_θ a z něj vzorkují nové jedince. Opakují cyklus *vzorkuj* $\rightarrow$ *vyber lepší* $\rightarrow$ *přeúč model*. **UMDA** používá nezávislé marginály přepočítané z vybrané podpopulace, **PBIL** je posouvá inkrementálně podle $p_i \leftarrow (1 - \alpha)p_i + \alpha x_i^{\text{best}}$, **MIMIC** a **BMDA** zachytí párové závislosti, **BOA** bayesovskou síť a **CMA-ES** gaussovské rozdělení (otázka 3).

Otázka 3. Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce

Osnova odpovědi

1) ES: charakteristické volby, notace, samoadaptace 2) CMA-ES 3) DE a její geometrická podstata 4) koevoluce: typy, patologie, léky 5) otevřená evoluce a novelty search.

Evoluční strategie

ES pracují s reálnými vektory a *hlavním operátorem je mutace*. Rodičovská selekce je *náhodná*, environmentální *deterministická* a jedinec má tvar $[\vec{x}, \vec{\sigma}]$. U dvojice (μ, λ) a $(\mu + \lambda)$ je potřeba umět rozdíly v elitismu, konvergenci a ve schopnosti opustit lokální optimum. Liší se i v samoadaptaci: čárková varianta zapomíná, a proto v ní samoadaptace funguje lépe, neboť zastaralé σ nepřežije. **(1 + 1)-ES a pravidlo 1/5**: je-li podíl úspěšných mutací $p > 1/5$, σ se zvětší (o cca 10 %), při $p < 1/5$ se zmenší. Jde o řízení *adaptivní*, nikoli samoadaptivní. Při **samoadaptaci** se nejprve přepočítá $\sigma' = \sigma \exp(\tau' N(0, 1) + \tau N_i(0, 1))$ a teprve poté $x' = x + \sigma' N(0, 1)$. Pořadí *nejdřív* σ , *pak* x je podstatné, aby se nový krok hned otestoval. Strategických parametrů může být jeden (izotropní mutace), n (nekorelovaná) nebo $n(n + 1)/2$ (korelovaná, tedy včetně úhlů natočení). **Rekombinace** je lokální ($\rho = 2$), nebo globální ($\rho = \mu$), a zvlášť je buď diskretní (dominantní), nebo intermediární (aritmetická).

CMA-ES

Stavem je pětice $\theta = (\vec{m}, \sigma, \mathbf{C}, \vec{p}_\sigma, \vec{p}_c)$ a vzorkuje se z rozdělení $\mathcal{N}(\vec{m}, \sigma^2 \mathbf{C})$. Nový střed se spočítá z μ nejlepších vzorků, **evoluční cesty** $\vec{p}_\sigma, \vec{p}_c$ akumulují posuny středu, **rank-1** update opravuje $\mathbf{C}$ podle $\vec{p}_c \vec{p}_c^\top$ a **rank- μ** update podle rozptylu vybraných jedinců. Velikost kroku σ řídí *délka* $\vec{p}_\sigma$. Metoda je invariantní vůči monotónním transformacím fitness i lineárním transformacím prostoru a je de facto standardem pro spojitou black-box optimalizaci.

Diferenciální evoluce

V **DE/rand/1/bin** vznikne dárcce jako $\vec{v} = \vec{x}_a + F(\vec{x}_b - \vec{x}_c)$. Následuje *binomické* křížení s prahem C a pojistkou $j = I_{\text{rand}}$, která zaručí, že alespoň jedna složka pochází od dárce. Potomek pak bojuje s *vlastním rodičem* a nahradí jej jen tehdy, když je lepší. Parametry jsou $F \in [0, 2]$ (typicky 0,5–0,9), $C \in [0, 1]$ a $N \approx 10D$. **Geometrická podstata** metody spočívá v tom, že se měřítko i orientace kroků přebírají z aktuálního rozptylu populace. Adaptace tak funguje bez strategických parametrů: široká populace dělá velké kroky, zkonvergovaná jemně dolaďuje. Varianty jsou rand/1, rand/2, best/1, best/2 a current-to-

best, křížení buď **bin**, nebo **exp**. *Umět předvést krok s čísly: mutace $\rightarrow$ křížení $\rightarrow$ selekce.*

Koevoluce

Koevoluce stojí na kontextové fitness, kdy se jedinec hodnotí *proti ostatním*, a krajina je proto dynamická. **Kompetitivní** podobu mají predátor s kořistí, host s parazitem a Hillisovy řadičí sítě, **kooperativní** dekompozice úlohy na komponenty, CCGA a schéma moduly + blueprints. Mezi **patologie** patří cyklení (intransitivita), odpojení (jedna populace uteče), efekt *Červené královny* (všichni se zlepšují, ale *relativní* fitness zůstává konstantní, takže z naměřených hodnot nepoznáme, zda je pokrok skutečný), dále průměrné stabilní stavy, přespecializace a zapomínání. Léčí se archivy (*hall of fame*), sdílenou fitness a měřením proti *pevné externí sadě* protivníků. Modelovou úlohou je **věžňovo dilemma** s výplatami $T > R > P > S$ a $2R > T + S$. Zradit (D) je dominantní tah, DD je Nashovo ekvilibrium a zároveň jediné Pareto-neoptimální pole. V iterované verzi uspěje TFT a s ní čtyři vlastnosti úspěšné strategie: slušnost, dráždivost, odpouštění a nezávistivost, k nimž se jako pátá řadí srozumitelnost. V *zašuměném* prostředí vítězí **Pavlov** (win-stay, lose-shift: při výplatě R nebo P hraj C , při T nebo S hraj D). Opakování Axelrodova turnaje po 20 letech vyhrál *tým* ze Southamptonu: jeho strategie se prvními zhruba 10 tahy rozpoznaly a pak všechny obětavě nahrávaly jedné z nich.

Diverzita a dynamické krajiny

Diverzitu udrží fitness sharing, crowding, speciace, ostrovní model a nenáhodné páření. Mění-li se fitness v čase, pomáhá diploidie, hypermutace, náhodná migrace, udržování diverzity a (μ, λ) -ES, jejíž zapomínání je tu výhodou.

Otevřená evoluce

Otevřená evoluce běží *bez pevného cíle*. Poznává se podle trvalé novosti, neomezeného růstu složitosti, vzniku nových tříd entit a evoluce evolvability. Systémy Tierra, Avida, Polyworld a ECHO se však dříve či později *zaseknou*. **Generativní (nepřímé) reprezentace** jsou L-systémy, celulární automaty, buněčné kódování a CPPN. **Novelty search** účelovou funkci *vůbec nepoužívá* a měří místo ní řídkost $\rho(x)$ v prostoru *chování*, a to vůči populaci i permanentnímu archivu. U deceptivních úloh se cíl vyplatí zahodit. Navazuje na něj *quality-diversity* a **MAP-Elites**, který drží mřížku deskriptorů chování a v každé buňce nejlepšího jedince. V **interaktivní evoluci** je fitness člověk (Biomorphs, Picbreeder, EndlessForms); omezuje ji malá populace a únava uživatele.

Otázka 4. Rojové optimalizační algoritmy

Osnova odpovědi

1) co dělá roj rojem 2) PSO: rovnice, parametry, topologie 3) čím se PSO liší od GA 4) ACO: rovnice a konstrukce řešení 5) varianty ACO 6) kdy který algoritmus.

Východiska rojové inteligence

Roj tvoří mnoho jednoduchých agentů bez centrálního řízení. Globálně rozumné chování nikdo nenaplňuje, nýbrž **emerguje** z lokálních interakcí a z úprav prostředí; právě komunikaci přes prostředí, nikoli zprávou, se říká **stigmergie**. Systém drží v rovnováze dvojice protichůdných sil. **Kladnou zpětnou vazbu** obstarává feromon, protože úspěšnou volbu posiluje, a tlumí ji **odpařování** coby vazba záporná. **Decentralizace** váže rojové algoritmy přímo na reaktivní architektury agentů (subsumpce, Steelsův průzkumník Marsu): rojový algoritmus je multiagentní systém, který řeší optimalizaci.

PSO — rovnice

$$\vec{v} \leftarrow w\vec{v} + c_1 r_1 (\vec{p} - \vec{x}) + c_2 r_2 (\vec{g} - \vec{x}), \quad \vec{x} \leftarrow \vec{x} + \vec{v}$$

Rychlost částice skládají tři příspěvky. **Setrvačnost** w udržuje dosavadní směr a během běhu klesá z 0,9 na 0,4, takže se roj nejprve rozhlíží a teprve pak doladuje. **Kognitivní** složka $c_1(\vec{p} - \vec{x})$ táhne částici k její vlastní nejlepší pozici, **sociální** složka $c_2(\vec{g} - \vec{x})$ k nejlepší pozici v okolí; typicky se volí $c_1 = c_2 = 2$ a čísla $r_1, r_2 \sim U(0, 1)$ se losují *po složkách*. Aby rychlost nedivergovala, omezí se shora hodnotou $v_{\max}$, nebo se použije **constriction** $\chi \approx 0,729$. Co je pro částici „okolí“, určuje **topologie**. V *gbest* je okolím celý roj (úplný graf), což konverguje rychle, zato hrozí uvíznutí; *lbest* (kruh, mřížka) šíří informaci pomaleji, a proto lépe prozkoumává.

PSO vs. GA

PSO nemá křížení ani mutaci a populace se nenahrazuje, jen se pohybuje prostorem. Částice si navíc *pamatují* ($\vec{p}_i$ a $\vec{g}$) a informace mezi nimi teče *jednoměrně* od lepších k horším.

ACO — rovnice

Úloha se nejdřív převede na hledání nejkratší cesty v ohodnoceném grafu. Mravenci pak řešení *konstruují* hranu po hraně, nikoli vylepšují. Hranu volí s pravděpodobností $p_{ij} \propto \tau_{ij}^\alpha \eta_{ij}^\beta$, kde τ je feromon, tedy naučená zkušenost, a $\eta = 1/d_{ij}$ heuristika (viditelnost); exponenty α a β váží zkušenost proti heuristice. Feromon se pak aktualizuje podle $\tau \leftarrow (1 - \rho)\tau + \sum_k Q/L_k$: nejprve se *odpaří* a potom přibude přídavek úměrný kvalitě řešení, takže kratší cesta dostane víc.

Varianty ACO

V původním **AS** (Dorigo 1991) aktualizují feromon *všichni* mravenci. **Elitní** varianta jej svěří jen globálně nejlepšímu, **rank-based** N nejlepším s vahou podle pořadí. **ACS** se inspirovuje Q-learningem: globální update dělá jen nejlepší mravenec a navíc při každém průchodu hranou proběhne *lokální* update, který feromon *snižuje*, aby ostatní zkoušeli jiné cesty. Hranu k tomu vybírá pseudonáhodným pravidlem, tedy s pravděpodobností q_0 rovnou tu nejlepší, jinak vzorkováním jako v AS. **MAX–MIN** drží feromon v mezích $\tau_{\min}$ a $\tau_{\max}$, a brání tak předčasnou konvergenci. **Akce démona** je centralizovaný krok, který dělá algoritmus mimo mravence; typicky jde o lokální prohledávání nad zkonstruovanými řešeními. Spojité úlohy se řeší tak, že se prostor diskretizuje na podintervaly a feromon navádí do těch lepších.

Další rojové algoritmy (nastavba nad slidy EVA)

V **ABC** (*artificial bee colony*) má roj tři role: *dělnice* pracují u zdrojů, *pozorovatelky* si zdroj vybírají ruletou podle kvality a *průzkumnice* zdroj po vyčerpání limitu neúspěšných pokusů opustí a restartují jej náhodně. V algoritmu **firefly** klesá přitažlivost exponenciálně se vzdáleností, takže se roj samovolně rozdělí na podskupiny kolem lokálních optim; hodí se proto na multimodální úlohy.

Kdy který

Na spojitou úlohu bez zjevné struktury se hodí PSO nebo CMA-ES. Kde se řešení konstruuje jako cesta či permutace a existuje k tomu heuristika, vede ACO. V *dynamickém* prostředí, kde se mění hrany a vypadávají uzly, je ACO dobrou volbou také, protože odpařování samo zapomíná neplatnou zkušenost. S multimodální krajinou si poradí firefly a lbest PSO. V praxi se ACO používá na TSP, směřování vozidel i paketů, skládání proteinů a detekci hran v obraze.

Meze rojových metod

Rojové metody mají mnoho parametrů a žádnou teorii, jak je nastavit; konvergenční záruky platí jen pro speciální případy, u PSO za omezujících předpokladů na w, c_1, c_2 . Roji navíc hrozí *stagnace*, když všechny částice splynou s $\vec{g}$ — pomáhá restart, náboj neboli odpuzování a lbest topologie. ACO je drahé na vyhodnocení, protože každý mravenec staví celé řešení. V **diskrétním PSO** se rychlost interpretuje jako pravděpodobnost překlopení bitu (přes sigmoidu), případně u permutací jako posloupnost prohození.

Pasti

PSO nemá selekci: populace se nikdy nenahrazuje, jen se pohybuje. ACO řešení *staví* po hranách, nevylepšuje hotové. Lokální update v ACS feromon *snižuje*, je to tedy nástroj explorační, ne exploatační. Stigmergie není komunikace zprávou, ale *úpravou prostředí*.

Otázka 5. Memetické algoritmy, hill climbing, simulované žhání

Osnova odpovědi

1) hill climbing a jeho tři nepřátelé 2) simulované žhání 3) tabu search 4) scatter search 5) memetické algoritmy: Lamarck vs. Baldwin 6) ladění vs. řízení parametrů 7) kam to celé patří.

Hill climbing

Hill climbing prohledává okolí jediného řešení a jednotlivé varianty se liší jen tím, kterého souseda vyberou. **Steepest ascent** vezme toho nejlepšího, **first improvement** první lepší, což je levnější, **stochastic** losuje souseda s pravděpodobností úměrnou zlepšení a varianta **s náhodnými restarty** celý běh několikrát zopakuje z jiného místa. Nepřátelé jsou tři. V *lokálním optimu* se metoda zastaví, na *plošině* nemá žádný gradient, kterého by se držela, a zbude jí náhodná chůze, a přes *hřeben* se dostane jen kombinací několika kroků najednou.

Simulované žhání

Metropolisovo kritérium přijme i horšího souseda, a to s pravděpodobností $P = \min(1, e^{-\Delta/T})$. Při vysoké teplotě je běh téměř náhodnou chůzí, při nízké téměř hill climbingem. **Rozvrh chlazení** se v praxi volí geometrický, $T \leftarrow \alpha T$. Logaritmický $T_k \propto 1/\log k$ je sice nutný pro důkaz konvergence, ale prakticky nepoužitelný. Pro *pevné* T konverguje rozdělení stavů k Boltzmannovu, $\propto e^{-f/T}$.

Tabu search (Glover 1986)

Tabu search vždy přejde do *nejlepšího nezakázaného* souseda, i když je horší než aktuální řešení. Lokální optimum tedy opouští systematicky, ne náhodou. **Tabu list** zakazuje nedávné *tahy* (prohození měst, překlopení bitu, přidání hrany), nikoli celá řešení; je to úspornější a lépe se to zobecňuje. Jak dlouho tah zakázaný zůstane, udává **tenure**, buď statické T , nebo náhodné z rozsahu. **Aspirační kritérium** zákaz zruší, vede-li tah k novému nejlepšímu řešení. Paměti jsou tři. **Krátkodobou** je sám tabu list, **střednědobá** intenzifikuje hledání nad elitními řešeními a **dlouhodobá frekvenční** diverzifikuje, protože často navštěvované komponenty penalizuje nebo od nich restartuje.

Scatter search

Referenční množina se vybírá podle *kvality i diverzity*. Nová řešení vznikají *aritmetickými kombinacemi* jejich podmnožin a pak se ještě vylepší lokálním prohledáváním. Metoda je deterministická tam, kde EA sahá po náhodě.

Memetické algoritmy (Moscato 1989)

Memetický algoritmus je EA doplněný o lokální prohledávání nad jedinci: populace hledá globálně a *mem* (hill climbing, SA, tabu, 2-opt, gradient či backpropagation) doladuje lokálně. Celý zisk je v tom, že genetické operátory *přenášejí informaci mezi běhy lokálního hledání*. Varianty jsou dvě:

- **lamarckismus** nechá vylepšeného jedince *přepsat genotyp*; konverguje rychleji, zato rychleji ztrácí diverzitu (a darwinisticky je „nekošer“);
- **baldwinismus** promítne vylepšení *jen do fitness* a genotyp nechá být; je pomalejší, zachovává diverzitu a vyhlazuje krajinu, protože fitness měří *potenciál* jedince.

Návrhář ještě rozhoduje, na koho lokální hledání pustit (na všechny, na nejlepší, nebo náhodně s pravděpodobností p), jak dlouho t a jak silně. V **memetic computing** nejsou memy známy dopředu. *Multi-meme MA* nese mem přímo v genotypu, takže se dědí; *meta-Lamarckian MA* dá memům vlastní populaci, která koevoluuje s jedinci, a odměnou memu je fitness jedince, kterého vylepšil.

Ladění vs. řízení parametrů

Ladění (*tuning*) hledá parametry *před* během, ať už grid searchem, iterovanými závody, nebo meta-EA. Naráží na to, že parametry nejsou nezávislé a vyčerpávající hledání je nereálné. **Řízení** (*control*) je mění za běhu a má tři podoby:

- **pevné** se řídí deterministicky časem (T v SA, w v PSO, $\sigma(t) = 1 - 0,9t/T$), případně stochasticky;
- **adaptivní** reaguje na zpětnou vazbu z běhu (pravidlo 1/5 nebo Boltzmannův turnaj s teplotou, kterou lze při uvíznutí zase zvýšit);
- **samoadaptivní** nese parametr v genomu a nechá jej evolvovat (σ v ES).

Řídit lze i *reprezentaci* (přidat bity, klesne-li hammingovská diverzita) a *velikost populace* (jedinec dostane délku života úměrnou fitness a pak zemře).

Souvislosti

SA, tabu search a hill climbing jsou *jednoduché* metody a evoluční algoritmus je používá jako lokální krok: v memetických algoritmech, v akci démona u ACS, jako 2-opt u TSP nebo WalkSAT u SAT. U kombinatorických úloh se hybridizace s lokální heuristikou vyplatí téměř vždy (otázka 6).

Otázka 6. Aplikace evolučních algoritmů (evoluce expertních systémů, neuroevoluce, řešení kombinatorických úloh, vícekritériální optimalizace)

Osnova odpovědi

1) LCS: Michigan vs. Pittsburgh, ZCS, XCS 2) neuroevoluce: co se evoluuje, konkurující konvence, NEAT a HyperNEAT 3) kombinatorické úlohy: rozhoduje kódování + práce s omezeními 4) vícekritériální optimalizace: dominance, skalarizace, NSGA-II.

LCS: dva přístupy

V **michiganském** pojetí je jedinec *jedno pravidlo* a řešením je celá populace; odměnu je proto nutné mezi pravidla rozdělit (*credit assignment*). V **pittsburském** je jedinec *celá sada pravidel*, takže fitness je přímočará, zato operátory složité (GIL). **Hollandův LCS** má podmínky nad $\{0, 1, *\}$, vnitřní zprávy a receptory. Odměnu rozdělujeme **bucket brigade**: pravidlo platí svému předchůdci za právo jednat. **ZCS** zprávy zruší. Z *match setu* M se ruletou vybere akce a vznikne *action set* A ; posílí se A a A_{-1} , zbytek $M \setminus A$ platí daň, a je-li M prázdná, zasáhne operátor *cover*. Slabiny má tři: neevoluuje *úplnou* sadu pravidel, pravidla na začátku řetězců se odměňují zřídka a vymírají a stejně dopadnou pravidla vedoucí k malým, ale nutným odměnám. **XCS** popisuje klasifikátor pětici (c, a, p, ϵ, F) a staví fitness na *přesnosti predikce*, $\kappa = \alpha(\epsilon/\epsilon_0)^{-\nu}$, přičemž pro $\epsilon \leq \epsilon_0$ je $\kappa = 1$ a fitness je *relativní přesnost* v rámci *action setu*. Predikci aktualizuje Q-learning a GA běží *nikově* uvnitř *action setu*. Výsledkem je *úplná* a *minimální* mapa vstup–výstup. To je hlavní pointa proti „strength-based“ systémům, kde vyhrávalo pravidlo silné, ale nepřesné. Varianty jsou UCS (učení s učitelem) a XCSF (aproximace funkcí).

Neuroevoluce

Evoluovat lze váhy, topologii, obojí, nebo hyperparametry učení. EA má tři přednosti: nepotřebuje gradient, zvládá rekurentní sítě i RL s řídkou odměnou a snadno se paralelizuje. **Problém konkurujících konvencí** (permutační problém) spočívá v tom, že dvě funkčně stejné sítě mají různě uspořádané genomy, a křížení je pak bez opatření destruktivní. **Kódování architektury** bývá přímé (matice vah), gramatické (Kitano), nebo buněčné (Gruau, kde růst sítě řídí GP program). **GNARL** je EP nad grafy se strukturálními i parametrickými mutacemi řízenými „teplotou“. **NEAT** zapisuje síť jako seznam hran s *inovačními čísly* a kříží jen shodné geny, čímž konkurující konvence řeší. *Speciace* podle podobnosti genomů se sdílenou fitness chrání nové topologie, než se stihnou vyladit, a *complexification* začíná od minimální sítě. **HyperNEAT** umístí neurony do geometrického *substrátu* a váhu spoje generuje z jejich souřadnic funkce $\mathbb{R}^4 \rightarrow \mathbb{R}$, reprezentovaná **CPPN** (DAG s různými aktivačními funkcemi) a evolovaná pomocí NEAT. Zachytí tak symetrie a regularity a oddělí velikost genomu od velikosti sítě. **NAS** popisuje trojice prostor (lineární, DAG buněk, super síť), strategie (EA, RL, bayesovská, gradientní) a odhad výkonu (sdílení vah, tedy ENAS). Patří sem DeepNEAT a CoDeepNEAT (moduly + blueprints); ES jsou škálovatelnou alternativou gradientu v deep RL.

Kombinatorické úlohy

Batoh se kóduje bitovou mapou a operátory jsou triviální; problémem je *kapacitní omezení*. Řeší se čtyřmi způsoby: **penalizací** (je nutné

zvolit váhu α), **opravou** (lamarckovsky, nebo baldwinovsky), **dekodérem** (jednička znamená „přidej, pokud se vejde“, takže *každý* genotyp je přípustný) a **vícekritériální** formulací (maximalizuj cenu, minimalizuj překročení). U **TSP** je fitness triviální a rozhoduje kódování. Sousednostní a ordinální reprezentaci nepoužívají; volí se permutační s PMX, OX, CX či ER, případně maticová. Inicializuje se nejbližším sousedem nebo vkládáním hran a mutací je inverze (2-opt). U **SAT** je fitness počet splněných klauzulí; počet splněných *proměnných* nestačí, protože vyrábí plošiny. Dále se klauzule váží a přidává se *zjemňující funkce* $f + \alpha r(x)$, která rozliší jedince se stejnou fitness (váhy v_j sledují tendenci proměnné k 0 či 1). Reprezentace je bitová, reálná, klauzulová, nebo cestová a WalkSAT slouží jako lokální heuristika. U reálné reprezentace $(x \mapsto (1-y)^2, -x \mapsto (1+y)^2)$, minimalizuje se) pozor na to, že hodnoty jsou *penalty*: disjunkce (klauzule) je proto **součin** a konjunkce (formule) **součet**. **Rozvrhování** používá přímé maticové kódování. *Tvrdá* omezení se řeší v operátorech, *měkká* ve fitness; u job shopu stojí proti sobě permutace s dekodérem a přímé kódování celého plánu. Obecně rozhoduje kódování a operátory respektující strukturu úlohy, doplněné o hybridizaci s lokální heuristikou.

Vícekritériální optimalizace

Místo jedné fitness je dán vektor $f_1, \dots, f_n$; uvažujeme minimalizaci. Řešení x **slabě dominuje** y , platí-li $f_i(x) \leq f_i(y)$ pro všechna i , a **dominuje** je, existuje-li navíc j s $f_j(x) < f_j(y)$; jinak jsou obě **neporovnatelná**. Nedominovaná řešení tvoří **Pareto množinu** v prostoru řešení a **Pareto frontu** v prostoru kritérií. Cíl je dvojí: *konvergovat* k frontě a *rovnoměrně ji pokrýt*. **Skalarizace** převede úlohu na jednokritériální. Lineární vážený součet je jednoduchý, ale nenajde nekonvexní části fronty a váhy neumíme zvolit; ϵ -*constraint* minimalizuje f_1 a ostatní kritéria uplatní jako omezení; třetí možností je Čebyševova. **VEGA** (1985) byla první: populaci rozdělí na n dílů po N/n nejlepších podle každého f_i , čímž ale konverguje k jednotlivým optimům a ztrácí diverzitu. **NSGA** (1994) zavádí nedominované třídění do front $F_1, F_2, \dots$ (F_1 jsou nedominované z P , F_2 z $P \setminus F_1$ a tak dál) a nikový faktor $sh(i, j) = 1 - (d_{ij}/d_{share})^2$ pro $d_{ij} < d_{share}$. Slabinou je volba d_{share} a chybějící elitismus. **NSGA-II** (2000) opravuje obojí. Místo d_{share} počítá *crowding distance* $d_i = \sum_m (f_m(i+1) - f_m(i-1)) / (f_m^{\max} - f_m^{\min})$ s krajními body ∞ a v turnaji rozhoduje *crowded comparison* (vyhrává nižší fronta, při shodě větší crowding), takže se žádná fitness nepočítá a stačí porovnat ta dvě čísla; elitismus zajišťuje spojení $P_t \cup Q_t$. *Umět spočítat crowding distance na příkladu*. **NSGA-III** míří na *many-objective* úlohy a crowding nahrazuje *referenčními body*, tedy rovnoměrně rozmístěnými směry, jejichž počet $N = \binom{p+M+1}{p}$ zhruba odpovídá velikosti populace; při plnění se přednostně doplňují nedostatečně zastoupené směry. **MOEA/D** úlohu dekomponuje na podpopulace s různými váhovými vektory $\lambda^{(i)}$, používá Čebyševovu skalarizaci $\min \max_i \lambda_i |f_i(x) - z_i|$ vůči referenčnímu bodu z a kříží jen v *sousedství* $B(i)$ nejbližších váhových vektorů. **SMS-EMOA** je steady-state a z $P \cup \{q\}$ vybere podmnožinu velikosti μ , která maximalizuje **hypervolume** (S-metricku). **SPEA2** pracuje s archivem, silou dominujících a hustotou měřenou přes k -tého souseda. **Hyper-volume** je objem dominovaný frontou vůči referenčnímu bodu. Jako jediná běžná metrika je monotónní vůči dominanci a nepotřebuje znát skutečnou frontu; vedle ní se používají GD, IGD, spread a ϵ -indikátor.