

Přírodou inspirované počítání

Shrnutí okruhu ke státní závěrečné zkoušce — jedna otázka na jednu stranu

SZZ Umělá inteligence, zaměření Intelligentní agenti, MFF UK · srpen 2026

Oficiální znění okruhu (zdroj pravdy, 2025/2026):

<https://www.mff.cuni.cz/cs/studenti/bc-a-mgr-studium/studijni-plany/2025-2026/informatika/mgr/umela-inteligence>

Šest vět okruhu, šest stran. Podrobný výklad v 02-prirodou-inspirovane-pocitani.pdf (anglicky ENG/02-nature-inspired-computing.pdf); zdrojové slidy materialy/ (EVA I — NAIL025, EVA II — NAIL086, Neruda).

1. Genetické algoritmy, genetické a evoluční programování. str. 2
2. Teorie schémat, pravděpodobnostní modely jednoduchého genetického algoritmu. str. 3
3. Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce. str. 4
4. Rojové optimalizační algoritmy. str. 5
5. Memetické algoritmy, hill climbing, simulované žhání. str. 6
6. Aplikace evolučních algoritmů (evoluce expertních systémů, neuroevoluce, řešení kombinatorických úloh, vícekritériální optimalizace). str. 7

Jednotící pohled — tímhle lze začít kteroukoli odpověď. Všechny probírané metody jsou *stochastické black-box hledání*:

k dispozici jsou jen hodnoty f ve zvolených bodech (žádný gradient), cenou je počet vyhodnocení. Algoritmus drží *rozdělení* p_θ nad prostorem řešení a opakuje **vzorkuj** → **vyhodnoť** → **aktualizuj** θ ; θ je jediná informace, která přechází mezi iteracemi (co se naučil + kde hledat dál). Liší se jen tím, co je θ : **EA** rodičovská populace · **ES** gaussian (střed, σ) · **CMA-ES** ($\bar{m}$, σ , C , $\bar{p}_\sigma$, $\bar{p}_c$) · **EDA** parametry modelu (marginály, bayesovská síť) · **PSO** pozice, rychlosti a paměť · **ACO** feromonová matice · **SA** aktuální bod + teplota · **tabu** aktuální bod + zakázané tahy.

alg.	reprezentace	variace	selekce	co si zapamatovat
SGA	binární řetězec	1-bod. křížení, bit-flip	ruleta, generační	teorie schémat, BBH
ES	$\mathbb{R}^n + \sigma$	gaussovská mutace, rekombinace	náhodní rodiče, $(\mu, \lambda)/(\mu + \lambda)$	pravidlo 1/5, samoadaptace
CMA-ES	$\mathbb{R}^n$, model $\mathcal{N}(\bar{m}, \sigma^2 C)$	vzorkování z rozdělení	pořadová, μ nejlepších	evoluční cesty, rank-1/rank- μ
DE	$\mathbb{R}^n$	$\vec{x}_a + F(\vec{x}_b - \vec{x}_c)$, binom. křížení	souboj rodič-potomek	měřítka kroku z populace
EP	doménová (automat)	jen mutace	turnaj rodiče + potomci	genotyp = fenotyp
GP	syntaktický strom	výměna podstromů, mutace	turnaj	bloat, ADF
PSO	$\mathbb{R}^n$ + rychlost	pohybové rovnice	žádná (jen paměť)	w , c_1 , c_2 , gbest/lbest
ACO	konstrukce cesty	feromon + heuristika	implicitní	$\tau^\alpha \eta^\beta$, odpařování
SA	jedno řešení	soused	Metropolis	rozvrh chlazení
MA	libovolná	EA operátory + lokální hledání	libovolná	Lamarck vs. Baldwin
NSGA-II	libovolná	SBX + polynom. mutace	fronty + crowding	elitismus, crowding distance
NEAT	seznam hran	mutace struktury, křížení dle ID	sdílená fitness v druhu	inovační čísla, speciace

Průřezová témata — ptají se napříč otázkami

- **Explorace vs. exploatace** a kde ji každý algoritmus řídí: GA (křížení vs. selekční tlak), ES (σ , pravidlo 1/5), SA (teplota), PSO (w , topologie), ACO (q_0 , odpařování), tabu (tabu list), novelty search (jen explorace).
- **Udržení diversity**: fitness sharing, crowding, speciace, ostrovní model, nenáhodné páření, restart, hypermutace.
- **Adaptace parametrů**: ladění vs. řízení; pevné / adaptivní / samoadaptivní.
- **Práce s omezeními**: penalizace, oprava, dekodér, uzavřené operátory, vícekritériální formulace.
- **Lamarckismus vs. baldwinismus**: memetické algoritmy, oprava jedinců, neuroevoluce s doučováním vah.
- **Teorie**: věta o schématech a její kritika, Voseho model, Markovovy řetězce a konvergence elitistického GA, No Free Lunch, konvergence SA.

Co se chce spočítat u tabule

- Ruletová selekce pro danou populaci; jeden krok DE s čísly.
- PMX a OX na devítiprvkovém příkladu; inverze (2-opt) na permutaci.
- Věta o schématech: $o(S)$, $d(S)$, celé odvození nerovnosti.
- Crowding distance v NSGA-II; dominance a Pareto fronta z tabulky kritérií.
- Metropolisovo kritérium pro konkrétní Δ a T ; samoadaptace σ .

Zařazení oboru — na úvodní otázku

UI se dělí na „tvrdé“ logicko-formální metody a „měkké“ přírodou inspirované. **Computational intelligence** (dříve soft computing) = neuronové sítě + fuzzy + **evoluční výpočty (EC)**. EC zastřešuje biologicky motivované metaheuristiky; **EVA** je jeho podmnožina stavějící na principech evoluce (populace, stochastičnost, fitness, mutace, křížení). Mimo biologickou inspiraci stojí tabu, scatter a novelty search.

Nejčastější chyby

- Zaměnit *adaptivní* (pravidlo 1/5) a *samoadaptivní* (σ v genomu) řízení.
- U samoadaptace mutovat x dřív než σ — je to naopak (nový krok se musí hned otestovat).
- Tvrdit, že věta o schématech dokazuje konvergenci GA — je to nerovnost na *jeden* krok a o *střední hodnotě*.
- Zaměnit (μ, λ) a $(\mu + \lambda)$, resp. jejich elitismus.
- Považovat No Free Lunch za argument proti EA — je to argument *pro* doménovou specializaci reprezentace a operátorů.
- Říct, že lineární skalarizace vícekritériální úlohy najde celou Pareto frontu — nenajde nekonvexní části.
- Zaměnit Pareto *množinu* (v prostoru řešení) a Pareto *frontu* (v prostoru kritérií).

Otázka 1. Genetické algoritmy, genetické a evoluční programování

Osnova odpovědi

1) obecné schéma EA a role variace vs. selekce 2) selekce 3) SGA a binární kódování 4) reprezentace + operátory = fitness krajina 5) GP a jeho patologie 6) varianty GP 7) EP a srovnání čtyř historických větví.

Obecné schéma EA

Populační stochastické prohledávání; cyklus *inicializace* → *ohodnocení* → *rodičovská selekce* → *rekombinace* → *mutace* → *ohodnocení* → *environmentální selekce*. **Variace** (křížení, mutace) diverzitu *tvorí*, **selekce** ji *odebírá* a směřuje hledání; návrh EA = hledání rovnováhy **explorace/exploatace**. **No Free Lunch** (Wolpert & Macready 1995–97): průměrně přes všechny úlohy si všechny algoritmy vedou stejně → smysl má *doménová specializace* reprezentace a operátorů.

Selekce

Ruleta ($p_i = f_i / \sum_j f_j$; vysoký rozptyl, citlivá na škálování fitness), **SUS** (jedno náhodné místo a dál posuny po $1/n$ — stejné střední hodnoty, nižší rozptyl, „spravedlivější ruleta“), **turnaj** (tlak řídí velikost k , typicky 2–5; invariantní k *monotónním* transformacím fitness a nepotřebuje explicitní fitness — stačí porovnání, proto je jediný použitelný, když se hraje hra nebo běží simulace), **pořadová** (konstantní tlak), **Boltzmannova** (tlak roste s časem). **Elitismus** zaručuje monotonii nejlepší fitness. **Generační vs. steady-state** model se liší podílem nahrazované populace. **Škálování fitness** (lineární, sigma truncation, mocninné, pořadové, Boltzmannovo) opravuje dvě slabiny ruletové selekce: dominanci „supermanů“ na začátku a ztrátu tlaku na konci běhu.

SGA a binární kódování

SGA = binární řetězec + ruleta + 1-bodové křížení + bit-flip mutace + generační náhrada; parametry n , $p_C \approx 0,7$, $p_M \approx 1/m$. Reálná čísla binárně: $x = a + z(b-a)/(2^k - 1)$; **Hammingovy útesy** řeší **Grayův kód**. Hollandův argument pro binární abecedu (nejvíc schémat na bit) dnes *neobstojí* — binární kódování je pro řadu úloh nepřírozené. Křížení: **1-bodové** (rozbije schéma s pravd. $d(S)/(m-1)$, poziční bias), **2-bodové** (bez okrajového biasu), **uniformní** (nejvíc disruptivní, bez pozičního biasu). Mutace je v GA *sekundární* — brání nevratné ztrátě alel; **inverze** je historický operátor pro evoluci uspořádání genů.

Reprezentace a operátory

Reprezentace + operátory = fitness krajina. **Celočíselná**: mutace *nezaujatá* (nová hodnota z celé domény) nebo *zaujatá* (*creep*, normální

posun) — zaujatá dává smysl jen u ordinálních atributů, ne u nominálních. **Reálná**: gaussovská mutace $x' = x + \sigma N(0, 1)$; křížení *strukturní* (1-bodové, uniformní) nebo *aritmické* $\alpha \vec{x} + (1 - \alpha) \vec{y}$ — to však *zmenšuje rozptyl* populace, proto BLX- α a SBX. **Permutace**: PMX (pozice + mapování), OX (relativní pořadí), CX (absolutní pozice pomocí cyklů), ER (hrany — nejlepší pro TSP); mutace swap, insert, inverze (2-opt), scramble. *Umět předvést PMX a OX na devítiprvkovém příkladu*.

Stromové GP (Koza 1989)

Terminály + neterminály, požadavky **uzavřenosti** (každý neterminál zpracuje každou hodnotu) a **dostatečnosti** (řešení je v prostoru vyjádřitelné); inicializace *grow* / *full* / *ramped half-and-half*; křížení = výměna podstromů (neterminály volit s vyšší pravděpodobností, jinak se mění jen listy), víc typů mutací včetně mutace konstant; fitness = spuštění programu na datech. **Bloat** = růst velikosti bez zlepšení fitness (*intron*); tři vysvětlení — *replication accuracy*, *removal bias*, *crossover bias*. Obrana: limity velikosti, penalizace (*parsimony pressure*), anti-bloat operátory (hoist, shrink, size-fair), vícekritériální přístup. **ADF** = evolvované podprogramy (modularita), operátory pracují na větvích odděleně; typované a gramatické GP omezují prostor na smysluplné programy.

Varianty GP

Lineární GP (byte kód; jednodušší operátory a rychlá emulace, ale mutace snadno vyrobí nesmysl; oblíbené v a-life a pro boty ve hrách). **Grafové GP** (DAG — obvody, automaty, neuronové sítě). **Cartesian GP** (lineární genotyp → 2D mřížka uzlů, bodová mutace, $(1+4)$ -ES; část uzlů zůstává neaktivní). **Vývojové GP** (strom je program, který staví graf). **Gramatická evoluce**: lineární genom celých čísel, pravidlo gramatiky se vybírá *modulem*, derivační strom → fenotyp; robustní kódování a standardní operátory GA, ale nelokální mapování genotyp–fenotyp.

Evoluční programování a poučení

EP: konečné automaty, *genotyp = fenotyp* (a proto „křížení je zlo“), jen mutace, turnajová selekce z rodičů i potomků; příklad predikce prvočísel. Umět vyjmenovat čtyři historické větve **GA** / **ES** / **EP** / **GP** a jejich charakteristické volby. **Headless chicken test**: porovnej skutečné křížení s křížením s náhodně vygenerovaným partnerem. Vyhraje-li náhodné, křížení nekombinuje stavební bloky, ale funguje jen jako *makromutace* — špatné kódování, špatný operátor, nebo úloha bez stavebních bloků.

Otázka 2. Teorie schémat, pravděpodobnostní modely jednoduchého genetického algoritmu

Osnova odpovědi

1) schéma a jeho tři charakteristiky 2) věta o schématech a její odvození ve třech krocích 3) BBH, implicitní paralelismus, bandita 4) kritika 5) Voseho model (nekonečná populace) 6) Markovův řetězec (konečná populace) 7) EDA jako praktický důsledek.

Schéma

Slovo nad $\{0, 1, *\}$. Řád $o(S)$ = počet pevných pozic; **definující délka** $d(S)$ = vzdálenost první a poslední pevné pozice; $F(S)$ = průměrná fitness reprezentantů v dané populaci — tedy veličina závislá na populaci, ne na úloze. Počty: schémat délky m je 3^m , jeden jedinec je reprezentantem 2^m z nich, schéma s r hvězdičkami pokrývá 2^r jedinců a populace n jedinců obsahuje mezi 2^m a $n \cdot 2^m$ schémat.

Věta o schématech (TST)

$$\mathbb{E}[C(S, t+1)] \geq C(S, t) \frac{F(S)}{\bar{f}} \left[1 - p_C \frac{d(S)}{m-1} - p_M o(S) \right]$$

Odvození ve třech krocích: *selekce* $\rightarrow$ faktor $F(S)/\bar{f}$ (nadprůměrná schémata rostou exponenciálně), *křížení* $\rightarrow$ schéma se rozbije s pravděpodobností nejvýš $d(S)/(m-1)$, *mutace* $\rightarrow$ přežije s pravděpodobností $(1 - p_M)^{o(S)} \approx 1 - p_M o(S)$. Slovně (Holland): *krátká, nízkého řádu a nadprůměrná* schémata rostou v populaci exponenciálně.

Příklad na dosazení ($m = 8$, $p_C = 0,7$, $p_M = 0,01$, $F(S)/\bar{f} = 1,5$)

$S = 1**0***1$: $o(S) = 3$, $d(S) = 7 \rightarrow 1 - 0,7 \cdot \frac{7}{7} - 0,01 \cdot 3 = 0,27$, tedy $1,5 \cdot 0,27 = 0,41$ — schéma *ubývá*, přestože je nadprůměrné. $S' = 110*****$: $o = 3$, $d = 2 \rightarrow 1 - 0,7 \cdot \frac{2}{7} - 0,03 = 0,77$, tedy $1,5 \cdot 0,77 = 1,16$ — *roste*. Přesně to je obsah slov „krátká a nízkého řádu“: rozhoduje $d(S)$, ne jen fitness.

BBH a implicitní paralelismus

Hypotéza stavebních bloků: GA skládá řešení z krátkých, nízkého řádu a nadprůměrných schémat. Důsledky: záleží na *kódování* (příbuzné geny blízko sebe) i na *velikosti populace*, škodí předčasná konvergence. **Implicitní paralelismus**: populace n jedinců implicitně zpracovává 2^m až $n \cdot 2^m$ schémat, ale exponenciálně roste jen řádově n^3 z nich („jediný případ, kdy je kombinatorická exploze na naší straně“).

Bandita

N mincí, dvouruký bandita s výplatami o středech μ_1, μ_2 a rozptylech σ_1, σ_2 . Analytické řešení: *exponenciálně* více pokusů dosud vítězné páce, $N - n^* = O(e^{c n^*})$. GA alokuje sloty v populaci stejně, a řeší tak dilema *explorace/exploatace* optimálně. Přesněji: schémata řádu k soupeří o týchž k pevných pozic, hrají tedy 2^k -**rukého banditu** (ne jednu hru s 3^m pákami).

Kritika teorie schémat

- Nerovnost platí jen na *jeden* krok a o *střední hodnotě* — nelze iterovat, $F(S)$ i $\bar{f}$ se mění; v malé populaci navíc vznikají výběrové chyby (drift).
- Ramena bandity jsou nezávislá, schémata *nejsou* — SGA je nevzorkuje nezávisle, a proto *špatně odhaduje jejich fitness*. Kanonický protipříklad: $f(x) = 2$ pro $111 \dots$, 1 pro $0 \dots$, jinak 0 . Skutečně je $F(1 \dots) = 1/2 < F(0 \dots) = 1$, ale SGA odhadne $F(1 \dots) \approx 2$, protože v populaci převládnou zástupci $111 \dots$.
- Statická BBH** (Grefenstette 1991): lidé očekávají konvergenci ke schématům se skutečnou průměrnou fitness, GA však konverguje k fitness *pozorované v populaci*. Odtud **kolaterální konvergence** (po konvergenci prefixu se ostatní schémata vzorkují zaujatě) a problém **velkého rozptylu fitness** uvnitř schématu.
- Deceptivní úlohy** (stavební bloky vedou pryč od optima); TST ignoruje *konstruktivní* efekty křížení a mutace, počítá jen s destruktivními.

Voseho model (nekonečná populace)

Řetězce ztotožníme s čísly $0..2^l - 1$. Populaci popisuje vektor relativních četností $p(t)$ v simplexu, vektor *selekčních pravděpodobností* $s(t)$. Hledáme $\mathcal{G} = \mathcal{M} \circ \mathcal{F}$ s $p(t+1) = \mathcal{G}(p(t))$:

- $\mathcal{F}$ (selekce) je dána diagonální maticí fitness, $s = \mathbf{F}p / \sum_j \mathbf{F}_{jj}p_j$;
- $\mathcal{M}$ (křížení + mutace) je kvadratický operátor $\mathbb{E}[p'_k] = \sum_{i,j} s_i s_j r(i, j, k)$; díky symetrii $r(i, j, k) = r(i \oplus k, j \oplus k, 0)$ stačí *jediná* míchací matice.

Pevné body: $\mathcal{F}$ — populace kopií nejlepšího jedince; $\mathcal{M}$ — rovnoměrné rozdělení. Jejich napětí vysvětluje *přerušované rovnováhy*; pevné body celého $\mathcal{G}$ známy nejsou.

Konečné populace: Markovův řetězec

Stavy = možné populace, jejich počet $N = \binom{n+2^l-1}{2^l-1}$; přechodová matice $\mathbf{Q}$ je *exaktní*, ale astronomicky velká. Při $p_M > 0$ je řetězec **ireducibilní** (z každé populace lze dosáhnout každé), takže optimum je navštíveno s pravděpodobností 1 — ale bez elitismu se zase ztratí; **elitistický GA proto konverguje k optimu s pravděpodobností 1**. Shrnutí: nekonečné populace = deterministický model (exaktní, nepraktický), konečné = stochastický (realistický, nezvládnutelný); limitní přechod je spojuje.

EDA — praktický důsledek

Algoritmy odhadu rozdělení berou pohled „GA = transformace rozdělení“ doslova: místo operátorů se *učí model* p_θ a z něj vzorkují. Cyklus *vzorkuj* $\rightarrow$ *vyber lepší* $\rightarrow$ *přeuč model*. **UMDA** — nezávislé marginály přepočítané z vybrané podpopulace; **PBIL** — inkrementálně $p_i \leftarrow (1 - \alpha)p_i + \alpha x_i^{\text{best}}$; **MIMIC/BMDA** — párové závislosti; **BOA** — bayesovská síť; **CMA-ES** — gaussovské rozdělení (otázka 3).

Otázka 3. Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce

Osnova odpovědi

1) ES: charakteristické volby, notace, samoadaptace 2) CMA-ES 3) DE a její geometrická podstata 4) koevoluce: typy, patologie, léky 5) otevřená evoluce a novelty search.

Evoluční strategie

Reálné vektory, *mutace je hlavní operátor*, rodičovská selekce *náhodná*, environmentální selekce *deterministická*; jedinec = $[\vec{x}, \vec{\sigma}]$. (μ, λ) vs. $(\mu + \lambda)$ — umět rozdíly v elitismu, konvergenci, schopnosti opustit lokální optimum a v samoadaptaci (čárková varianta zapomíná, a proto v ní samoadaptace funguje lépe: zastaralé σ nepřežije). **(1 + 1)-ES a pravidlo 1/5**: podíl úspěšných mutací $p > 1/5 \rightarrow$ zvětší σ (o cca 10 %), $p < 1/5 \rightarrow$ zmenší — jde o *adaptivní*, nikoli samoadaptivní řízení. **Samoadaptace**: $\sigma' = \sigma \exp(\tau' N(0, 1) + \tau N_i(0, 1))$, teprve poté $x' = x + \sigma' N(0, 1)$ — *nejdříve σ , pak x* , aby se nový krok hned otestoval. Počet strategických parametrů: 1 (izotropní), n (nekorelované), $n(n+1)/2$ (korelované, včetně úhlů natočení). **Rekombinace**: lokální ($\rho = 2$) / globální ($\rho = \mu$), diskretní (dominantní) / intermediární (aritmetická).

CMA-ES

Stav $\theta = (\vec{m}, \sigma, \mathbf{C}, \vec{p}_\sigma, \vec{p}_c)$, vzorkuje se $\mathcal{N}(\vec{m}, \sigma^2 \mathbf{C})$. Aktualizace: nový střed z μ nejlepších vzorků; **evoluční cesty** $\vec{p}_\sigma, \vec{p}_c$ akumulují posuny středu; **rank-1** update podle $\vec{p}_c \vec{p}_c^\top$ a **rank- μ** update podle rozptylu vybraných jedinců; *délka $\vec{p}_\sigma$ řídí velikost kroku σ* . Invariantní vůči monotónním transformacím fitness a lineárním transformacím prostoru; de facto standard pro spojitou black-box optimalizaci.

Diferenciální evoluce

DE/rand/1/bin: dárce $\vec{v} = \vec{x}_a + F(\vec{x}_b - \vec{x}_c)$; *binomické* křížení s prahem C a pojistkou $j = I_{\text{rand}}$ (alespoň jedna složka od dárce); souboj potomka s *vlastním rodičem* — nahrazení jen při zlepšení. Parametry: $F \in [0, 2]$ (typicky 0,5–0,9), $C \in [0, 1]$, $N \approx 10D$. **Geometrická podstata**: měřítko i orientace kroků se přebírají z aktuálního rozptylu populace $\rightarrow$ adaptace bez strategických parametrů (široká populace = velké kroky, zkonvergovaná = jemné doladění). Varianty: rand/1, rand/2, best/1, best/2, current-to-best; bin vs. exp křížení. *Umět předvést krok s čísly: mutace $\rightarrow$ křížení $\rightarrow$ selekce.*

Koevoluce

= kontextová fitness (hodnotí se *proti ostatním*) + dynamická krajina. **Kompetitivní**: predátor–kořist, host–parazit, Hillisovy řadičí sítě. **Kooperativní**: dekompozice na komponenty, CCGA, moduly + blueprints. **Patologie**: cyklení (intranзитivita), odpojení (jedna populace uteče), efekt *Červené královny* (všichni se zlepšují, ale *relativní* fitness zůstává konstantní — z naměřených hodnot nepoznáme, zda je pokrok skutečný), průměrné stabilní stavy, přespecializace, zapomínání. **Léky**: archivy (*hall of fame*), sdílená fitness, měření proti *pevné externí sadě* protivníků. **Věžňovo dilema** jako modelová úloha: $T > R > P > S$ a $2R > T + S$; D dominantní, DD je Nashovo ekvilibrium a jediné Pareto-neoptimální pole; iterovaná verze $\rightarrow$ TFT a čtyři vlastnosti úspěšné strategie (slušnost, dráždivost, odpouštění, nezávislost) + srozumitelnost jako pátá. V *zašuměném* prostředí vítězí **Pavlov** (win-stay, lose-shift: při výplatě R nebo P hraj C , při T nebo S hraj D). Opakování Axelrodova turnaje po 20 letech vyhrál tým ze Southamptonu: strategie se prvními cca 10 tahy rozpoznaly a pak všechny obětavě nahrávaly jedné z nich.

Diverzita a dynamické krajiny

Diverzita: fitness sharing, crowding, speciace, ostrovní model, nenáhodné páření. Dynamická fitness: diploidie, hypermutace, náhodná migrace, udržování diverzity, (μ, λ) -ES (zapomínání je zde výhodou).

Otevřená evoluce

Evoluce *bez pevného cíle*. Znaky: trvalá novost, neomezený růst složitosti, vznik nových tříd entit, evoluce evolvability. Systémy Tierra, Avida, Polyworld, ECHO — všechny se dříve či později *zaseknou*. **Generativní (nepřímé) reprezentace**: L-systémy, celulární automaty, buněčné kódování, CPPN. **Novelty search**: účelová funkce se *vůbec nepoužívá*, měří se řídkost $\rho(x)$ v prostoru *chování* vůči populaci a permanentnímu archivu — u deceptivních úloh se vyplatí cíl zahodit. Navazuje *quality-diversity* a **MAP-Elites** (mřížka deskriptorů chování, v každé buňce nejlepší jedinec). **Interaktivní evoluce**: fitness = člověk (Biomorphs, Picbreeder, EndlessForms); omezením je malá populace a únava uživatele.

Otázka 4. Rojové optimalizační algoritmy

Osnova odpovědi

1) co dělá roj rojem 2) PSO: rovnice, parametry, topologie 3) čím se PSO liší od GA 4) ACO: rovnice a konstrukce řešení 5) varianty ACO 6) kdy který algoritmus.

Východiska rojové inteligence

Mnoho jednoduchých agentů bez centrálního řízení; z lokálních interakcí a úprav prostředí vzniká globálně rozumné chování. Klíčová slova: **stigmergie** (komunikace přes prostředí), **emergence**, **decentralizace**, **kladná zpětná vazba** (feromon) tlumená **odpařováním** jako zápornou zpětnou vazbou. Přímá vazba na reaktivní architektury agentů (subsumpce, Steelsův průzkumník Marsu) — rojové algoritmy jsou MAS řešící optimalizaci.

PSO — rovnice

$$\vec{v} \leftarrow w\vec{v} + c_1 r_1 (\vec{p} - \vec{x}) + c_2 r_2 (\vec{g} - \vec{x}), \quad \vec{x} \leftarrow \vec{x} + \vec{v}$$

w = **setrvačnost** (klesá $0,9 \rightarrow 0,4$: nejdřív explorace, pak exploatace); $c_1(\vec{p} - \vec{x})$ = **kognitivní** složka (osobní nejlepší pozice); $c_2(\vec{g} - \vec{x})$ = **sociální** složka (nejlepší v okolí); typicky $c_1 = c_2 = 2$, $r_1, r_2 \sim U(0, 1)$ po složkách. Divergenci brání omezení $v_{\max}$ nebo **constriction** $\chi \approx 0,729$. **Topologie**: *gbest* (úplný graf — rychlá konvergence, riziko uvíznutí) vs. *lbest* (kruh, mřížka — pomalejší šíření informace, lepší explorace).

PSO vs. GA

Žádné křížení ani mutace; částice mají *paměť* ($\vec{p}_i, \vec{g}$); informace teče *jednosměrně* od lepších k horším; populace se nenahrazuje, jen se pohybuje.

ACO — rovnice

Úloha se převede na hledání nejkratší cesty v ohodnoceném grafu; mravenci řešení *konstruují* po hranách, nikoli vylepšují. Pravděpodobnost přechodu $p_{ij} \propto \tau_{ij}^\alpha \eta_{ij}^\beta$, kde τ = feromon (naučená zkušenost) a $\eta = 1/d_{ij}$ = heuristika (viditelnost); α, β váží zkušenost proti heuristice. Aktualizace $\tau \leftarrow (1 - \rho)\tau + \sum_k Q/L_k$ — *odpařování* + přídavek úměrný kvalitě řešení (kratší cesta $\rightarrow$ víc feromonu).

Varianty ACO

AS (původní, Dorigo 1991: feromon aktualizují *všichni* mravenci)

· **elitní** a **rank-based** (aktualizuje jen globálně nejlepší, resp. N nejlepších s vahou podle pořadí) · **ACS** (inspirace Q-learningem: globální update jen nejlepším; navíc *lokální* update při každém průchodu hranou, který feromon *snižuje*, aby ostatní zkoušeli jiné cesty; pseudonáhodné pravidlo — s pravděpodobností q_0 rovnou nejlepší hrana, jinak vzorkování jako v AS) · **MAX–MIN** (meze $\tau_{\min}, \tau_{\max}$ proti předčasné konvergenci). **Akce démona** = centralizovaný krok mimo mravence, typicky lokální prohledávání nad zkonstruovanými řešeními. Pro spojitě úlohy se prostor diskretizuje na podintervaly a feromon navádí do lepších z nich.

Další rojové algoritmy (nastavba nad slidy EVA)

ABC (*artificial bee colony*): *dělnice* u zdrojů, *pozorovatelky* vybírají zdroj ruletou podle kvality, *průzkumnice* po vyčerpání limitu neúspěšných pokusů zdroj opustí a restartují jej náhodně. **Firefly**: přitažlivost klesá exponenciálně se vzdáleností, takže se roj samovolně dělí na podskupiny okolo lokálních optim — vhodné pro multimodální úlohy.

Kdy který

Spojitá úloha bez struktury $\rightarrow$ PSO nebo CMA-ES; konstrukce cesty či permutace, kde existuje heuristika $\rightarrow$ ACO; *dynamické* prostředí (mění se hrany, vypadávají uzly) $\rightarrow$ ACO, protože odpařování samo zapomíná neplatnou zkušenost; multimodální krajina $\rightarrow$ firefly, lbest PSO. Praxe ACO: TSP, směřování vozidel a paketů, skládání proteinů, detekce hran v obraze.

Meze rojových metod

Mnoho parametrů bez teorie, jak je nastavit; konvergenční záruky jen pro speciální případy (u PSO za omezujících předpokladů na w, c_1, c_2); u PSO hrozí *stagnace* roje, když všechny částice splynou s $\vec{g}$ (léky: restart, náboj/odpuzování, lbest topologie); ACO je drahé na vyhodnocení, protože každý mravenec staví celé řešení. **Diskrétní PSO**: rychlost se interpretuje jako pravděpodobnost překlopení bitu (sigmoida), případně jako posloupnost prohození u permutací.

Pasti

PSO nemá selekci — populace se nikdy nenahrazuje, jen se pohybuje. ACO řešení *staví* po hranách, nevylepšuje hotové. Lokální update v ACS feromon *snižuje* — je to nástroj explorace, ne exploatace. Stigmergie není komunikace zprávou, ale *úpravou prostředí*.

Otázka 5. Memetické algoritmy, hill climbing, simulované žhání

Osnova odpovědi

1) hill climbing a jeho tři nepřátelé 2) simulované žhání 3) tabu search 4) scatter search 5) memetické algoritmy: Lamarck vs. Baldwin 6) ladění vs. řízení parametrů 7) kam to celé patří.

Hill climbing

Prohledávání okolí jednoho řešení: **steepest ascent** (nejlepší soused) · **first improvement** (první lepší — levnější) · **stochastic** (soused s pravděpodobností úměrnou zlepšení) · **s náhodnými restarty**. Tři nepřátelé: *lokální optima*, *plošiny* (žádný gradient, jen náhodná chůze), *hřebeny* (zlepšení jen kombinací více kroků najednou).

Simulované žhání

Metropolisovo kritérium: horší soused se přijme s pravděpodobností $P = \min(1, e^{-\Delta/T})$ — při vysoké teplotě téměř náhodná chůze, při nízké téměř hill climbing. **Rozvrh chlazení**: geometrický $T \leftarrow \alpha T$ (v praxi), logaritmický $T_k \propto 1/\log k$ (nutný pro důkaz convergence, prakticky nepoužitelný). Pro *pevné* T konverguje rozdělení stavů k Boltzmannovu $\propto e^{-f/T}$.

Tabu search (Glover 1986)

Vždy se přejde do *nejlepšího nezakázaného* souseda, i když je horší než aktuální řešení — odtud schopnost opustit lokální optimum bez náhody. **Tabu list** zakazuje nedávné *tahy* (swap měst, překlopení bitu, přidání hrany), ne celá řešení — je to úspornější a zobecňuje to lépe. **Tenure** = počet iterací, po které tah zůstává zakázán (statické T , nebo náhodné z rozsahu). **Aspirační kritérium** zákaz zruší, vede-li tah k novému nejlepšímu řešení. Tři paměti: **krátkodobá** (tabu list) · **střednědobá** (intenzifikace nad elitními řešeními) · **dlouhodobá frekvenční** (diverzifikace — často navštěvované komponenty se penalizují nebo se od nich restartuje).

Scatter search

Referenční množina se vybírá podle *kvality i diverzity*, nová řešení vznikají *aritmetickými kombinacemi* podmnožin a následným vylepšením lokálním prohledáváním; deterministické tam, kde EA používá náhodu.

Memetické algoritmy (Moscato 1989)

= EA + lokální prohledávání nad jedinci: populace hledá globálně, *mem* (hill climbing, SA, tabu, 2-opt, gradient/backpropagation) dolaďuje lokálně. Genetické operátory navíc *přenášejí informaci mezi běhy lokálního hledání*, což je celý zisk. Dvě varianty:

- **lamarckismus** — vylepšený jedinec *přepíše genotyp*; rychlejší convergence, ale rychlejší ztráta diverzity (a darwinisticky „nekošer“);
- **baldwinismus** — vylepšení se projeví *jen ve fitness*, genotyp zůstane; pomalejší, zachovává diverzitu a vyhlazuje krajinu (fitness = *potenciál* jedince).

Rozhodnutí návrhu: na koho lokální hledání pustit (všichni / nejlepší / náhodně s pravděpodobností p), jak dlouho t a jak silně. **Meme-tic computing**: memy nejsou známy dopředu — *multi-meme MA* (mem je součást genotypu a dědí se) a *meta-Lamarckian MA* (memy mají vlastní populaci a koevolují s jedinci, odměnou memu je fitness jedince, který vylepšil).

Ladění vs. řízení parametrů

Ladění (*tuning*) — hledá se *před* během (grid search, iterované závody, meta-EA); parametry ale nejsou nezávislé a vyčerpávající hledání je nereálné. **Řízení** (*control*) — mění se *za* běhu:

- **pevné** — deterministicky podle času (T v SA, w v PSO, $\sigma(t) = 1 - 0,9t/T$), případně stochasticky;
- **adaptivní** — podle zpětné vazby z běhu (pravidlo 1/5, Boltzmannův turnaj s teplotou, kterou lze při uvíznutí zase zvýšit);
- **samoadaptivní** — parametr je součástí genomu a evoluuje (σ v ES).

Řídit lze i *reprezentaci* (přidávat bity, klesne-li hammingovská diverzita) a *velikost populace* (jedinec dostane délku života úměrnou fitness a pak zemře).

Souvislosti

SA, tabu a HC jsou *jednobodové* metody, které EA doplňují jako lokální krok (memetické algoritmy, akce démona v ACS, 2-opt v TSP, WalkSAT v SAT). U kombinatorických úloh je hybridizace s lokální heuristikou téměř vždy výhodná (otázka 6).

Otázka 6. Aplikace evolučních algoritmů (evoluce expertních systémů, neuroevoluce, řešení kombinatorických úloh, vícekriteriální optimalizace)

Osnova odpovědi

1) LCS: Michigan vs. Pittsburgh, ZCS, XCS 2) neuroevoluce: co se evoluuje, konkurující konvence, NEAT a HyperNEAT 3) kombinatorické úlohy: rozhoduje kódování + práce s omezeními 4) vícekriteriální optimalizace: dominance, skalarizace, NSGA-II.

LCS: dva přístupy

Michigan: jedinec = jedno pravidlo, řešením je celá populace → nutné rozdělení odměny (*credit assignment*). **Pittsburgh:** jedinec = celá sada pravidel, fitness přímočará, ale operátory složité (GIL). **Hollandův LCS:** podmínky nad $\{0, 1, *\}$, vnitřní zprávy a receptory, **bucket brigade** (pravidlo platí předchůdci za právo jednat). **ZCS:** bez zpráv; *match set* $M \rightarrow$ ruletový výběr akce $\rightarrow$ *action set* A ; posílení A a A_{-1} , daň pro $M \setminus A$; operátor *cover* při prázdném M . Slabiny: neevoluuje úplnou sadu pravidel, pravidla na začátku řetězců se odměňují zřídka a vymírají, stejně tak pravidla vedoucí k malým, ale nutným odměnám. **XCS:** klasifikátor (c, a, p, ϵ, F) , *fitness podle přesnosti predikce* $\kappa = \alpha(\epsilon/\epsilon_0)^{-\nu}$ (pro $\epsilon \leq \epsilon_0$ je $\kappa = 1$; fitness je relativní přesnost v action setu), predikce se aktualizuje Q-learningem, GA běží nikoliv uvnitř action setu. Výsledkem je úplná a minimální mapa vstup-výstup — to je hlavní pointa oproti „strength-based“ systémům, kde silné, ale nepřesné pravidlo vyhrávalo. Varianty UCS (s učitelem), XCSF (aproximace funkcí).

Neuroevoluce

Co se evoluuje: váhy / topologie / obojí / hyperparametry učení. Předností EA: nepotřebuje gradient, zvládá rekurentní sítě a RL s řídkou odměnou, snadno se paralelizuje. **Problém konkurujících konvencí** (permutační problém): dvě funkčně stejné sítě mají různě uspořádané genomy → křížení je bez opatření destruktivní. **Kódování architektury:** přímé (matice vah), gramatické (Kitano), buněčné (Gruau — GP program řídí růst sítě); **GNARL** = EP nad grafy, strukturální i parametrické mutace řízené „teplotou“. **NEAT:** seznam hran s *inovačními čísly* (křížení jen shodných genů — tím řeší konkurující konvence), *speciace* podle podobnosti genomů se sdílenou fitness (chrání nové topologie, než se stihnou vydatit), *complexification* od minimální sítě. **HyperNEAT:** neurony leží v geometrickém *substrátu* a váhu spoje generuje z jejich souřadnic funkce $\mathbb{R}^4 \rightarrow \mathbb{R}$ reprezentovaná **CPPN** (DAG s různými aktivačními funkcemi) evolvovanou pomocí NEAT — zachytí symetrie a regularity, oddělí velikost genomu od velikosti sítě. **NAS:** prostor (lineární / DAG buněk / super síť), strategie (EA, RL, bayesovská, gradientní), odhad výkonu (sdílení vah — ENAS); DeepNEAT a CoDeepNEAT (moduly + blueprints); ES jako škálovatelná alternativa gradientu v deep RL.

Kombinatorické úlohy

Batoh: bitová mapa, triviální operátory, problém je *kapacitní omezení* — čtyři strategie: **penalizace** (volba váhy α), **oprava** (lamarckovsky nebo baldwinovsky), **dekodér** („1 znamená: přidej, pokud se vejde“ —

každý genotyp je pak přípustný), **vícekriteriální** formulace (maximalizuj cenu, minimalizuj překročení). **TSP:** fitness triviální, rozhoduje kódování. Sousednostní a ordinální reprezentaci nepoužívat; permutační + PMX/OX/CX/ER, případně maticová. Inicializace nejbližším sousedem či vkládáním hran; mutace inverze (2-opt). **SAT:** fitness = počet splněných klauzulí (počet splněných *proměnných* nestačí — plošiny), dále vážení klauzulí a *zjemňující funkce* $f + \alpha r(x)$, která rozliší jedince se stejnou fitness (váhy v_j sledují tendenci proměnné k 0/1). Reprezentace bitová, reálná, klauzulová, cestová; WalkSAT jako lokální heuristika. U reálné reprezentace $(x \mapsto (1 - y)^2, \neg x \mapsto (1 + y)^2)$, minimalizace) pozor: hodnoty jsou *penalty*, takže disjunkce (klauzule) je **součin** a konjunkce (formule) **součet**. **Rozvrhování:** přímé maticové kódování; *tvrdá* omezení řešit v operátorech, *měkká* ve fitness; job shop — permutace s dekodérem vs. přímé kódování celého plánu. Obecné pravidlo: rozhoduje kódování a operátory respektující strukturu úlohy + hybridizace s lokální heuristikou.

Vícekriteriální optimalizace

Místo jedné fitness vektor $f_1, \dots, f_n$ (uvažujme minimalizaci). **Slabá dominance** $f_i(x) \leq f_i(y)$ pro všechna i ; **dominance** navíc $\exists j : f_j(x) < f_j(y)$; jinak jsou řešení **neporovnatelná**. **Pareto množina** (v prostoru řešení) a **Pareto fronta** (v prostoru kritérií, množina nedominovaných). Dvojitý cíl: *konvergence* k frontě + *rovnovážné pokrytí* fronty. **Skalarizace:** lineární vážený součet (jednoduchá, ale nenajde nekonvexní části fronty a váhy neumíme zvolit), ϵ -*constraint* (minimalizuj f_1 , ostatní jako omezení), Čebyševova. **VEGA** (1985, první): populace se rozdělí na n dílů po N/n nejlepších podle každého f_i — konverguje k jednotlivým optimům a ztrácí diverzitu. **NSGA** (1994): nedominované třídění do front $F_1, F_2, \dots$ (F_1 nedominované z P , F_2 z $P \setminus F_1, \dots$) + nikový faktor $sh(i, j) = 1 - (d_{ij}/d_{share})^2$ pro $d_{ij} < d_{share}$; slabiny: volba d_{share} a chybějící elitismus. **NSGA-II** (2000) obojí opravuje: místo d_{share} *crowding distance* $d_i = \sum_m (f_m(i+1) - f_m(i-1)) / (f_m^{max} - f_m^{min})$, krajní body ∞ ; *crowded comparison* (nižší fronta vyhrává, při shodě větší crowding) v turnaji — žádná fitness se nepočítá, porovnávají se jen ta dvě čísla; elitismus spojením $P_t \cup Q_t$. *Umět spočítat crowding distance na příkladu*. **NSGA-III:** pro *many-objective* nahrazuje crowding *referenčními body* (rovnoměrně rozmístěné směry, počet $\approx$ velikost populace, $N = \binom{p+M+1}{p}$); při plnění se přednostně doplňují nedostatečně zastoupené směry. **MOEA/D:** dekompozice na podpopulace s různými váhovými vektory $\lambda^{(i)}$, Čebyševova skalarizace $\min \max_i \lambda_i |f_i(x) - z_i|$ vůči referenčnímu bodu z , křížení jen v *sousedství* $B(i)$ nejbližších váhových vektorů. **SMS-EMOA:** steady-state, z $P \cup \{q\}$ se vybere podmnožina velikosti μ maximalizující **hypervolume** (S-metricku). **SPEA2:** archiv, síla dominujících, hustota přes k -tého souseda. **Hypervolume** = objem dominovaný frontou vůči referenčnímu bodu — jediná běžná metrika monotónní vůči dominanci a nepotřebující znát skutečnou frontu; dále GD, IGD, spread, ϵ -indikátor.