

Přírodou inspirované počítání

Shrnutí okruhu ke státní závěrečné zkoušce — jedna otázka na jednu stranu

SZZ Umělá inteligence, zaměření Inteligentní agenti, MFF UK · srpen 2026

Oficiální znění okruhu (zdroj pravdy, 2025/2026):

<https://www.mff.cuni.cz/cs/studenti/bc-a-mgr-studium/studijni-plany/2025-2026/informatika/mgr/umela-inteligence>

Šest vět oficiálního znění okruhu, šest stran tohoto textu. Podrobný výklad je v 02-prirodou-inspirovane-pocitani.pdf, anglicky v ENG/02-nature-inspired-computing.pdf.

1. Genetické algoritmy, genetické a evoluční programování. str. 2
2. Teorie schémat, pravděpodobnostní modely jednoduchého genetického algoritmu. str. 3
3. Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce. str. 4
4. Rojové optimalizační algoritmy. str. 5
5. Memetické algoritmy, hill climbing, simulované žíhání. str. 6
6. Aplikace evolučních algoritmů (evoluce expertních systémů, neuroevoluce, řešení kombinatorických úloh, vícekritériální optimalizace). str. 7

Souhrnná srovnávací tabulka — kostra každé odpovědi

alg.	reprezentace	variace	selekce	co si zapamatovat
SGA	binární řetězec	1-bod. křížení, bit-flip	ruleta, generační	teorie schémat, BBH
ES	$\mathbb{R}^n + \sigma$	gaussovská mutace, rekombinace	náhodní rodiče, $(\mu, \lambda)/(\mu + \lambda)$	pravidlo 1/5, samoadaptace
CMA-ES	$\mathbb{R}^n$, model $\mathcal{N}(\vec{m}, \sigma^2 \mathbf{C})$	vzorkování z rozdělení	pořadová, μ nejlepších	evoluční cesty, rank-1/rank- μ
DE	$\mathbb{R}^n$	$\vec{x}_a + F(\vec{x}_b - \vec{x}_c)$, binom. křížení	souboj rodič-potomek	měřítka kroku z populace
EP	doménová (automat)	jen mutace	turnaj rodiče + potomci	genotyp = fenotyp
GP	syntaktický strom	výměna podstromů, mutace	turnaj	bloat, ADF
PSO	$\mathbb{R}^n$ + rychlost	pohybové rovnice	žádná (jen paměť)	w, c_1, c_2 , gbest/lbest
ACO	konstrukce cesty	feromon + heuristika	implicitní	$\tau^\alpha \eta^\beta$, odpařování
SA	jedno řešení	soused	Metropolis	rozvrh chlazení
MA	libovolná	EA operátory + lokální hledání	libovolná	Lamarck vs. Baldwin
NSGA-II	libovolná	SBX + polynom. mutace	fronty + crowding	elitismus, crowding distance
NEAT	seznam hran	mutace struktury, křížení dle ID	sdílená fitness v druhu	inovační čísla, speciace

Průřezová témata — ptají se napříč otázkami

- **Explorace vs. exploatace** a kde ji každý algoritmus řídí: GA (křížení vs. selekční tlak), ES (σ , pravidlo 1/5), SA (teplota), PSO (w , topologie), ACO (q_0 , odpařování), tabu (tabu list), novelty search (jen explorace).
- **Udržení diversity**: fitness sharing, crowding, speciace, ostrovní model, nenáhodné páření, restart, hypermutace.
- **Adaptace parametrů**: ladění vs. řízení; pevné / adaptivní / samoadaptivní.
- **Práce s omezeními**: penalizace, oprava, dekodér, uzavřené operátory, vícekritériální formulace.
- **Lamarckismus vs. baldwinismus**: memetické algoritmy, oprava jedinců, neuroevoluce s doučováním vah.
- **Teorie**: věta o schématech a její kritika, Voseho model, Markovovy řetězce a konvergence elitistického GA, No Free Lunch, konvergence SA.

Co se chce spočítat u tabule

- Ruletová selekce pro danou populaci; jeden krok DE s čísly.
- PMX a OX na devítiprvkovém příkladu; inverze (2-opt) na permutaci.
- Věta o schématech: $o(S)$, $d(S)$, celé odvození nerovnosti.
- Crowding distance v NSGA-II; dominance a Pareto fronta z tabulky kritérií.
- Metropolisovo kritérium pro konkrétní Δ a T ; samoadaptace σ .

Nejčastější chyby

- Zaměnit *adaptivní* (pravidlo 1/5) a *samoadaptivní* (σ v genomu) řízení.
- U samoadaptace mutovat x dřív než σ — je to naopak.
- Tvrdit, že věta o schématech dokazuje konvergenci GA (je to nerovnost na *jeden* krok).
- Zaměnit (μ, λ) a $(\mu + \lambda)$, resp. jejich elitismus.
- Považovat No Free Lunch za argument proti EA (je to argument pro doménovou specializaci).

Otázka 1. Genetické algoritmy, genetické a evoluční programování

Obecné schéma EA

Populační stochastické prohledávání; cyklus *inicializace* → *ohodnocení* → *rodičovská selekce* → *rekombinace* → *mutace* → *ohodnocení* → *environmentální selekce*. **Variace** (křížení, mutace) tvoří diverzitu, **selekce** ji odebírá a směřuje hledání; návrh EA = hledání rovnováhy **explorace/exploatace**. **No Free Lunch**: neexistuje univerzálně nejlepší algoritmus ⇒ smysl má doménová specializace reprezentace a operátorů.

Selekce

Ruleta ($p_i = f_i / \sum_j f_j$; vysoký rozptyl, citlivá na škálování fitness), **SUS** (stejně střední hodnoty, nízký rozptyl), **turnaj** (tlak řídí velikost k , invariantní k *monotónním* transformacím fitness, nepotřebuje explicitní fitness — stačí porovnání), **pořadová** (konstantní tlak), **Boltzmannova** (tlak roste s časem). **Elitismus** zaručuje monotónii nejlepší fitness. **Generační** vs. **steady-state** model se liší podílem nahrazované populace. **Škálování fitness** (lineární, sigma truncation, mocninné, pořadové, Boltzmannovo) opravuje slabiny fitness-proporcionální selekce: dominanci „supermanů“ na začátku a ztrátu tlaku na konci běhu.

SGA a binární kódování

SGA = binární řetězce + ruleta + 1-bodové křížení + bit-flip mutace + generační náhrada; parametry n , $p_C \approx 0,7$, $p_M \approx 1/m$. Reálná čísla binárně: $x = a + z(b - a)/(2^k - 1)$; **Hammingovy útesy** řeší **Grayův kód**. Křížení: **1-bodové** (rozbije schéma s pravděpodobností $d(S)/(m - 1)$), **2-bodové** (bez okrajového biasu), **uniformní** (nejvíce disruptivní, bez pozičního biasu). Mutace je v GA *sekundární* — brání nevratné ztrátě alel; **inverze** je historický operátor pro evoluci uspořádání genů.

Reprezentace a operátory

Reprezentace + *operátory* = *fitness krajina*. Nominální atributy: jen

nezaujaté mutace; ordinální: i zaujaté (*creep*). **Reálná**: gaussovská mutace $x' = x + \sigma N(0, 1)$; aritmetické křížení $\alpha \vec{x} + (1 - \alpha) \vec{y}$ *zmenšuje rozptyl* populace, proto BLX- α a SBX. **Permutace**: PMX (pozice + mapování), OX (relativní pořadí), CX (absolutní pozice pomocí cyklů), ER (hrany — nejlepší pro TSP); mutace swap, insert, inverze (2-opt), scramble. *Umět předvést PMX a OX na devítiprvkovém příkladu.*

Stromové GP (Koza)

Terminály + neterminály, požadavky **uzavřenosti** a **dostatečnosti**; inicializace *grow* / *full* / *ramped half-and-half*; křížení = výměna podstromů (neterminály volit s vyšší pravděpodobností), víc typů mutací včetně mutace konstant; fitness = spuštění programu. **Bloat** = růst velikosti bez zlepšení fitness (*introny*); tři vysvětlení — *replication accuracy*, *removal bias*, *crossover bias*. Obrana: limity velikosti, penalizace (*parsimony pressure*), anti-bloat operátory (hoist, shrink, size-fair), vícekritériální přístup. **ADF** = evolvované podprogramy (modularita), operátory pracují na větvích odděleně; typované a gramatické GP omezují prostor na smysluplné programy.

Variety GP a gramatická evoluce

Lineární GP (byte kód, Tierra), grafové GP, **Cartesian GP** (lineární genotyp → 2D DAG, bodová mutace, (1 + 4)-ES), vývojové GP (strom staví graf — obvody, sítě). **Gramatická evoluce**: lineární genom celých čísel, pravidlo gramatiky se vybírá *modulem*, derivační strom → fenotyp; robustní kódování a standardní operátory GA, ale nelokální mapování genotyp-fenotyp.

Evoluční programování a poučení

EP: konečné automaty, *genotyp* = *fenotyp*, jen mutace, turnajová selekce z rodičů i potomků; příklad predikce prvočísel (degenerace fitness). Historické větve **GA** / **ES** / **EP** / **GP** a jejich charakteristické volby umět vyjmenovat. **Headless chicken experiment**: test, zda křížení skutečně kombinuje stavební bloky, nebo je jen makromutací.

Otázka 2. Teorie schémat, pravděpodobnostní modely jednoduchého genetického algoritmu

Schéma

Slovo nad $\{0, 1, *\}$. **Řád** $o(S)$ = počet pevných pozic; **definující délka** $d(S)$ = vzdálenost první a poslední pevné pozice; $F(S)$ = průměrná fitness reprezentantů v dané populaci (tedy veličina závislá na populaci, ne na úloze). Celkem existuje 3^m schémat, jeden jedinec je reprezentantem 2^m z nich.

Věta o schématech (TST)

$$\mathbb{E}[C(S, t+1)] \geq C(S, t) \frac{F(S)}{\bar{f}} \left[1 - p_C \frac{d(S)}{m-1} - p_M o(S) \right]$$

Odvození ve třech krocích: *selekce* $\rightarrow$ faktor $F(S)/\bar{f}$ (nadprůměrná schémata rostou exponenciálně), *křížení* $\rightarrow$ schéma se rozbije s pravděpodobností nejvýš $d(S)/(m-1)$, *mutace* $\rightarrow$ přežije s pravděpodobností $(1 - p_M)^{o(S)} \approx 1 - p_M o(S)$.

BBH a implicitní paralelismus

Hypotéza stavebních bloků: GA skládá krátká, nízkého řádu a nadprůměrná schémata. Důsledky: záleží na *kódování* (příbuzné geny blízko sebe), na velikosti populace, škodí předčasná konvergence. **Implicitní paralelismus:** populace zpracovává $\sim n^3$ užitečných schémat; analogie s *k-rukým banditou* — exponenciální alokace pokusů dosud lepší variantě.

Kritika teorie schémat

Nerovnost platí jen na *jeden* krok (nelze iterovat, $F(S)$ i $\bar{f}$ se mění); je to tvrzení o *střední hodnotě* — v konečné a malé populaci způsobují výběrové chyby odchylky (drift); **deceptivní úlohy** (stavební bloky vedou pryč od optima); **kolaterální konvergence**; velký rozptyl fitness uvnitř schématu; ignoruje *konstruktivní* efekty křížení a mutace (jen destruktivní); schémata nejsou nezávislá.

Voseho model (nekonečná populace)

Řetězce ztotožníme s čísly $0..2^l - 1$. Populaci popisuje vektor relativních četností $p(t)$ v simplexu, vektor *selektivních pravděpodobností* $s(t)$. Hledáme $\mathcal{G} = \mathcal{M} \circ \mathcal{F}$ s $p(t+1) = \mathcal{G}(p(t))$:

- $\mathcal{F}$ (selekce) je dána diagonální maticí fitness, $s = \mathbf{F}p / \sum_j \mathbf{F}_{jj}p_j$;
- $\mathcal{M}$ (křížení + mutace) je kvadratický operátor $\mathbb{E}[p'_k] = \sum_{i,j} s_i s_j r(i, j, k)$; díky symetrii $r(i, j, k) = r(i \oplus k, j \oplus k, 0)$ stačí *jediná* míchací matice.

Pevné body: $\mathcal{F}$ — populace kopií nejlepšího jedince; $\mathcal{M}$ — rovnoměrné rozdělení. Jejich kombinace vysvětluje *přerušované rovnováhy*; pevné body celého $\mathcal{G}$ známy nejsou.

Konečné populace: Markovův řetězec

Stavy = možné populace, jejich počet $N = \binom{n+2^l-1}{2^l-1}$; přechodová matice $\mathbf{Q}$ je *exaktní*, ale astronomicky velká. Při $p_M > 0$ je řetězec **ireducibilní** (z každé populace lze dosáhnout každé); **elitistický GA konverguje k optimu s pravděpodobností 1**. Shrnutí: nekonečné populace = deterministický model (exaktní, nepraktický), konečné = stochastický (realistický, nezvládnutelný); limitní přechod je spojuje.

EDA — praktický důsledek

Algoritmy odhadu rozdělení berou pohled „GA = transformace rozdělení“ doslova: místo operátorů se *učí model* p_θ a z něj vzorkují. Cyklus: *vzorkuj* $\rightarrow$ *vyber lepší* $\rightarrow$ *přeuč model*. **UMDA** — nezávislé marginály přepočítané z vybrané podpopulace, **PBIL** — inkrementálně $p_i \leftarrow (1 - \alpha)p_i + \alpha x_i^{\text{best}}$, **MIMIC/BMDA** — párové závislosti, **BOA** — Bayesovská síť, **CMA-ES** — gaussovské rozdělení (viz otázka 3).

Otázka 3. Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce

Evoluční strategie

Reálné vektory, *mutace je hlavní operátor*, rodičovská selekce *náhodná*, environmentální selekce *deterministická*; jedinec = $[\vec{x}, \vec{\sigma}]$. (μ, λ) vs. $(\mu + \lambda)$: umět vyjmenovat rozdíly v elitismu, konvergenci, schopnosti opustit lokální optimum a v samoadaptaci (čárková varianta zapomíná, a proto samoadaptace funguje lépe). **(1 + 1)-ES a pravidlo 1/5**: podíl úspěšných mutací $p > 1/5 \Rightarrow$ zvětší σ , $p < 1/5 \Rightarrow$ zmenší — jde o *adaptivní*, nikoli samoadaptivní řízení. **Samoadaptace**: $\sigma' = \sigma \exp(\tau' N(0, 1) + \tau N_i(0, 1))$, poté $x' = x + \sigma' N(0, 1)$ — *nejdříve* σ , pak x , aby se nový krok hned otestoval. Počet strategických parametrů: 1 (izotropní), n (nekorelované), $n(n + 1)/2$ (korelované, s úhly natočení). **Rekombinace**: lokální ($\rho = 2$) / globální ($\rho = \mu$), diskrétní (dominantní) / intermediární (aritmická).

CMA-ES

Stav $\theta = (\vec{m}, \sigma, \mathbf{C}, \vec{p}_\sigma, \vec{p}_c)$, vzorkování $\mathcal{N}(\vec{m}, \sigma^2 \mathbf{C})$; **evoluční cesty** akumulují směr posunů, **rank-1** update (podle cesty) a **rank- μ** update (podle vybraných jedinců), délka $\vec{p}_\sigma$ řídí velikost kroku. Invariantní vůči monotónním transformacím fitness a lineárním transformacím prostoru; de facto standard pro spojitou black-box optimalizaci.

Diferenciální evoluce

DE/rand/1/bin: dárce $\vec{v} = \vec{x}_a + F(\vec{x}_b - \vec{x}_c)$; *binomické* křížení s pravěhem C a pojistkou $j = I_{\text{rand}}$ (alespoň jedna složka od dárce); souboj potomka s *vlastním rodičem* — nahrazení jen při zlepšení. Parametry: $F \in [0, 2]$ (typicky 0,5–0,9), $C \in [0, 1]$, $N \approx 10D$. **Geometrická podstata**: měřítko i orientace kroků se přebírají z aktuálního rozptylu populace $\Rightarrow$ automatická adaptace bez strategických parametrů. Varianty: rand/1, rand/2, best/1, best/2, current-to-best; **bin** vs. **exp** křížení. *Umět předvést krok s čísly: mutace $\rightarrow$ křížení $\rightarrow$ selekce.*

Koevoluce

= kontextová fitness (hodnotí se *proti ostatním*) + dynamická krajina. **Kompetitivní**: predátor–kořist, host–parazit, Hillisovy řadičské sítě. **Kooperativní**: dekompozice na komponenty, CCGA, moduly + blueprints. **Patologie**: cyklení (intranzitivita), odpojení (jedna populace uteče), efekt *Červené královny* (všichni se zlepšují, ale *relativní* fitness zůstává konstantní — z naměřených hodnot nepoznáme, zda je pokrok skutečný; lék je měření proti pevné externí sadě), průměrné stabilní stavy, přespecializace, zapomínání. **Léky**: archivy (*hall of fame*), sdílená fitness, měření proti pevné sadě protivníků. **Věžňovo dilema**: $T > R > P > S$ a $2R > T + S$; D dominantní, DD je Nashovo ekvilibrium a jediné Pareto-neoptimální pole; iterovaná verze $\Rightarrow$ TFT a čtyři vlastnosti úspěšné strategie (slušnost, dráždivost, odpouštění, nezávislost) + srozumitelnost jako pátá; Pavlov v zašuměném prostředí.

Diverzita a dynamické krajiny

Diverzita: fitness sharing, crowding, speciace, ostrovní model, nenáhodné páření. Dynamická fitness: diploidie, hypermutace, náhodná migrace, udržování diverzity, (μ, λ) -ES (zapomínání je zde výhodou).

Otevřená evoluce

Evoluce *bez pevného cíle*. Znaky: trvalá novost, neomezený růst složitosti, vznik nových tříd entit, evoluce evolvability. Systémy Tierra, Avida, Polyworld, ECHO — všechny se dříve či později *zaseknou*. **Generativní (nepřímé) reprezentace**: L-systémy, celulární automaty, buněčné kódování, CPPN. **Novelty search** měří řídkost $\rho(x)$ v prostoru *chování* vůči populaci a permanentnímu archivu, účelovou funkci vůbec nepoužívá — u deceptivních úloh se vyplatí zahodit cíl; navazuje *quality-diversity* a **MAP-Elites** (mřížka deskriptorů chování). **Interaktivní evoluce**: fitness = člověk (Biomorphs, Picbreeder, EndlessForms); omezením je malá populace a únava uživatele.

Otázka 4. Rojové optimalizační algoritmy

Východiska rojové inteligence

Mnoho jednoduchých agentů bez centrálního řízení, lokální interakce a úprava prostředí dávají globálně rozumné chování. Klíčová slova: **stigmergie** (komunikace přes prostředí), **emergence**, **decentralizace**, **kladná zpětná vazba** + **odpařování** jako negativní zpětná vazba, vhodnost pro *dynamická* prostředí.

PSO — rovnice

$$\vec{v} \leftarrow w\vec{v} + c_1 r_1 (\vec{p} - \vec{x}) + c_2 r_2 (\vec{g} - \vec{x}), \quad \vec{x} \leftarrow \vec{x} + \vec{v}$$

w = **setrvačnost** (klesá $0,9 \rightarrow 0,4$: nejdřív explorační, pak exploatační), $c_1(\vec{p} - \vec{x})$ = **kognitivní** složka (osobní nejlepší pozice), $c_2(\vec{g} - \vec{x})$ = **sociální** složka (nejlepší v okolí), typicky $c_1 = c_2 = 2$. Divergenci brání omezení $v_{\max}$ nebo **constriction** $\chi \approx 0,729$. **Topologie**: *gbest* (úplný graf — rychlá konvergence, riziko uvíznutí) vs. *lbest* (kruh, mřížka — pomalejší šíření, lepší explorační).

PSO vs. GA

Žádné operátory křížení ani mutace; částice mají *paměť* ($\vec{p}_i, \vec{g}$); informace teče *jednosměrně* od lepších k horším; populace se nenahrazuje, jen se hýbe.

ACO — rovnice

Pravděpodobnost přechodu $p_{ij} \propto \tau_{ij}^\alpha \eta_{ij}^\beta$, kde τ = feromon (naučená zkušenost), $\eta = 1/d_{ij}$ = heuristika (viditelnost); α, β váží zkušenost

proti heuristice. Aktualizace feromonu $\tau \leftarrow (1 - \rho)\tau + \sum_k Q/L_k$ — *odpařování* + uložení úměrné kvalitě řešení (kratší cesta $\Rightarrow$ víc feromonu). Řešení se *konstruuje* po krocích, nikoli vylepšuje.

Variety ACO

AS (původní: aktualizují všichni mravenci), **ACS** (globální update jen nejlepším, navíc *lokální* update při průchodu hranou, který feromon *snižuje* (aby ostatní mravenci zkoušeli jiné cesty), pseudonáhodné pravidlo s parametrem q_0 pro přímé využití nejlepší hrany), **MAX-MIN** (meze feromonu $\tau_{\min}, \tau_{\max}$ proti předčasné konvergenci). **Akce démona** = centralizovaný krok, typicky lokální prohledávání nad zkonstruovanými řešeními.

Další rojové algoritmy

ABC (*artificial bee colony*): *dělnice* u zdrojů, *pozorovatelky* vybírají zdroj ruletou podle kvality, *průzkumnice* po vyčerpání limitu neúspěšných pokusů zdroj opustí a restartují jej náhodně. **Firefly**: přitažlivost klesá exponenciálně se vzdáleností, takže se roj samovolně dělí na podskupiny okolo lokálních optim (vhodné pro multimodální úlohy).

Kdy který

Spojité úlohy bez struktury $\rightarrow$ PSO nebo CMA-ES; konstrukce cesty či permutace s heuristikou $\rightarrow$ ACO; dynamické prostředí (změna hran, poruchy) $\rightarrow$ ACO díky odpařování; multimodální krajina $\rightarrow$ firefly, *lbest* PSO.

Otázka 5. Memetické algoritmy, hill climbing, simulované žíhání

Hill climbing

Prohledávání okolí jednoho řešení: **steepest ascent** (nejlepší soused), **first improvement** (první lepší — levnější), **stochastic** (soused podle pravděpodobnosti úměrné zlepšení), **s náhodnými restarty**. Problémy: *lokální optima*, *plošiny* (žádný gradient), *hřebeny* (zlepšení jen kombinací kroků).

Simulované žíhání

Metropolisovo kritérium: horší soused se přijme s pravděpodobností $P = \min(1, e^{-\Delta/T})$ — při vysoké teplotě téměř náhodná chůze, při nízké téměř hill climbing. **Rozvrh chlazení**: geometrický $T \leftarrow \alpha T$ (v praxi), logaritmický $T_k \propto 1/\log k$ (nutný pro důkaz konvergence, prakticky nepoužitelný). Pro *pevné* T konverguje rozdělení stavů k Boltzmannovu $\propto e^{-f/T}$.

Tabu search

Vždy se přejde do *nejlepšího nezakázaného* souseda, i když je horší než aktuální řešení. **Tabu list** zakazuje nedávné *tahy* (ne stavy) po dobu **tenure**; **aspirační kritérium** zákaz zruší, pokud tah vede k novému nejlepšímu řešení. **Střednědobá** paměť (intenzifikace nad elitními řešeními) a **dlouhodobá** frekvenční paměť (diverzifikace — penalizace často použitých komponent).

Scatter search

Referenční množina vybíraná podle *kvality i diverzity*, nová řešení vznikají *aritmetickými kombinacemi* podmnožin a následným vylepšením (lokální prohledávání); deterministické tam, kde EA používá náhodu.

Memetické algoritmy

= EA + lokální prohledávání aplikované na jedince (populace hledá globálně, lokální hledání doladuje). Dvě varianty:

- **lamarckismus** — vylepšený jedinec *přepíše genotyp*; rychlejší konvergence, ale rychlejší ztráta diverzity;
- **baldwinismus** — vylepšení se projeví *jen ve fitness*, genotyp zůstane; pomalejší, zachovává diverzitu a vyhlazuje krajinu.

Rozhodnutí návrhu: na koho lokální hledání pustit (všichni / nejlepší / náhodně), jak dlouho a jak silně. **Memetic computing**: memy jako součást genomu nebo jako koevolující populace strategií.

Ladění vs. řízení parametrů

Ladění (*tuning*) — parametry se hledají *před* během (grid search, iterované závody, meta-EA). **Řízení** (*control*) — mění se *za* běhu:

- **pevné** (deterministické podle času, např. T v SA, w v PSO),
- **adaptivní** (podle zpětné vazby z běhu — pravidlo 1/5),
- **samoadaptivní** (parametr je součástí genomu a evoluuje — σ v ES).

Souvislosti

SA, tabu a HC jsou *jednoduché* metody, které EA doplňují jako lokální krok (memetické algoritmy, akce démona v ACS, 2-opt v TSP, WalkSAT v SAT). Hybridizace s lokální heuristikou je u kombinatorických úloh téměř vždy výhodná (otázka 6).

Otázka 6. Aplikace evolučních algoritmů (evoluce expertních systémů, neuroevoluce, řešení kombinatorických úloh, vícekritériální optimalizace)

LCS: dva přístupy

Michigan: jedinec = *jedno pravidlo*, řešením je celá populace $\Rightarrow$ nutné rozdělení odměny (*credit assignment*). **Pittsburgh:** jedinec = *celá sada pravidel*, fitness přímočará, ale operátory složité (GIL). **Hollandův LCS:** podmínky nad $\{0, 1, *\}$, vnitřní zprávy a receptory, **bucket brigade** (pravidlo platí předchůdci za právo jednat). **ZCS:** bez zpráv; *match set* $M \rightarrow$ ruletový výběr akce $\rightarrow$ *action set* A ; posílení A a A_{-1} , daň pro $M \setminus A$; *cover* operátor při prázdném M . **XCS:** klasifikátor (c, a, p, ϵ, F) , *fitness podle přesnosti predikce* $\kappa = \alpha(\epsilon/\epsilon_0)^{-\nu}$ (pro $\epsilon \leq \epsilon_0$ je $\kappa = 1$; fitness je *relativní přesnost* v action setu), aktualizace Q-learningem, *nikový* GA v action setu; evoluje *úplnou a minimální* mapu vstup–výstup. Varianty UCS (s učitelem), XCSF (aproximace funkcí). *Umět vysvětlit, proč přesnost jako fitness řeší nedostatky „strength-based“ systémů* (silná, ale nepřesná pravidla přestanou vyhrávat).

Neuroevoluce

Co se evoluje: váhy / topologie / obojí / hyperparametry učení. Výhody EA: bez gradientu, zvládá rekurentní sítě a RL, snadná paralelizace. **Problém konkurujících konvencí** (permutační problém): dvě funkčně stejné sítě mají různé genomy $\Rightarrow$ křížení je bez opatření destruktivní. **Kódování architektury:** přímé (matice), gramatické (Kitano), buněčné (Gruau — GP program řídí růst sítě); **GNARL** = EP nad grafy, strukturální i parametrické mutace řízené „teplotou“. **NEAT:** seznam hran s *inovačními čísly* (křížení jen shodných genů), *speciace* podle podobnosti genomů se sdílenou fitness (chrání nové topologie), *complexification* od minimální sítě. **HyperNEAT:** neurony leží v geometrickém *substrátu* a váhu spoje generuje z jejich souřadnic funkce $\mathbb{R}^4 \rightarrow \mathbb{R}$ reprezentovaná **CPPN** (DAG s různými aktivními funkcemi) evolvovanou pomocí NEAT — zachytí symetrie a regularity. **NAS:** prostor (lineární / DAG buněk / super síť), strategie (EA, RL, bayesovská, gradientní), odhad výkonu (sdílení vah — ENAS); DeepNEAT a CoDeepNEAT (moduly + blueprints); ES pro deep RL.

Kombinatorické úlohy

Batoch: bitová mapa, triviální operátory, problém je *omezení kapacity* — čtyři strategie: **penalizace** (volba váhy α), **oprava** (lamarckovsky nebo baldwinovsky), **dekodér** („přidej, pokud se vejde“ — každý genotyp je přípustný), **vícekritériální** formulace. **TSP:** fitness triviální, rozhoduje kódování. Sousednostní a ordinální reprezentaci nepoužívat; permutační + PMX/OX/CX/ER, případně maticová. Inicializace nejbližším sousedem či vkládáním hran; mutace inverze (2-opt). **SAT:** fitness = počet splněných klauzulí (samotné f nestačí — plošiny), vážení klauzulí, zjemňující funkce; reprezentace bitová, reálná, klauzulová, cestová; WalkSAT jako lokální heuristika. U reálné reprezentace ($x \mapsto (1-y)^2$, $\neg x \mapsto (1+y)^2$, minimalizace) pozor: hodnoty jsou *penalty*, takže disjunkce (klauzule) je **součin** a konjunkce (formule) **součet**. **Rozvrhování:** přímé maticové kódování; *tvrdá* omezení řešit v operátorech, *měkká* ve fitness; job shop — permutace s dekodérem vs. přímé kódování. Obecné pravidlo: rozhoduje kódování a operátory respektující strukturu úlohy + hybridizace s lokální heuristikou.

Vícekritériální optimalizace

Dominance $x \prec y$: ve všech kritériích ne horší a alespoň v jednom lepší; **Pareto množina** (v prostoru řešení) a **Pareto fronta** (v prostoru kritérií). Dvojitý cíl: *konvergence* k frontě + *diverzita* po ní. **Skalarizace:** lineární (jednoduchá, nenajde nekonvexní části fronty), ϵ -constraint, Čebyševova. **NSGA-II:** nedominované třídění do front, *crowding distance* $d_i = \sum_m (f_m(i+1) - f_m(i-1)) / (f_m^{\max} - f_m^{\min})$, krajní body ∞ ; *crowded comparison* (nižší fronta, při shodě větší crowding); elitismus spojením $P_t \cup Q_t$. *Umět spočítat crowding distance na příkladu*. Dále **SPEA2** (archív, síla dominujících, hustota přes k -tého nejbližšího souseda), **MOEA/D** (Čebyševova skalarizace, váhové vektory, sousedství), **SMS-EMOA** (příspěvek k hypervolume), **NSGA-III** (referenční body pro *many-objective*). **Hypervolume:** objem dominovaný frontou vůči referenčnímu bodu — jediná běžná metrika monotónní vůči dominanci a bez znalosti skutečné fronty; dále GD, IGD, spread, ϵ -indikátor.