

Dobývání znalostí

Shrnutí okruhu ke státní závěrečné zkoušce — jedna otázka na jednu stranu

SZZ Umělá inteligence, MFF UK · srpen 2026

Oficiální znění okruhu (zdroj pravdy, 2025/2026):

<https://www.mff.cuni.cz/cs/studenti/bc-a-mgr-studium/studijni-plany/2025-2026/informatika/mgr/umela-inteligence>

Oficiální znění okruhu má sedm vět a tento text jim věnuje sedm stran, na každou otázku jednu. Podrobný výklad je v 03-dobyvani-znalosti.pdf, anglicky v ENG/03-data-mining.pdf.

- | | |
|--|--------|
| 1. Základní paradigmaty dobývání znalostí. | str. 2 |
| 2. Příprava dat; výběr atributů a metody pro analýzu jejich relevance. | str. 3 |
| 3. Metody pro dobývání znalostí; asociační pravidla, přístupy založené na principu učení s učitelem a klastrová analýza. | str. 4 |
| 4. Metody pro extrakci charakteristických diskriminačních pravidel a měření jejich zajímavosti. | str. 5 |
| 5. Reprezentace, vyhodnocování a vizualizace získaných znalostí. | str. 6 |
| 6. Modely pro analýzu sociálních sítí; míry centrality, detekce komunit. | str. 7 |
| 7. Praktické využití technik pro dobývání znalostí a analýzu sociálních sítí. | str. 8 |

Průřezová témata — ptají se napříč otázkami

- **Přesnost proti srozumitelnosti.** Stromy a pravidla si člověk přečte, SVM a neuronové sítě klasifikují přesněji, ale nevysvětlí proč. Které kritérium vyhraje, rozhoduje typ úlohy, tedy zda jde o klasifikaci, popis, nebo hledání nugetů.
- **Nevyvážená data.** Accuracy tu zavádí, a proto se hodnotí přesností a úplností, mírou F_1 , křivkami ROC a lift a plochou AUC. S nerovnováhou se dá zatočit už při přípravě dat, a to vahami chyb nebo různými pravděpodobnostmi výběru.
- **Škály atributů.** Nominální, ordinální, intervalová a poměrová škála určují, které operace jsou přípustné, jakou metriku zvolit i kterou metodu vůbec nasadit. Je to nejčastější „proč“ u doplňujících otázek.
- **Transformace proti selekci atributů.** PCA vyrobí nové atributy, takže se ztrácí interpretace a je nutné znát všechny původní. Filtry a wrappery vyberou podmnožinu původních atributů a interpretace zůstane zachována.
- **Složitost.** AOI běží v $O(na)$, indukce stromu v $O(np \log p)$, PAM v $O(kn^2d)$, Girvanové–Newman v $O(m^2n)$ a Louvain v $O(n \log n)$. NP-těžké je hledání klik, vyvážený řez s vahami a maximalizace vlivu; tu hladový postup vyřeší na 63 % optima.
- **Proces, ne algoritmus.** CRISP-DM běží v cyklu, příprava dat spotřebuje 60–80 % času a nasazením práce nekončí: přijde drift, soukromí a spravedlnost.

Co se chce spočítat u tabule

- **Support, confidence a lift** z malé tabulky transakcí a k tomu jeden krok Apriori, tedy spojení a prořezání.
- **Entropii a informační zisk** pro volbu atributu; v příkladu s úvěrem vyjde příjem 0,5747; konto 0,6667; pohlaví 0,9183 a nezaměstnaný 0,825. Vedle toho Gini index.
- **Naivního Bayese** na malé tabulce (0,1042 proti 0,0416).
- χ^2 na čtyřpolní tabulce ($42,857 > 3,84$) se stupni volnosti $(R-1)(S-1)$.
- **Kvartily a IQR**, mez odlehlosti $\pm 1,5$ IQR a box plot.
- **t-weight a d-weight** z tabulky generalizovaných záznamů.
- **Matici záměn** a z ní p , r a F_1 ; dále konstrukci **ROC** ze žebříčku a úvahu o AUC.
- **Centrality** na malém grafu, tedy stupňovou, mezilehlou, blízkostní a vlastní; k tomu **klastrovací koeficient** a **modularitu** Q .
- **Test homofilie** (5 z 18 proti $2pq = 8$) a test korelace (14 % proti 49 %).
- **PageRank** jednou iterací a **HITS** s normalizací.

Nejčastější chyby

- Tvrdit, že vysoká t-weight znamená i vysokou d-weight. Typičnost není totéž co rozlišovací síla.
- Zapomenout, že u **MS-Apriori** *neplatí* uzavřenost dolů.
- Míchat trénovací a testovací data, případně ladit parametry na testovací množině. Na ladění je *validační* množina.
- Zaměnit **bagging**, který snižuje rozptyl a běží paralelně, s **boostingem**, který snižuje zkreslení, běží sekvenčně a je citlivý na šum.
- Tvrdit u PageRanku, že potřebuje normalizaci. Nepotřebuje ji, na rozdíl od HITS.

Otázka 1. Základní paradigmata dobývání znalostí

Co je KDD

Dobývání znalostí z databází (*knowledge discovery in databases*) je netriviální proces, který z dat získává informace *implicitní*, dosud *neznámé* a *potenciálně užitečné*. Je **interaktivní**, protože o dalším kroku rozhoduje uživatel, a **iterativní**, protože se jeho fáze opakují. Pojem *data mining* označuje v úzkém smyslu jen jednu fázi tohoto procesu, v běžné mluvě celý proces.

Pět fází KDD

Proces má pět fází: *výběr dat* → *předzpracování* → *transformace* → *dobývání (data mining)* → *interpretace a vyhodnocení*. První tři z nich tvoří dohromady přípravu dat a spotřebují **60–80 % času** celého projektu. To je nejčastěji ověřovaný fakt.

Kořeny oboru

Obor vyrostl ze tří kořenů. Z umělé inteligence si bere strojové učení, z **databází** práci s velkými objemy a dotazování a ze **statistiky** inferenci a testování; všechny tři spojuje potřeba *podpory rozhodování*. Od **OLAP** se KDD liší tím, na co odpovídá: OLAP zpracuje *předem položenou* otázku agregacemi, kostkami a drill-downem, kdežto KDD hledá vzory, *o nichž předem nevíme*. Od klasické statistiky se liší vstupem i cílem, protože pracuje s daty, která nebyla sbírána k tomuto účelu, a hypotézy hledá, nejen testuje.

Tři typy úloh

- U **klasifikace** a **predikce** rozhoduje *přesnost* a srozumitelnost je bonus.
- U **popisu** (deskripce) rozhoduje *srozumitelnost* a *plné pokrytí* dat.
- U **hledání nugetů** rozhoduje *překvapivost*. Nuget nemusí pokrývat téměř nic, stačí, že je zajímavý a akceschopný.

Dělení úloh a metod

Deskriptivní úlohy data popisují (asociační pravidla, klastrování, sumarizace), **prediktivní** odhadují neznámou hodnotu (klasifikace, regrese). Podle toho, co o datech víme, se učí **s učitelem**, jsou-li známy cílové hodnoty, **bez učitele**, máme-li jen strukturu dat, nebo **poloučeně**, tedy z mála označovaných a mnoha neoznačovaných dat.

Škály atributů

Nominální škála dovoluje jen rovnost (barva), **ordinální** navíc uspořádání (známka), **intervalová** rozdíly, ale ne poměry (teplota ve °C), a **poměrová** i poměry, protože má absolutní nulu (příjem). Škála určuje *přípustné operace* — průměr nominálního atributu spočítat nelze — a s nimi volbu metriky i metody. Typicky se nominální atribut převede na *v* binárních atributů a poměrový atribut s exponenciálním chováním se zlogaritmuje.

Metodologie

SEMMA (SAS) má fáze *Sample, Explore, Modify, Model, Assess*. **CRISP-DM** jich má šest: porozumění problému → porozumění datům → příprava dat → modelování → vyhodnocení → nasazení. Jejich pořadí *není striktní* a proces je *cyklický*. **ASUM-DM** (IBM) doplňuje CRISP-DM o projektové řízení a provoz.

Nejčastější doplňující otázka

Proč pořadí fází CRISP-DM není striktní? Protože výsledky každé fáze určují další kroky: zjištěná kvalita dat vede zpět k přeformulování cíle a výsledek modelování zpět k jiné přípravě dat. Proces je smyčka s návraty, ne lineární postup.

Otázka 2. Příprava dat; výběr atributů a metody pro analýzu jejich relevance

Cíl přípravy dat

Cílem je vybrat relevantní data a reprezentovat je tak, aby je zvolený algoritmus zvládl. Výsledkem je *jedna* tabulka *objekty* $\times$ *atributy*, ke které se dojde denormalizací a agregací přes vztahy 1:N.

Chybějící hodnoty

Nabízejí se čtyři cesty. Objekt lze *ignorovat*, čímž ovšem přijdeme o data a riskujeme zkreslení. Lze zavést *novou hodnotu* „nevím“. Lze *doplnit existující hodnotu*, a to modelem, poměrně podle rozdělení, nebo libovolně. A konečně lze hodnotu *doplnit modelem* (regrese, k -NN, EM). U zkoušky se ptají, kdy je která volba vhodná: je-li *absence sama informací* (nevyplněný příjem u žadatele o úvěr), patří jí vlastní kategorie „nevím“.

Odlehle hodnoty

Mezikvartilové rozpětí je $IQR = Q_3 - Q_1$ a odlehlá hodnota leží mimo interval $[Q_1 - 1,5 IQR, Q_3 + 1,5 IQR]$. Kvartily se počítají ze vzestupně seřazených dat na pozicích $n/4$ a $3n/4$ se zaokrouhlením nahoru; k nim se kreslí **box plot** s mediánem, kvartily, vousy a body mimo. Odlehlá hodnota může být chyba měření, kterou je nutné odstranit, ale i nejzajímavější případ v datech — právě na tom stojí detekce podvodů.

Standardizace

Používá se desítkové škálování, **min-max** do $[0, 1]$ nebo $[-1, 1]$, **z-skóre** podle *střední absolutní odchylky*, které je robustnější k odlehlým hodnotám, a **std-skóre** podle směrodatné odchylky. Bez standardizace ovládne vzdálenost ten atribut, který má největší rozsah: příjem v korunách přebije počet dětí.

Diskretizace

Ekvidistantní diskretizace tvoří stejně široké intervaly a je citlivá na odlehlé hodnoty, **ekvifrekvenční** intervaly stejně obsazené a diskretizace **s využitím třídy** klade hranice tam, kde se mění rozdělení tříd, tedy dělí podle entropie nebo χ^2 . **Fuzzy diskretizace** hranice rozostří: jedné hodnotě odpovídají dvě kategorie, jejichž charakteristické funkce dávají v součtu 1, a váha fuzzy-objektu je součin $\prod_j \mu_j$. Diskretizací se ztrácí informace a mohou vzniknout *kontradikce*, tedy shodné vzory s různou třídou. **KEX** seskupuje hodnoty kategoriálního atributu podle χ^2 testu proti *apriornímu* rozdělení tříd; slouží k tomu procedury *Assign* a *Group*.

Redukce dat

Redukovat je potřeba ve třech situacích. Je-li *objektů příliš mnoho*, pomůže vzorkování (pozor na **reprezentativnost**), efektivnější uložení nebo stavba více modelů nad podmnožinami. Jsou-li *třídy nevyvážené*, nasadí se váhy chyb nebo různé pravděpodobnosti výběru, tedy převzorkování minority či podvzorkování majority. Je-li *atributů příliš mnoho*, vedou dvě různé cesty:

- **transformace (PCA)** vyrobí méně *nových* atributů jako lineární kombinace původních; je však nutné znát *všechny* původní atributy a mizí interpretace;
- **selektce** ponechá podmnožinu *původních* atributů, takže interpretace zůstává.

Filtry vs. wrappery

Filtr spočítá charakteristiku pro každý atribut *samostatně* a nezávisle na modelu: je rychlý, ale nezachytí *interakce* atributů. **Wrapper** naproti tomu postaví model nad podmnožinou atributů a vyhodnotí jej: je drahý, zato zohlední interakce i konkrétní algoritmus. Podmnožiny se prohledávají *bottom-up* přidáváním atributů, nebo *top-down* jejich odebíráním.

Filtrační kritéria

Používá se χ^2 , kde je větší lepší, entropie $H(A)$, kde je lepší menší, dále vzájemná informace $MI(A, C)$ a informační míra závislosti $ID(A, C) = MI(A, C)/H(C)$, u níž je opět větší lepší. Zkoušející chce zdůvodnit *normalizaci* ID: bez ní jsou zvýhodněny atributy s mnoha hodnotami a v extrému vyhraje identifikátor, který rozdělí data na jednoprvkové skupiny.

χ^2 test a regrese

χ^2 test nezávislosti má $(R - 1)(S - 1)$ stupňů volnosti a je použitelný jen za podmínky $r_{k,sl}/n \geq 5$; pro malé četnosti se sáhne po **Fisherově exaktním testu**. Výpočet na čtyřpolní tabulce je typická úloha u tabule: v příkladu s úvěrem vyjde $\chi^2 = 42,857 > 3,84$, takže nezávislost zamítáme. **Regrese a korelace** stojí na metodě nejmenších kvadrátů. Koeficient β je kovariance dělená rozptylem, $\alpha = \bar{y} - \beta \bar{x}$, a vícerozměrně $\beta = (X^T X)^{-1} X^T Y$. Korelační koeficient $\rho = \sigma_{xy}/(\sigma_x \sigma_y)$ měří *jen lineární* závislost, takže nulová korelace neznamena nezávislost.

Otázka 3. Metody pro dobývání znalostí; asociační pravidla, přístupy založené na principu učení s učitelem a klastrová analýza

Asociační pravidla — míry

Support je podíl transakcí obsahujících i a j , **confidence** podíl transakcí s i a j mezi transakcemi s i a **lift** $= p(i \wedge j) / (p(i)p(j))$. Je-li $\text{lift} < 1$, je pravidlo horší než náhoda a lepším pravidlem může být negace závěru. Všechny tři míry se počítají z malé tabulky transakcí.

Apriori a varianty

Apriori využívá **uzavřenost dolů**, tedy že každá podmnožina frekventované množiny je frekventovaná, a prohledává *do šířky*. Krok APRIORI-GEN nejprve spojí kombinace shodné v $k - 2$ kategoriích a pak prořeže ty, jimž chybí některá podkombinace délky $k - 1$. Prostor pravidel je $O(2^m)$, takže MBA typicky vyprodukuje *nadměrné množství* pravidel. **Taxonomie a virtuální položky**: vzácné položky se berou výše v taxonomii, časté níže; virtuální položky nesou informaci o transakci (den, čas, zákazník), za což se platí redundancí pravidel. **MS-Apriori** míří na vzácné položky. Každá položka má vlastní MIS, minsup pravidla je *minimum* MIS jeho položek a přibývá omezení rozdílů supportů φ . Tím *přestává platit uzavřenost dolů* (umět protipříklad), a proto se položky seřadí vzestupně podle MIS a místo F_1 nastoupí množina *semen* L a **tailCount** při generování pravidel. **CAR** pracuje s transakcemi označovanými třídou a hledá pravidlo $X \rightarrow y$; doluje je *přímo v jednom kroku* přes pravidlové položky (*condset*, y) a různým třídám lze dát různý minsup (101 % třídu zakáže). **Sekvenční vzory**: sekvence je uspořádaný seznam množin položek, *velikost* je počet prvků a *délka* počet položek; **GSP** pracuje obdobně jako Apriori. Pozor, $\langle \{3\}\{8\} \rangle$ a $\langle \{3, 8\} \rangle$ se navzájem *neobsahují*. **FP-Growth** projde data dvakrát a negeneruje *žádné kandidáty*. FP-strom sdílí *prefixy* (pořadí položek podle klesajícího supportu je heuristika) a doplňuje jej spojovými seznamy položek; extrakce jde zdola nahoru metodou *rozděl a panuj* přes prefixové podstromy a podmíněné FP-stromy. Jsou-li všechny transakce unikátní, vyjde v nejhorším případě strom větší než data.

Rozhodovací stromy

TDIDT staví strom metodou rozděl a panuj: atribut volí podle *minimální vážené entropie* $H(A) = \sum_v \frac{|A(v)|}{|D|} H(A(v))$, což je totéž jako maximální *informační zisk*. Indukce stojí $O(np \log p)$, klasifikace $O(q \log p)$, a hotový strom lze přepsat na pravidla. **ID3** (Quinlan 1986) je hladový a řídí se informačním ziskem. **C4.5** přidává chybějící a spojitě hodnoty, prořezávání validací (*reduced-error pruning*, *subtree raising*) a *rule post-pruning*; přesnost odhaduje dolní mezí $\text{acc} - 1,96 \sqrt{\text{acc}(1 - \text{acc})/n}$ a používá *poměrný* informační zisk, který penalizuje nadměrné větvení. **C5.0** je komerční a umí boosting. **CART** staví *binární* stromy a měří Gini $G(v_i) = 1 - \sum_j p_j^2$, kde je nižší lepší; dělí podle kritéria $\Phi = 2P_L P_R \sum_j |P(C_j|t_L) - P(C_j|t_R)|$. **CHAID** se řídí χ^2 a sám seskupuje hodnoty kategoriálních atributů.

Další metody učení s učitelem

Bayes vybírá hypotézu s maximální aposteriorní pravděpodobností $H_{MAP} = \arg \max_H P(E | H)P(H)$, protože jmenovatel lze zanedbat. *Naivní* předpoklad podmíněné nezávislosti z toho udělá $\arg \max_{H_t} P(H_t) \prod_i P(E_i | H_t)$. Zvládne nekompletní vzory, ale trápí jej nulové pravděpodobnosti, na což je Laplaceovo vyhlazení. **SVM**

maximalizuje okraj $2/\|w\|$; primární úloha zní $\min \frac{\langle w \cdot w \rangle}{2}$ za podmínky $y_i(\langle w \cdot x_i \rangle + b) \geq 1$. Kuhn–Tuckerovy podmínky jsou u konvexní úlohy s lineárními omezeními nutné *i postačující* a ve Wolfeho duálu vyjde $\alpha_i > 0$ jen pro *podpůrné vektory*. **Kernelový trik** využívá toho, že duál potřebuje jen skalární součiny: stačí $K(x, z) = \langle \phi(x) \cdot \phi(z) \rangle$ a samotné ϕ nikdy nevyčíslíme (Mercer). *Měkký okraj* přidá do podmínky pomocné proměnné $\xi_i \geq 0$ a do účelové funkce penalizaci $C \sum_i \xi_i$, kde C řídí kompromis mezi šířkou okraje a chybami. Metoda je omezena na dvě třídy a reálný prostor a výsledek není interpretovatelný. **Logistická regrese** modeluje $\ln \frac{p}{1-p} = \beta^T x$, tedy $p = \sigma(z)$, a učí se maximální věrohodností, což vede na křížovou entropii; ze $\sigma' = \sigma(1 - \sigma)$ plyne $\Delta \beta_j = \eta \sum_i (y_i - \sigma(z_i)) x_{ij}$. **Diskriminační analýza** zavede pro každou třídu funkci $g_j(x)$ a klasifikuje podle maxima; optimální je $g_j \propto P(C_j | x)$. U normálního rozdělení vyjde funkce kvadratická, a jsou-li kovarianční matice *shodné*, dokonce *lineární* (stačí μ_j a S). **ELM** nastaví parametry skrytých neuronů náhodně a výstupní váhy dopočítá *jednou* pseudoinverzí $\beta = H^+ T$ (regularizace I/C); je rychlá a nemá lokální minima. **Ensemble: bagging** snižuje *rozptyl* ($\sigma^2 \rightarrow \sigma^2/k$ pro i.i.d.), jeden bootstrap obsahuje $\approx 63,2\%$ různých bodů $(1 - 1/e)$ a ideální komponentou je strom, protože má nízké zkreslení a vysoký rozptyl; zkreslení bagging nesníží. **Náhodné lesy** řeší korelaci komponent: rozptyl je $\rho \sigma^2 + (1 - \rho) \sigma^2 / k$ a první člen na k nezávisí. Náhodnost proto přichází z bootstrapu a navíc z podmnožiny $m \approx \sqrt{\# \text{příznaků}}$ v každém uzlu. **AdaBoost** naproti tomu snižuje *zkreslení*: váhy chybně klasifikovaných vzorů rostou, váha modelu je $\alpha_t = \frac{1}{2} \ln \frac{1 - \epsilon_t}{\epsilon_t}$, běží *sekvenčně* a je citlivý na šum.

Klastrová analýza

Metriky: Hammingova neboli Manhattan (L_1), euklidovská (L_2), Čebyševova (L_∞) a Minkowského (L_q), jejímiž speciálními případy jsou všechny předchozí; pro veličiny s různým rozptylem **Mahalanobisova** $d_M^2 = (x_1 - x_2)^T S^{-1} (x_1 - x_2)$. Před shlukováním se *normalizuje*. Vzdálenost dvou klastrů se měří přes nejbližšího souseda, nejvzdálenějšího souseda, průměr, nebo centroidy. **k-means** (Lloyd) rozdělí data náhodně, spočítá centroidy, přesune body a opakuje. Cenu nikdy nezvyší, ale nedává záruku aproximace, a proto vznikl **k-means++**, který volí centroid s pravděpodobností $\propto$ kvadrátu vzdálenosti k nejbližšímu centroidu, a dále LocalSearch++. **k-medians** pracuje v Manhattanské metrice a bere medián po dimenzích, takže je robustnější. **k-medoids** volí reprezentanty *z dat* a hledá hill-climbingem s výměnami; stojí $O(knd)$ na iteraci a zvládne libovolný typ dat. **PAM** testuje všech $k(n - k)$ výměn ($O(kn^2d)$), **CLARA** vzorkuje a riskuje špatný vzorek a **CLARANS** prohledává náhodně nad plnými daty (*MaxAttempt*, *MaxLocal*). **Hierarchické** shlukování zdola nahoru dá každému vzoru vlastní klastř a pak slučuje dva nejbližší; výstupem je **dendrogram** a počet klastrů se volí až *řezem*. **CURE** vezme vzorek, rozdělí jej na p částí, každou zpracuje nezávisle hierarchicky na k' klastrů, ty hierarchicky na k a nakonec přiřadí zbytek dat. **LVQ** je shlukování s *učitelem*: vítězný vektor se při souhlasu tříd přitáhne, při nesouhlasu odtlačí a μ klesá jako $\mu(k - 1)/(k + 1)$. **Mřížkové** metody (MAFIA) rozdělí prostor na p^d hyperkrychlí, uplatní prah hustoty τ a za klustry prohlásí komponenty souvislosti grafu buněk. **DBSCAN** rozlišuje bod *jádrový* ($\geq \tau$ bodů v radiu ε), *hraniční* a *šumový*; klustry jsou komponenty souvislosti jádrových bodů. Zvládne klustry *libovolného tvaru* a sám detekuje odlehle hodnoty.

Otázka 4. Metody pro extrakci charakteristických diskriminačních pravidel a měření jejich zajímavosti

Charakterizace vs. diskriminace

Charakterizace popisuje *cílovou třídu* a odpovídá na otázku, co je pro ni typické. **Diskriminace** tutéž třídu *porovnává* s kontrastními třídami a ptá se, čím se od nich odlišuje. Rozdíl mezi oběma úlohami je rozdílem mezi *typičností* a *rozdlišovací silou*. Vlastnost může být pro třídu naprosto typická (většina zákazníků jsou muži), a přesto pro rozlišení bezcenná, protože muži tvoří většinu i v ostatních třídách.

AOI — indukce řízená atributy

Indukce řízená atributy (*attribute-oriented induction*) zobecňuje data tak dlouho, dokud z tabulky nezbude relace o několika řádcích. Postupuje v šesti krocích:

1. dotazem se seberou relevantní data, tedy cílová a případně i kontrastní třída;
2. ke každému záznamu se přidá atribut **count**;
3. každý atribut se buď *odstraní*, má-li mnoho hodnot a neexistuje k němu koncepční hierarchie, nebo *generalizuje*, tedy nahradí nadřazenou hodnotou podle hierarchie;
4. shodné záznamy se agregují a jejich **count** se sečtou;
5. generalizuje se dál, dokud relace není menší než prahová velikost T ;
6. výsledná generalizovaná relace se předloží uživateli.

Celý postup stojí $O(na)$, je tedy *lineární* v počtu záznamů i atributů. Řídí jej dva prahy: *attribute threshold* říká, kolik hodnot se u atributu ještě snese, a *generalized relation threshold* T určuje velikost výsledné relace.

Koncepční hierarchie

Bez hierarchie se s atributem nedá udělat nic jiného než jej odstranit, a proto na její podobě záleží. **Schématová** hierarchie plyne přímo ze struktury dat (ulice → město → stát), **seskupovací** vzniká explicitním výčtem skupin hodnot, **operační** se odvodí výpočtem (z e-mailu doména) a **pravidlová** je definovaná pravidly.

Dvě váhy

Nad generalizovanou relací se počítají dvě čísla a každé odpovídá na jinou otázku.

$$\text{t-weight} = \frac{\text{count}(q_a)}{\sum_i \text{count}(q_i)}$$

T-weight měří typičnost *uvnitř* cílové třídy, takže součet t-weight přes všechny záznamy generalizované relace dá 100 %. Stojí na ní **charakteristická** pravidla, která mří ve směru *třída* $\Rightarrow$ *vlastnosti* (implikace „ $\Rightarrow$ “) a formulují nutnou podmínku.

$$\text{d-weight} = \frac{\text{count}(q_a \in C_{\text{target}})}{\sum_j \text{count}(q_a \in C_j)}$$

D-weight měří rozlišovací sílu vůči kontrastním třídám; ve jmenovateli se proto sčítá přes *všechny* třídy včetně cílové. Stojí na ní **diskriminační** pravidla, tedy směr *vlastnosti* $\Rightarrow$ *třída* („ $\Leftarrow$ “) a postačující podmínka. **Popisné pravidlo** kombinuje obojí („ $\Leftrightarrow$ “) a uvádí obě váhy.

Interpretace

Obě váhy se u tabule počítají z tabulky generalizovaných záznamů a vzápětí přijde otázka, proč vysoká t-weight neznamená vysokou d-weight. Odpověď zní, že d-weight je nutné srovnávat s *apriorním* podílem cílové třídy: je-li podíl třídy v datech 50 % a d-weight vlastnosti vyjde také 50 %, vlastnost nerozlišuje vůbec.

Zajímavost znalosti

Míry zajímavosti se dělí podle toho, kdo rozhoduje. **Objektivní** míry počítá stroj: t-weight a d-weight, support a confidence, **lift**, pokrytí, χ^2 , informační zisk a *jednoduchost*, tedy délku pravidla. **Subjektivní** míry patří uživateli; **neočekávanost** znamená, že pravidlo odporuje jeho dosavadní představě, a **akceschopnost** (*actionability*), že se podle něj dá něco udělat. Objektivní míry si systém spočítá sám, ale teprve subjektivní rozhodnou, jestli je výsledek *znalost*, nebo *notorieta*: totéž pravidlo bývá pro jednoho uživatele objevem a pro druhého samozřejmostí.

Souvislosti

Charakterizace i diskriminace jsou *deskriptivní* úlohy z otázky 1. Vstupem je tabulka po přípravě dat a diskretizaci z otázky 2 doplněná o koncepční hierarchie, výstupem generalizovaná relace. Zajímavost pak funguje jako filtr nadprodukce pravidel, čímž navazuje na asociační pravidla z otázky 3 a na kritéria hodnocení znalostí z otázky 5.

Otázka 5. Reprezentace, vyhodnocování a vizualizace získaných znalostí

Formy reprezentace znalostí

Forma, v níž znalost vyjde, je dána metodou a rozhoduje o tom, kolik z ní člověk pochopí. **IF-THEN pravidla** jsou nejsrozumitelnější a jsou *lokální*, protože každé pravidlo se dá číst samostatně. **Rozhodovací strom** je naopak *globální* a čitelný zůstává do hloubky 4–5. Dále se používá **rozhodovací tabulka**, **matematická funkce** (SVM, neuronové sítě, regrese), která je kompaktní, zato neinterpretovatelná, **prototypy a centroidy** z klastrování, **pravděpodobnostní model** u Bayese, **grafy a sítě** a konečně **instance** (k -NN, CBR), kde jsou „modelem“ samotná data. U každé formy se ptají, z jaké metody vzniká a čím se za srozumitelnost platí.

Kritéria hodnocení metod

Metody se srovnávají podle prediktivní přesnosti, efektivity (počítá se čas konstrukce i čas použití), robustnosti vůči šumu a chybějícím hodnotám, škálovatelnosti, interpretovatelnosti a kompaktnosti modelu. Žádná metoda nevyhraje ve všem, takže volba je vždy kompromisem a řídí ji typ úlohy z otázky 1.

Odhad chyby

Holdout rozdělí data na trénovací a testovací množinu a hodí se pro velká data; obě množiny se *nesmí míchat*. **k -násobná křížová validace** rozdělí data na k částí a postaví k modelů, běžně pro k rovné 5 nebo 10; výsledná přesnost je průměrem k přesností a doplní se interval spolehlivosti s $t_{N,k-1}$. Používá se na menších datech. **Leave-one-out** je m -násobná křížová validace pro data opravdu malá. Ladí-li se *parametry* algoritmu, odděluje se ještě třetí, **validační množina**, aby testovací data zůstala nezávislá.

Matice záměn a míry

Matice záměn obsahuje TP , FN , FP a TN ; z nich se spočítá přesnost $p = \frac{TP}{TP+FP}$, úplnost $r = \frac{TP}{TP+FN}$ a jejich harmonický průměr $F_1 = \frac{2pr}{p+r}$. Harmonický průměr leží blíž k *menšímu* z obou čísel, a proto F_1 netoleruje nulu ani v jedné míře. Otázka, *proč accuracy nestačí*, míří na nevyvážená data: při 1 % pozitivních případů má triviální postup „nedělat nic“ přesnost 99 %.

ROC a AUC

Křivka ROC vynáší $TPR = \frac{TP}{TP+FN}$, tedy senzitivitu neboli úplnost (*recall*) pozitivní třídy, proti $FPR = \frac{FP}{FP+TN}$; doplnkem je TNR , specifita $= 1 - FPR$. Vede z $(0, 0)$ do $(1, 1)$, diagonála odpovídá náhodnému hádání a ideálem je levý horní roh. Sestrojí se tak, že se vzory seřadí podle skóre a práh se posouvá po jednotlivých případech. **AUC** vyjde 1 pro perfektní a 0,5 pro náhodný klasifikátor. Potřebná je proto, že se ROC křivky dvou klasifikátorů mohou *křížit*, takže ani jeden není lepší ve všech prázích.

Skórování a lift

Skórování přiřadí místo třídy *odhad pravděpodobnosti*; u stromu jím je confidence v listu. Vzory se podle skóre seřadí a rozdělí do přihrádek, typicky decilů, a **lift křivka** porovná zásah v přihrádce s diagonálou náhodného výběru. Na to navazuje ekonomická úvaha: známe-li cenu zásilky a výnos z reakce, spočítá se, kolik zásilek se ještě vyplatí poslat.

Tři roviny vyhodnocování

1. statistická kvalita modelu (přesnost, AUC) — objektivní;
2. zajímavost jednotlivých vzorů (lift, χ^2 , jednoduchost) — objektivní;
3. vyhodnocení uživatelem — subjektivní.

Samotná znalost se posuzuje podle **čtyř kritérií**: musí být *srozumitelná, platná, užitečná a nová*.

Vizualizace

Technika se volí podle úlohy: histogram ukáže rozdělení, box plot odlehle hodnoty, scatter a SPLOM vztahy dvojic, paralelní souřadnice mnoho dimenzí najednou, heatmapa matici, dendrogram hierarchii klastrů, projekce (PCA, t-SNE, UMAP) sníženou dimenzi a ROC s liftem kvalitu modelu. V KDD má vizualizace **tři role**: explorační dat, vizualizaci modelu a prezentaci výsledků. Pro tu první je klasickým argumentem **Anscombeho kvartet**, tedy shodné statistiky a přitom zcela různé grafy. Tufteho zásady žádají nezkrášlovat osami, hlídat poměr dat k inkoustu a volit barvu podle typu dat, tedy škálu kvalitativní, sekvenční, nebo divergující. Znat je potřeba i omezení: *t-SNE a UMAP zkreslují globální vzdálenosti*, takže vzdálenost mezi klastry v projekci nelze interpretovat.

Otázka 6. Modely pro analýzu sociálních sítí; míry centrality, detekce komunit

Co je SNA

Analýza sociálních sítí spojuje sociální vědy, analýzu sítí a teorii grafů. Zajímají ji *vztahy*, ne entity a jejich atributy. Sít se zapisuje obrázkem, seznamem hran nebo maticí sousednosti, která u orientovaných grafů nemusí být symetrická. Zkoumat lze **ego síť** kolem jednoho uzlu, nebo „celou“ síť; **problém specifikace hranic** připomíná, že žádná studovaná síť není celá.

Síla vazeb

Vazby jsou silné, nebo slabé a **síla slabých vazeb** (Granovetter 1973) říká, že práci člověk najde přes vazby slabé, protože jediné ty nesou nové informace. Síť formuje **homofilie** (podobní se spojují), **tranzitivita** a **přemostění**; homofilie s tranzitivitou dohromady vytvářejí *kliky*. **Most** je hrana, jejíž odstranění rozpojí koncové uzly, a **zkratkový most** taková, po jejímž odstranění vzdálenost vzroste nad 2. Sílu vazby měří **překryv sousedství** $O(i, j) = \frac{|N_i \cap N_j|}{|N_i \cup N_j| - 2}$: čím větší, tím silnější vazba.

Čtyři míry centrality

- **stupňová** počítá, kolik lidí uzel *přímo* dosáhne, a měří tak lokální aktivitu;
- **mezilehlá** počítá, na kolika nejkratších cestách uzel leží, a ukazuje, kdo kontroluje tok a kde se síť *rozpadne*;
- **blízkostní** je převrácená průměrná délka nejkratších cest, tedy rychlost *šíření*;
- **vlastní** řeší $Ax = \lambda x$, přičemž nezáporný vektor dává jen *největší* vlastní číslo; říká, jak dobře je uzel spojen s *dobře propojenými*.

U zkoušky se chce interpretační tabulka a zdůvodnění, proč jedna míra nestačí: dva průměrné uzly mohou být *společně* důležitější než jeden s nejvyšším stupněm. **Strukturní ekvivalence** znamená, že pozice lze vyměnit bez změny struktury sítě.

Koheze a vlastnosti reálných sítí

Kohezi popisuje reciprocita (jen u orientovaných grafů), hustota $|E|/\binom{|V|}{2}$, která je pro kliku rovna 1, a **klastrovací koeficient** $C_i = \frac{2|e_{jk}|}{k_i(k_i-1)}$ i jeho průměr. Vzdálenosti měří *průměr sítě* (*diameter*), tedy nejdelší nejkratší cesta, dále průměrná vzdálenost a excentricita. **Malý svět** je vysoké C spolu s krátkou průměrnou cestou. Reálné komplexní sítě mají **šest vlastností**: efekt malého světa (Milgram, medián 6), tranzitivitu čili klastrování, *mocinné* rozdělení stupňů, odolnost (robustní k náhodnému, zranitelné cíleným odstraněním hubů), vzorce míchání (asortativní míchání je homofilie) a komunitní strukturu. **Bezškálové sítě** vznikají růstem a **preferenčním připojováním** (rich-get-richer, Matoušův efekt); s tím souvisí **centralizace** a struktura *jádro-periferie* (bow-tie).

Modely šíření vlivu

Oba modely sdílejí orientovaný graf, dělení uzlů na aktivní a neaktivní a pravidlo, že *aktivovaný uzel už nelze deaktivovat*. **LTM** je prahový a dívá se očima *příjemce*: práh θ_v se losuje uniformně z $[0, 1]$ a uzel se aktivuje, jakmile $\sum_{\text{aktivní}} w_{u,v} \geq \theta_v \sum w_{u,v}$. **ICM** je kaskádový a dívá se očima *vysílajícího*: každý soused se aktivuje s pravděpodobností $p_{v,u}$, ale pokus proběhne *jen jednou*. **Maximalizace vlivu** je NP-těžká a hladový přístup dává aspoň 63 % optima.

Vliv, korelace, homofilie

Test korelace porovná podíl hran mezi různými hodnotami atributu s hodnotou $2p(1-p)$; u kuřáků vyjde $14\% < 49\%$. Korelaci mohou vysvětlit tři procesy: *homofilie*, *zmatení* společným prostředím a *vliv*. Sociální korelaci kvantifikuje logistický model $\ln \frac{p(a)}{1-p(a)} = \alpha \ln(a+1) + \beta$, kde α je koeficient sociální korelace. **Shuffle test** zpřehází *časové značky*; významná změna α je důkazem *vlivu*. **Test homofilie** srovnává počet heterogenních hran s $2pq$: významně méně znamená homofilii, významně více *inverzní* homofilii (v příkladu 5 z 18 proti

očekávaným $2pq = 8$ z 18). **Výběr** znamená, že charakteristiky řídí tvorbu vazeb, kdežto **sociální vliv** znamená, že vazby formují charakteristiky *mutabilní* (pohlaví, rasa a věk jsou imutabilní). Rozlišit je lze jen *longitudinálně*, jak ukázali na obezitě Christakis a Fowler. **Afiliční sítě** jsou bipartitní, spojují osoby $\times$ fokusy, a vazby v nich vznikají **třemi uzávěry**: tranzitivní (společný přítel), *fokální* (společný fokus, tedy výběr) a *členským* (přítel už je ve fokusu, tedy vliv). Bázový model dává $T_{\text{base}}(k) = 1 - (1-p)^k$, empiricky se ale projevují klesající výnosy. **Schellingův model** pracuje s agenty dvou typů, kteří jsou spokojeni při $\geq t$ sousedech téhož typu, a ukazuje, jak z lokální homofilie vzejde *samovolná segregace*. **Strukturní balance**: balancované jsou trojúhelníky $+++$ a $+-$. *Věta o bilanci* říká, že úplný balancovaný graf znamená buď samé přátele, nebo dvě skupiny vnitřních přátel a vzájemných nepřátel; *slabá balance* zakazuje jen $++-$ a připouští libovolný počet skupin.

Authority: HITS a PageRank

HITS je dotazově *závislý*: z kořenové množiny S vznikne báze B a mocinná iterace střídá $a = L^T h$ a $h = La$, přičemž normalizace je *nutná*. Po k krocích je $a_k = (L^T L)^{k-1} a_0$, kde $L^T L$ je ko-citační matice. Slabinou je spamovatelnost, drift tématu a náklady v době dotazu. **PageRank** je naproti tomu dotazově *nezávislý*, $P(i) = \sum_{(j,i) \in E} P(j)/O_j$, a *normalizaci nepotřebuje*, protože celkový PageRank zůstává konstantní. Problém „pomaleho úniku“ řeší tlumicí faktor d (0,85): $P(i) = (1-d) + d \sum P(j)/O_j$. Markovský řetězec potřebuje matici *stochastickou*, *ireducibilní* a *aperiodickou*, a webový graf nesplňuje ani jednu podmínku. Stochasticitu kazí *visící stránky* s nulovým řádkem, které se řeší zvlášť (odstranit, nebo dát řádek $1/n$), zatímco ireducibilitu i aperiodicitu spraví *jediná* úprava: odkaz odkudkoli kamkoli s malou pravděpodobností.

Detekce komunit

Definice komunity je *subjektivní* a skupiny mohou být explicitní, nebo implicitní. **Rezy**: minimální řez dává nevyvážené skupiny a s vahami a balancí je NP-těžký, a proto se sahne po *poměrovém* a *normalizovaném* řezu (dělení $|C_i|$, resp. $\text{vol}(C_i)$). **Girvanové-Newman** je divizivní: odstraňuje hrany s nejvyšší *mezilehlostí*, stojí $O(m^2 n)$ a počet komunit se určí podle maxima **modularity** $Q = \frac{1}{2m} \sum_{i,j} (A_{ij} - \frac{k_i k_j}{2m}) \delta(c_i, c_j)$; Q leží v $[-1, 1]$ a smysluplné komunity začínají u $Q \geq 0,3$. **Louvain** maximalizuje modularitu hladově a aglomerativně ve dvou fázích (lokální přesuny $\rightarrow$ supergraf) v čase $O(n \log n)$; je ale citlivý na pořadí, vrací *nesouvislé komunity* a uváže v lokálních optimech. **Leiden** proto přidává fázi *upřesnění rozdělení*. Metody se dělí do **čtyř kategorií**. *Uzlově orientované* hledají kliky, což je NP-těžké; **CPM** zvládne *překrývající se* komunity a kliku změkčuje k -kliku, klub a klan, k -jádro a k -plex. *Skupinově orientované* hledají γ -husté kvazikliky. *Sítově orientované* spočítají podobnost vrcholů a nasadí k -means, MDS, blokové modely nebo spektrální shlukování přes laplacián s *nejmenšími* vlastními čísly (maximalizace modularity naopak bere *největší*); vše lze psát jako maticovou faktORIZACI $X \approx S \Sigma S^T$. *Hierarchicky orientované* jsou divizivní GN a aglomerativní Louvain. **Tematické komunity** $K = (T, M)$ se mohou *překrývat*; v *bipartitních jádrech* jsou vějíře huby a středů authority.

Predikce vazeb

Míry jsou obsahové (staví na homofilii), nebo strukturní (staví na tranzitivním uzávěru), a ty strukturní bývají silnější. Počítají se *společní sousedé* $|S_i \cap S_j|$, což stupně ignoruje, *Jaccard* $\frac{|S_i \cap S_j|}{|S_i \cup S_j|}$ a *Adamic-Adar* $\sum_k \frac{1}{\log |S_k|}$, kde váha klesá se stupněm společného souseda. **Katzova míra** $K_{ij} = \sum_t \beta^t W_{ij}^{(t)}$, maticově $K = (I - \beta A)^{-1} - I$ pro dostatečně malé β , mří na *řídce* sítě s málo společnými sousedy. **Klasifikační pojetí** bere predikci vazeb jako pozitivně-neoznačovanou úlohu: doplní se vzorek negativ a nasadí logistická regrese. Klasifikátor se relevancí příznaků naučí sám a zvládne *asymetrické* příznaky u orientovaných sítí.

Otázka 7. Praktické využití technik pro dobývání znalostí a analýzu sociálních sítí

Jak odpovídat

Ke každé aplikaci patří **trojice**: *typ úlohy* (deskriptivní, nebo prediktivní; s učitelem, nebo bez učitele), *použitá metoda* a *způsob vyhodnocení*. Zkoušející neověřuje výčet aplikací, ale schopnost přiřadit k úloze metodu a metriku.

Vlajkové aplikace dobývání znalostí

- **Analýza nákupního košíku** stojí na asociačních pravidlech a hodnotí se supportem, confidence a liftem; hlavním rizikem je nadprodukce pravidel.
- **Detekce podvodů** (příkladem je zdravotní pojišťovna) pracuje s nevyváženými daty a hodnotí se liftem a náklady chyb; stroj tu pozornost experta *zaostřuje*, nenahrazuje jej.
- **Kreditní skórování** používá rozhodovací stromy a Bayese, protože klíčovým požadavkem je *srozumitelnost*: rozhodnutí je nutné umět odůvodnit žadateli i regulátorovi.
- **Segmentace zákazníků** je klastrování, v němž centroid představuje typického zákazníka; hodnotí se interpretovatelností segmentů, ne přesností.
- **Churn a cílený marketing** jsou klasifikace na nevyvážených datech, takže se sáhne po ROC, AUC a *liftu* a doplní se ekonomická úvaha o počtu kontaktovaných zákazníků.
- **Klasifikace textu** je doménou SVM kvůli vysoké dimenzi a řídkým datům.
- **Predikce časových řad** se posuvným oknem převede na tabulku objektů $\times$ atributy.
- **Web usage mining** hledá sekvenční vzory nad logy.

Vlajkové aplikace SNA

- **Klíčoví hráči v kriminálních a teroristických sítích** se hledají mírami centrality: mezilehlá najde spojky, vlastní vliv.
- **Doporučování přátel** je predikce vazeb (společní sousedé, Adamic–Adar).

- **Optimalizace komunikačních sítí** sleduje kohezi, úzká hrdla a mezilehlost.
- **Epidemiologie** (Rockdale County 1996) ukázala, že šíření vysvětlí struktura kontaktní sítě lépe než počet kontaktů.
- **Vakcinace cílená na huby** plyne přímo z vlastností bezškálových sítí.
- **Marketing a kaskádové finanční krachy** se popisují modely šíření vlivu (LTM, ICM).
- **Segmentace zákazníků operátora** podle jazykových komunit se dělá Louvainem nad sítí volání; 2 mil. zákazníků je ukázkou škálovatelnosti.

Klíčová vlastnost SF sítí pro praxi

Bezškálová síť je odolná proti *náhodným* poruchám, protože vydrží až 80 % odstraněných uzlů, ale zranitelná *cíleným* útokem, kde stačí 5–15 % hubů. Z toho plyne jak strategie vakcinace a ochrany infrastruktury, tak nemožnost vymýtit internetové viry běžnými prostředky.

Nasazení není konec

Po nasazení se monitoruje **drift**, protože rozdělení dat se v čase mění a model stárne, a také *zpětná vazba modelu do dat*: doporučení ovlivní chování, které se pak model učí znovu. K tomu přistupuje **soukromí**, neboť i anonymizovaný graf lze deanonymizovat porovnáním struktury, a **spravedlnost**, protože chráněný atribut jde rekonstruovat z ostatních a jeho vynechání nestačí. Právní rámec dává **GDPR** čl. 22 (automatizované rozhodování a právo na vysvětlení) a **AI Act**.

Vazby na ostatní otázky

Volba metody vychází z typu úlohy (otázka 1) a kvalita výsledku stojí na přípravě dat (otázka 2); metriky, ROC a lift pocházejí z otázky 5 a komunity s centralitami z otázky 6.