

Dobývání znalostí

Shrnutí okruhu ke státní závěrečné zkoušce — jedna otázka na jednu stranu

SZZ Umělá inteligence, MFF UK · srpen 2026

Oficiální znění okruhu (zdroj pravdy, 2025/2026):

<https://www.mff.cuni.cz/cs/studenti/bc-a-mgr-studium/studijni-plany/2025-2026/informatika/mgr/umela-inteligence>

Sedm vět oficiálního znění okruhu, sedm stran tohoto textu. Podrobný výklad je v 03-dobyvani-znalosti.pdf, anglicky v ENG/03-data-mining.pdf.

- | | |
|--|--------|
| 1. Základní paradigmaty dobývání znalostí. | str. 2 |
| 2. Příprava dat; výběr atributů a metody pro analýzu jejich relevance. | str. 3 |
| 3. Metody pro dobývání znalostí; asociační pravidla, přístupy založené na principu učení s učitelem a klastrová analýza. | str. 4 |
| 4. Metody pro extrakci charakteristických diskriminačních pravidel a měření jejich zajímavosti. | str. 5 |
| 5. Reprezentace, vyhodnocování a vizualizace získaných znalostí. | str. 6 |
| 6. Modely pro analýzu sociálních sítí; míry centrality, detekce komunit. | str. 7 |
| 7. Praktické využití technik pro dobývání znalostí a analýzu sociálních sítí. | str. 8 |

Průřezová témata — ptají se napříč otázkami

- **Přesnost vs. srozumitelnost:** stromy a pravidla jsou čitelné, SVM a sítě přesnější a neinterpretovatelné; typ úlohy (klasifikace / popis / nugety) rozhoduje, které kritérium vyhraje.
- **Nevyvážená data:** accuracy je zavádějící $\Rightarrow$ precision/recall, F_1 , ROC/AUC, lift; váhy chyb nebo různé pravděpodobnosti výběru už při přípravě dat.
- **Škály atributů** (nominální, ordinální, intervalová, poměrová) určují přípustné operace, metriky i volbu metody — to je nejčastější „proč“ u doplňujících otázek.
- **Transformace vs. selekce atributů:** PCA (nové atributy, ztráta interpretace, nutné znát všechny původní) vs. filtry a wrappery (podmnožina, interpretace zůstává).
- **Složitost:** AOI $O(na)$, indukce stromu $O(np \log p)$, PAM $O(kn^2d)$, Girvanové–Newman $O(m^2n)$, Louvain $O(n \log n)$; NP-těžké: hledání klik, vyvážený řez s vahami, maximalizace vlivu (hladově 63 % optima).
- **Proces, ne algoritmus:** CRISP-DM je cyklický, příprava dat spotřebuje 60–80 % času, nasazení není konec (drift, soukromí, spravedlnost).

Co se chce spočítat u tabule

- **Support, confidence, lift** z malé tabulky transakcí; jeden krok Apriori (spojení + prořezání).
- **Entropie a informační zisk** pro volbu atributu; příklad s úvěrem (příjem 0,5747; konto 0,6667; pohlaví 0,9183; nezaměstnaný 0,825), Gini index.
- **Naivní Bayes** na malé tabulce (0,1042 vs. 0,0416).
- χ^2 na čtyřpolní tabulce ($42,857 > 3,84$), stupně volnosti $(R-1)(S-1)$.
- **Kvartily, IQR** a mez odlehlosti $\pm 1,5$ IQR, box plot.
- **t-weight a d-weight** z tabulky generalizovaných záznamů.
- **Matrice záměn:** p, r, F_1 ; konstrukce **ROC** ze žebříčku a úvaha o AUC.
- **Centrality** na malém grafu (stupňová, mezilehlá, blízkostní, vlastní); **klastrovací koeficient**; **modularita** Q .
- **Test homofilie** (5 z 18 vs. $2pq = 8$), test korelace (14 % vs. 49 %).
- **PageRank** jednou iterací; **HITS** s normalizací.

Nejčastější chyby

- Tvrdit, že vysoká t-weight znamená vysokou d-weight (typičnost $\neq$ rozlišovací síla).
- Zapomenout, že u **MS-Apriori** *neplatí* uzavřenost dolů.
- Míchat trénovací a testovací data, resp. ladit parametry na testovací množině (na to je *validační* množina).
- Zaměnit **bagging** (snižuje rozptyl, paralelní) a **boosting** (snižuje zkreslení, sekvenční, citlivý na šum).
- U PageRanku tvrdit, že potřebuje normalizaci (nepotřebuje — na rozdíl od HITS).

Otázka 1. Základní paradigmata dobývání znalostí

Co je KDD

Dobývání znalostí z databází (*knowledge discovery in databases*) = netriviální proces získávání *implicitních*, dosud *neznámých* a *potenciálně užitečných* informací z dat. Je **interaktivní** (uživatel rozhoduje) a **iterativní** (fáze se opakují). *Data mining* je v úzkém smyslu jen jedna fáze tohoto procesu, v běžné mluvě celý proces.

Pět fází KDD

výběr dat → *předzpracování* → *transformace* → *dobývání (data mining)* → *interpretace a vyhodnocení*. Příprava dat (první tři fáze) spotřebuje **60–80 % času** celého projektu — to je nejčastěji ověřovaný fakt.

Kořeny oboru

Umělá inteligence (strojové učení), **databáze** (velké objemy, dotazování) a **statistika** (inference, testování), motivované potřebou *podpory rozhodování*. Odlišení od **OLAP**: OLAP odpovídá na *předem položené* otázky (agregace, kostky, drill-down), KDD hledá vzory, *o nichž předem nevíme*. Odlišení od klasické statistiky: KDD pracuje s daty, která nebyla sbírána pro daný účel, a hledá hypotézy, nejen je testuje.

Tři typy úloh

- **klasifikace a predikce** — rozhoduje *přesnost*, srozumitelnost je bonus;
- **popis** (deskripce) — rozhoduje *srozumitelnost* a *plné pokrytí* dat;
- **hledání nugetů** — rozhoduje *překvapivost*; nuget nemusí pokrývat téměř nic, stačí, že je zajímavý a akceschopný.

Dělení úloh a metod

Deskriptivní (popsat data: asociační pravidla, klastrování, summarizace) vs. **prediktivní** (odhadnout neznámou hodnotu: klasifikace, regrese). **S učitelem** (známé cílové hodnoty) vs. **bez učitele** (jen struktura dat) vs. **poloučené** (málo označovaných + hodně neoznačovaných dat).

Škály atributů

Nominální (jen rovnost — barva), **ordinální** (uspořádání — známka), **intervalová** (rozdíly, ne poměry — teplota ve °C), **poměrová** (i poměry, absolutní nula — příjem). Škála určuje *přípustné operace* (nelze počítat průměr nominálního atributu), volbu metriky i metody. Typické transformace: nominální atribut → *v* binárních atributů; poměrový atribut s exponenciálním chováním → logaritmovat.

Metodologie

SEMMA (SAS): *Sample, Explore, Modify, Model, Assess*. **CRISP-DM** (6 fází): porozumění problému → porozumění datům → příprava dat → modelování → vyhodnocení → nasazení. Pořadí *není striktní* a proces je *cyklický*. **ASUM-DM** (IBM) = CRISP-DM + projektové řízení a provoz.

Nejčastější doplňující otázka

Proč pořadí fází CRISP-DM není striktní? — protože výsledky každé fáze určují další kroky: zjištěná kvalita dat vede zpět k přeformulování cíle, výsledek modelování zpět k jiné přípravě dat. Proces je smyčka s návraty, ne lineární postup.

Otázka 2. Příprava dat; výběr atributů a metody pro analýzu jejich relevance

Cíl přípravy dat

Vybrat relevantní data a reprezentovat je tak, aby je zvolený algoritmus zvládl; výsledkem je *jedna* tabulka *objekty* $\times$ *atributy* (denormalizace, agregace přes vztahy 1:N).

Chybějící hodnoty

Možnosti: *ignorovat objekt* (ztráta dat, riziko zkreslení) / *nová hodnota „nevím“* / *doplnit existující hodnotu* (modus, poměrně podle rozdělení, libovolně) / *doplnit modelem* (regrese, *k*-NN, EM). Umět říct, kdy je která volba vhodná: je-li *absence sama informací* (nevyplněný příjem u žadatele o úvěr), patří jí vlastní kategorie „nevím“.

Odlehlé hodnoty

IQR = $Q_3 - Q_1$; odlehlá hodnota leží mimo $[Q_1 - 1,5 \text{ IQR}, Q_3 + 1,5 \text{ IQR}]$. Umět spočítat kvartily ze vzestupně seřazených dat (pozice $n/4$ a $3n/4$, zaokrouhlení nahoru) a nakreslit **box plot** (medián, kvartily, vousy, body mimo). Odlehlá hodnota může být chyba měření (odstranit) i nejzajímavější případ (detekce podvodů).

Standardizace

Desítkové škálování, **min-max** do $[0, 1]$ nebo $[-1, 1]$, **z-skóre** podle *střední absolutní odchylky* (robustnější k odlehlým hodnotám), **std-skóre** podle směrodatné odchylky. Motivace: bez standardizace ovládne vzdálenost atribut s největším rozsahem (příjem v korunách vs. počet dětí).

Diskretizace

Ekvidistantní (stejně široké intervaly — citlivá na odlehlé hodnoty), **ekvifrekvenční** (stejně obsazené), **s využitím třídy** (dělení podle entropie nebo χ^2 — hranice tam, kde se mění rozdělení tříd). **Fuzzy diskretizace**: rozostřené hranice, jedné hodnotě odpovídají dvě kategorie se součtem charakteristických funkcí 1; váha fuzzy-objektu je součin $\prod_j \mu_j$. Rizika diskretizace: ztráta informace a vznik *kontradikcí* (shodné vzory s různou třídou). **KEX** seskupuje hodnoty kategoriálního atributu podle χ^2 testu proti *apriornímu* rozdělení tříd (procedure *Assign a Group*).

Redukce dat

Příliš mnoho objektů $\rightarrow$ vzorkování (pozor na **reprezentativnost**), efektivnější uložení, více modelů nad podmnožinami. *Nevyvážené třídy* $\rightarrow$ váhy chyb nebo různé pravděpodobnosti výběru (převzorkování minority, resp. podvzorkování majority). *Příliš mnoho atributů* $\rightarrow$ dvě různé cesty:

- **transformace (PCA)**: méně *nových* atributů jako lineární kombinace původních; nutné však znát *všechny* původní atributy a mizí interpretace;
- **selektce**: podmnožina *původních* atributů, interpretace zůstává.

Filtr vs. wrappery

Filtr počítá charakteristiku pro každý atribut *samostatně*, nezávisle na modelu — rychlý, ale nezachytí *interakce* atributů. **Wrapper** postaví model nad podmnožinou atributů a vyhodnotí jej — drahý, zohledňuje interakce a konkrétní algoritmus. Prohledávání podmnožin *bottom-up* (přidávání atributů) nebo *top-down* (odebírání).

Filtrační kritéria

χ^2 (větší = lepší), entropie $H(A)$ (menší = lepší), vzájemná informace $MI(A, C)$, informační míra závislosti $ID(A, C) = MI(A, C)/H(C)$ (větší = lepší). Umět zdůvodnit *normalizaci* ID: bez ní jsou zvýhodněny atributy s mnoha hodnotami (extrém: identifikátor rozdělí data na jednoprvkové skupiny).

χ^2 test a regrese

χ^2 **test** nezávislosti: $(R - 1)(S - 1)$ stupňů volnosti, podmínka použitelnosti $r_k s_l / n \geq 5$; pro malé četnosti **Fisherův exaktní test**. Umět projít výpočet na čtyřpolní tabulce (příklad s úvěrem: $\chi^2 = 42,857 > 3,84 \Rightarrow$ zamítáme nezávislost). **Regrese a korelace**: metoda nejmenších kvadrátů, β jako kovariance dělená rozptylem, $\alpha = \bar{y} - \beta \bar{x}$; vícerozměrně $\beta = (X^T X)^{-1} X^T Y$. Korelační koeficient $\rho = \sigma_{xy} / (\sigma_x \sigma_y)$ měří *jen lineární* závislost — nulová korelace neznamená nezávislost.

Otázka 3. Metody pro dobývání znalostí; asociační pravidla, přístupy založené na principu učení s učitelem a klastrová analýza

Asociační pravidla — míry

Support = podíl transakcí obsahujících i i j ; **confidence** = podíl transakcí s i j mezi transakcemi s i; **lift** = $p(i \wedge j)/(p(i)p(j))$. Lift $< 1 \Rightarrow$ pravidlo je horší než náhoda a negace závěru může být lepší pravidlo. Umět spočítat všechny tři z malé tabulky transakcí.

Apriori a varianty

Apriori využívá **uzavřenost dolů** (každá podmnožina frekventované množiny je frekventovaná) a prohledává *do šířky*. APRIORI-GEN = krok *spojení* (kombinace shodné v $k-2$ kategoriích) + krok *prořezání* (chybí-li některá podkombinace délky $k-1$). Prostor pravidel je $O(2^m)$, MBA typicky vyprodukuje *nadměrné množství* pravidel. **Taxonomie a virtuální položky**: vzácné položky brát výše v taxonomii, časté níže; virtuální položky nesou informaci o transakci (den, čas, zákazník) — pozor na redundanci pravidel. **MS-Apriori** (vzácné položky): každá položka má vlastní MIS, minsup pravidla je *minimum* MIS jeho položek, navíc omezení rozdílu supportů φ . *Uzavřenost dolů přestává platit* $\Rightarrow$ položky se seřadí vzestupně podle MIS, místo F_1 se použije množina *semen* L a **tailCount** při generování pravidel. *Umět uvést protipříklad k uzavřenosti dolů*. **CAR**: transakce označované třídou, pravidlo $X \rightarrow y$; dolují se *přímo v jednom kroku* přes pravidlové položky (*condset*, y); různým třídám lze dát různý minsup (101 % = třídu zakázat). **Sekvenční vzory**: sekvence = uspořádaný seznam množin položek, *velikost* = počet prvků, *délka* = počet položek; **GSP** pracuje obdobně jako Apriori. Pozor: $\{\{3\}\{8\}\}$ a $\{\{3, 8\}\}$ se navzájem *neobsahují*. **FP-Growth**: 2 průchody daty, *žádní kandidáti*; FP-strom sdílí *prefixy* (pořadí položek podle klesajícího supportu je heuristika) + spojové seznamy položek; extrakce zdola nahoru *rozděl a panuj* přes prefixové podstromy a podmíněné FP-stromy. Nejhorší případ: unikátní transakce $\Rightarrow$ strom větší než data.

Rozhodovací stromy

TDIDT (rozděl a panuj): atribut se volí podle *minimální vážené entropie* $H(A) = \sum_v \frac{|A(v)|}{|D|} H(A(v))$, ekvivalentně maximálního *informačního zisku*. Složitost indukce $O(np \log p)$, klasifikace $O(q \log p)$. Strom lze přepsat na pravidla. **ID3** (Quinlan 1986) — hladový, informační zisk. **C4.5** — chybějící a spojitě hodnoty, prořezávání validací (*reduced-error pruning*, *subtree raising*), *rule post-pruning*, odhad přesnosti dolní mezi $acc - 1,96\sqrt{acc(1-acc)/n}$, *poměrný* informační zisk (penalizuje nadměrné větvení). **C5.0** — komerční, boosting. **CART** — *binární* stromy, Gini $G(v_i) = 1 - \sum_j p_j^2$ (nižší = lepší), kritérium $\Phi = 2P_L P_R \sum_j |P(C_j|t_L) - P(C_j|t_R)|$. **CHAID** — χ^2 , automatické seskupování hodnot kategoriálních atributů.

Další metody učení s učitelem

Bayes: hypotéza s maximální aposteriorní pravděpodobností $H_{MAP} = \arg \max_H P(E|H)P(H)$ (jmenovatel lze zanedbat); *naivní* předpoklad podmíněné nezávislosti $\Rightarrow \arg \max_{H_t} P(H_t) \prod_i P(E_i |$

$H_t)$. Zvládne nekompletní vzory; problém nulových pravděpodobností (Laplaceovo vyhlazení). **SVM**: maximální okraj $2/\|w\|$, primární úloha $\min \frac{\langle w, w \rangle}{2}$ za podmínek $y_i(\langle w, x_i \rangle + b) \geq 1$; Kuhn–Tuckerovy podmínky jsou u konvexní úlohy s lineárními omezeními nutné i *postačující*; $\alpha_i > 0$ jen pro *podpůrné vektory* (Wolfeho duál). **Kernelový trik**: duál potřebuje jen skalární součiny $\Rightarrow K(x, z) = \langle \phi(x) \cdot \phi(z) \rangle$ a ϕ nikdy nevyčíslíme (Mercer). *Měkký okraj*: pomocné proměnné $\xi_i \geq 0$ v podmínkách a penalizace $C \sum_i \xi_i$ v účelové funkci; C řídí kompromis mezi šířkou okraje a chybami. Omezení: dvě třídy, reálný prostor, neinterpretovatelné. **Logistická regrese**: $\ln \frac{p}{1-p} = \beta^T x$, tedy $p = \sigma(z)$; učení maximální věrohodností (křížová entropie), $\sigma' = \sigma(1 - \sigma) \Rightarrow \Delta \beta_j = \eta \sum_i (y_i - \sigma(z_i)) x_{ij}$. **Diskriminační analýza**: $g_j(x)$ pro každou třídu, klasifikuje maximum; optimální $g_j \propto P(C_j | x)$; normální rozdělení $\rightarrow$ kvadratická funkce, při *shodných* kovariančních maticích *lineární* (stačí μ_j a S). **ELM**: náhodné parametry skrytých neuronů, výstupní váhy *jednou* pseudoinverzí $\beta = H^+ T$ (regularizace I/C); rychlé, bez lokálních minim. **Ensembley**: **bagging** snižuje *rozptyl* ($\sigma^2 \rightarrow \sigma^2/k$ pro i.i.d.), bootstrap obsahuje $\approx 63,2\%$ různých bodů ($1 - 1/e$), ideální komponenta je strom (nízké zkreslení, vysoký rozptyl); zkreslení nesníží. **Náhodné lesy** řeší korelaci komponent: rozptyl $\rho \sigma^2 + (1 - \rho) \sigma^2 / k$ — první člen na k nezávisí; náhodnost přes bootstrap a podmnožinu $m \approx \sqrt{\#\text{příznaků}}$ v každém uzlu. **AdaBoost** snižuje *zkreslení*: váhy chybně klasifikovaných rostou, $\alpha_t = \frac{1}{2} \ln \frac{1 - \epsilon_t}{\epsilon_t}$, běží *sekvenčně*, citlivý na šum.

Klastrová analýza

Metriky: Hammingova/Manhattan (L_1), euklidovská (L_2), Čebyševova (L_∞), Minkowského (L_q — ostatní jsou její speciální případy), **Mahalanobisova** $d_M^2 = (x_1 - x_2)^T S^{-1} (x_1 - x_2)$ pro veličiny s různým rozptylem. Před shlukováním *normalizovat*. Vzdálenost klastřů: nejbližší soused, nejvzdálenější soused, průměrná, centroidní. **k-means** (Lloyd): náhodné rozdělení $\rightarrow$ centroidy $\rightarrow$ přesuny $\rightarrow$ opakuj; cenu nikdy nezvýší, ale bez záruky aproximace $\Rightarrow$ **k-means++** (pravděpodobnost $\propto$ kvadrát vzdálenosti k nejbližšímu centroidu), Local-Search++. **k-medians** (Manhattan, medián po dimenzích, robustnější) vs. **k-medoids** (reprezentanti *z dat*, hill-climbing s výměnami, $O(knd)$ na iteraci, libovolný typ dat): **PAM** testuje všech $k(n - k)$ výměn ($O(kn^2d)$), **CLARA** vzorkuje (riziko špatného vzorku), **CLARANS** prohledává náhodně nad plnými daty (*MaxAttempt*, *MaxLocal*). **Hierarchické** zdola nahoru: každý vzor svůj klastř $\rightarrow$ slučuj dva nejbližší; výstup **dendrogram**, počet klastřů se volí až *řezem*. **CURE**: vzorek $\rightarrow p$ částí $\rightarrow$ nezávisle hierarchicky na k' $\rightarrow$ hierarchicky na k $\rightarrow$ přiřad zbytek. **LVQ** = shlukování *s učitelem* (vítězný vektor se přitáhne při souhlasu tříd, odtlačí při nesouhlasu, μ klesá jako $\mu(k-1)/(k+1)$). **Mřížkové** (MAFIA): p^d hyperkrychlí, prah hustoty τ , klastř = komponenty souvislosti grafu buněk. **DBSCAN**: *jádrový* bod ($\geq \tau$ bodů v radiu ϵ), *hraniční*, *šumový*; klastř = komponenty souvislosti jádrových bodů. Zvládne klastř *libovolného tvaru* a sám detekuje odlehle hodnoty.

Otázka 4. Metody pro extrakci charakteristických diskriminačních pravidel a měření jejich zajímavosti

Charakterizace vs. diskriminace

Charakterizace popisuje *cílovou třídu* — co je pro ni typické. **Diskriminace** ji *porovnává* s kontrastními třídami — čím se od nich odlišuje. Rozdíl je v otázce: *typičnost* $\neq$ *rozlišovací síla*. Vlastnost může být pro třídu typická (většina zákazníků jsou muži), a přesto bezcenná pro rozlišení (muži tvoří většinu i v ostatních třídách).

AOI — indukce řízená atributy

Postup *attribute-oriented induction*:

1. sběr relevantních dat dotazem (cílová, případně kontrastní třída);
2. přidání atributu **count** k záznamům;
3. pro každý atribut *odstranění* (má mnoho hodnot a neexistuje k němu koncepční hierarchie) nebo *generalizace* (nahrazení nadřazenou hodnotou podle hierarchie);
4. agregace shodných záznamů (součet **count**);
5. další generalizace, dokud relace není menší než prahová velikost T ;
6. prezentace výsledné generalizované relace.

Složitost $O(na)$ — *lineární* v počtu záznamů i atributů. Prahy: *attribute threshold* (kolik hodnot atributu se ještě snese) a *generalized relation threshold* T .

Koncepční hierarchie

Schématová (dána strukturou dat: ulice $\rightarrow$ město $\rightarrow$ stát), **seskupovací** (explicitní výčet skupin hodnot), **operační** (odvozená výpočtem: e-mail $\rightarrow$ doména), **pravidlová** (definovaná pravidly). Bez hierarchie lze atribut jen odstranit.

Dvě váhy

$$\text{t-weight} = \frac{\text{count}(q_a)}{\sum_i \text{count}(q_i)}$$

Typičnost *uvnitř* cílové třídy; součet t-weight přes všechny záznamy generalizované relace je 100 %. Slouží pro **charakteristická** pravidla — implikace „ $\Rightarrow$ “ ve směru *třída* $\Rightarrow$ *vlastnosti* (nutná podmínka).

$$\text{d-weight} = \frac{\text{count}(q_a \in C_{\text{target}})}{\sum_j \text{count}(q_a \in C_j)}$$

Rozlišovací síla vůči kontrastním třídám (jmenovatel je součet přes *všechny* třídy včetně cílové). Slouží pro **diskriminační** pravidla — „ $\Leftarrow$ “, tedy *vlastnosti* $\Rightarrow$ *třída* (postačující podmínka). **Popisné pravidlo** kombinuje obojí („ $\Leftrightarrow$ “) a uvádí obě váhy.

Interpretace

Umět spočítat obě váhy z tabulky a vysvětlit, proč vysoká t-weight neznámá vysokou d-weight: d-weight je nutné srovnávat s *apriorním* podílem cílové třídy. Je-li podíl třídy v datech 50 % a d-weight vlastnosti je také 50 %, vlastnost nerozlišuje vůbec.

Zajímavost znalosti

Objektivní míry (počítá stroj): t-weight a d-weight, support a confidence, **lift**, pokrytí, χ^2 , informační zisk, *jednoduchost* (krátká pravidla). **Subjektivní** míry (rozhoduje uživatel): **neočekávanost** (odporuje dosavadní představě) a **akceschopnost** (*actionability* — lze podle toho něco udělat). Objektivní míry umí systém spočítat sám, ale teprve subjektivní rozhodují, zda je výsledek *znalost*, nebo notorieta — stejné pravidlo může být pro jednoho uživatele objevem a pro druhého samozřejmostí.

Souvislosti

Charakterizace a diskriminace jsou *deskriptivní* úlohy (otázka 1); vstupem je tabulka po přípravě dat a diskretizaci (otázka 2) plus koncepční hierarchie, výstupem generalizovaná relace; zajímavost jako filtr nadprodukce pravidel navazuje na asociační pravidla (otázka 3) a na kritéria hodnocení znalostí (otázka 5).

Otázka 5. Reprezentace, vyhodnocování a vizualizace získaných znalostí

Formy reprezentace znalostí

IF-THEN pravidla — nejsrozumitelnější, lokální (každé pravidlo lze číst samostatně); **rozhodovací strom** — globální, čitelný do hloubky 4–5; **rozhodovací tabulka**; **matematická funkce** (SVM, sítě, regrese) — kompaktní, ale neinterpretovatelná; **prototypy/centroidy** (klastrování); **pravděpodobnostní model** (Bayes); **grafy a sítě**; **instance** (k -NN, CBR — „model“ jsou samotná data). Ke každé formě umět říct, z jaké metody vzniká a čím se za srozumitelnost platí.

Kritéria hodnocení metod

Prediktivní přesnost, efektivita (čas konstrukce i použití), robustnost (šum, chybějící hodnoty), škálovatelnost, interpretovatelnost, kompaktnost modelu. Volba metody je vždy kompromis mezi nimi — viz typ úlohy z otázky 1.

Odhad chyby

Holdout — rozdělení na trénovací a testovací množinu (velká data); *množiny se nesmí míchat*. **k -násobná křížová validace** — data na k částí, k modelů; běžné je 5 a 10; přesnost = průměr k přesností + interval spolehlivosti s $t_{N,k-1}$ (menší data). **Leave-one-out** — m -násobná CV pro velmi malá data. **Validační množina** — třetí část dat; na ní se ladí *parametry* algoritmu, aby testovací množina zůstala nezávislá.

Matice záměn a míry

TP , FN , FP , TN ; přesnost $p = \frac{TP}{TP+FP}$, úplnost $r = \frac{TP}{TP+FN}$, $F_1 = \frac{2pr}{p+r}$ (harmonický průměr — leží blíž k *menšímu* z obou čísel, proto netoleruje nulu ani v jedné míře). Umět vysvětlit, *proč accuracy nestačí* u nevyvážených dat: při 1 % pozitivních případů má triviální „nedělat nic“ 99 % přesnost.

ROC a AUC

$TPR = \frac{TP}{TP+FN}$ (senzitivita = recall pozitivní třídy) proti $FPR =$

$\frac{FP}{FP+TN}$; $TNR = \text{specifita} = 1 - FPR$. Křivka vede z (0,0) do (1,1), diagonála = náhodné hádání, levý horní roh = ideál. Konstrukce: vzory se seřadí podle skóre a postupně se posouvá práh (dělení na každém případě). **AUC** = 1 pro perfektní, 0,5 pro náhodný klasifikátor; je potřebná proto, že se ROC křivky dvou klasifikátorů mohou *křížit* — pak žádný není lepší ve všech prázích.

Skórování a lift

Místo třídy se přiřadí *odhad pravděpodobnosti* (u stromu confidence v listu); vzory se seřadí a rozdělí do příhrádek (decilů). **Lift křivka** porovnává zásah v příhradce s diagonálou náhodného výběru. Umět provést ekonomickou úvahu: kolik zásilek se vyplatí poslat, když známe cenu zásilky a výnos z reakce.

Tři roviny vyhodnocování

1. statistická kvalita modelu (přesnost, AUC) — objektivní;
2. zajímavost jednotlivých vzorů (lift, χ^2 , jednoduchost) — objektivní;
3. vyhodnocení uživatelem — subjektivní.

Čtyři kritéria zajímavosti znalosti: *srozumitelnost, platnost, užitečnost, novost*.

Vizualizace

Technika podle úlohy: histogram (rozdělení), box plot (odlehle hodnoty), scatter a SPLOM (vztahy dvojic), paralelní souřadnice (mnoho dimenzí), heatmapa (matice), dendrogram (hierarchie klastrů), projekce (PCA, t-SNE, UMAP), ROC a lift (kvalita modelu). **Tři role v KDD:** *explorace dat (Anscombeho kvartet — shodné statistiky, různé grafy), vizualizace modelu, prezentace výsledků*. Zásady (Tufta): nezakreslovat osami, poměr dat k inkoustu, barva podle typu dat (kvalitativní vs. sekvenční vs. divergující). Znat omezení: *t-SNE a UMAP zkreslují globální vzdálenosti* — vzdálenost mezi klastry v projekci nelze interpretovat.

Otázka 6. Modely pro analýzu sociálních sítí; míry centrality, detekce komunit

Co je SNA

Sociální vědy + analýza sítí + teorie grafů; zajímají ji *vztahy*, ne entity a jejich atributy. Reprezentace: obrázek, seznam hran, matice sousednosti (u orientovaných grafů nemusí být symetrická). **Ego síť** vs. „celá“ síť — **problém specifikace hranic**: žádná studovaná síť není celá.

Síla vazeb

Silné vs. slabé vazby; **síla slabých vazeb** (Granovetter 1973 — práci člověk najde přes slabé vazby, protože nesou nové informace). **Homofilie** (podobní se spojují), **tranzitivita** a **přemostění**; homofilie + tranzitivita → *kliky*. **Most** = hrana, jejíž odstranění rozpojí koncové uzly; **zkratkový most** = vzdálenost po odstranění vzroste nad 2. **Překryv sousedství** $O(i, j) = \frac{|N_i \cap N_j|}{|N_i \cup N_j| - 2}$ — čím větší, tím silnější vazba.

Čtyři míry centrality

- **stupňová** — kolik lidí uzel *přímo* dosáhne (lokální aktivita);
- **mezilehlá** — na kolika nejkratších cestách leží; kde se síť *rozpadne*, kdo kontroluje tok;
- **blízkostní** — převrácená průměrná délka nejkratších cest; rychlost *šíření*;
- **vlastní** — $Ax = \lambda x$, jen *největší* vlastní číslo dává nezáporný vektor; jak dobře je uzel spojen s *dobře propojenými*.

Umět interpretační tabulku a vysvětlit, proč nestačí jedna míra (dva průměrné uzly mohou být *společně* důležitější než jeden s nejvyšším stupněm). **Strukturní ekvivalence**: pozice lze vyměnit bez změny struktury sítě.

Koheze a vlastnosti reálných sítí

Reciprocita (jen orientované grafy), hustota $|E|/\binom{|V|}{2}$ (klika = 1), **klastrovací koeficient** $C_i = \frac{2|\{e_{jk}\}|}{k_i(k_i-1)}$ a jeho průměr, *průměr sítě* (*diameter*) = nejdelší nejkratší cesta, průměrná vzdálenost, excentricita. **Malý svět** = vysoké C + krátká průměrná cesta. **Šest vlastností reálných komplexních sítí**: efekt malého světa (Milgram, medián 6), tranzitivita/klastrování, *mocinné* rozdělení stupňů, odolnost (robustní k náhodnému, zranitelná cíleným odstraněním hubů), vzorce míchání (asortativní = homofilie), komunitní struktura. **Bezškálové sítě**: růst + **preferenční připojování** (rich-get-richer, Matoušův efekt); **centralizace** a struktura *jádro-periferie* (bow-tie).

Modely šíření vlivu

Společné rysy: orientovaný graf, aktivní/neaktivní uzly, *aktivovaný uzel nelze deaktivovat*. **LTM** (prahový): θ_v uniformně z $[0, 1]$, aktivace při $\sum_{\text{aktivní}} w_{u,v} \geq \theta_v \sum w_{u,v}$ — pohled *příjemce*. **ICM** (kaskádový): každý soused se aktivuje s pravděpodobností $p_{v,u}$, ale *jen jednou* — pohled *vysílajícího*. **Maximalizace vlivu** je NP-těžká, hladový přístup dává $\geq 63\%$ optima.

Vliv, korelace, homofilie

Test korelace: podíl hran mezi různými hodnotami atributu vs. $2p(1-p)$ (kuřáci: $14\% < 49\%$). Tři procesy, které korelaci vysvětlují: *homofilie*, *zmatení* (společné prostředí), *vliv*. Logistický model $\ln \frac{p(a)}{1-p(a)} = \alpha \ln(a+1) + \beta$, α = koeficient sociální korelace; **shuffle test** zpřehází *časové značky* — významná změna α je důkaz *vlivu*. **Test homofilie**: heterogenních hran významně méně než $2pq$

⇒ homofilie, významně více ⇒ *inverzní* homofilie (příklad: 5 z 18 vs. $2pq = 8$ z 18). **Výběr vs. sociální vliv**: výběr = charakteristiky řídí tvorbu vazeb, vliv = vazby formují *mutabilní* charakteristiky (imutabilní: pohlaví, rasa, věk). Rozlišit lze jen *longitudinálně* (obeznata: Christakis & Fowler). **Afiliční sítě** (bipartitní osoby × fokusy) a **tři uzávěry**: tranzitivní (společný přítel), *fokální* (společný fokus = výběr), *členský* (přítel už ve fokusu = vliv); **bázový model** $T_{\text{base}}(k) = 1 - (1-p)^k$, empiricky klesající výnosy. **Schellingův model**: agenti dvou typů, spokojeni při $\geq t$ sousedech téhož typu ⇒ *samovolná segregace* z lokální homofilie. **Strukturní balance**: balancované trojúhelníky jsou $+++$ a $+-$; *věta o bilanci* — úplný balancovaný graf znamená všichni přátelé, nebo dvě skupiny vnitřních přátel a vzájemných nepřátel; *slabá balance* (zakázáno jen $+-$) ⇒ libovolný počet skupin.

Authority: HITS a PageRank

HITS — dotazově závislý; kořenová množina $S \rightarrow$ báze B ; $a = L^T h$, $h = La$, mocinná iterace s *nutnou normalizací*; $a_k = (L^T L)^{k-1} a_0$ ($L^T L$ = ko-citační matice). Slabiny: spamovatelnost, drift tématu, náklady v době dotazu. **PageRank** — dotazově nezávislý, $P(i) = \sum_{(j,i) \in E} P(j)/O_j$, *normalizaci nepotřebuje* (celkový PageRank je konstantní). Problém „pomalého úniku“ ⇒ tlumivý faktor d (0,85): $P(i) = (1-d) + d \sum P(j)/O_j$. Markovský řetězec potřebuje matici *stochastickou, ireducibilní a aperiodickou* — webový graf nesplňuje ani jednu: stochasticitu kazí *visící stránky* (nulový řádek — řeší se zvlášť: odstranit, nebo dát řádek $1/n$), ireducibilitu a aperiodicitu spraví *jediná* úprava (odkaz odkudkoli kamkoli s malou pravděpodobností).

Detekce komunit

Definice komunity je *subjektivní*; explicitní vs. implicitní skupiny. **Řezy**: minimální řez dává nevyvážené skupiny, s vahami a *balancí* je NP-těžký ⇒ *poměrový* a *normalizovaný* řez (dělení $|C_i|$, resp. $\text{vol}(C_i)$). **Girvanové-Newman** — divizivní, odstraňuje hrany s nejvyšší *mezilehlostí*, $O(m^2 n)$; počet komunit podle maxima **modularity** $Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j)$, $Q \in [-1, 1]$, smysluplné komunity $Q \geq 0,3$. **Louvain** — hladová aglomerativní maximalizace modularity ve dvou fázích (lokální přesuny → supergraf), $O(n \log n)$; nevýhody: citlivost na pořadí, *nesouvislé komunity*, lokální optima. **Leiden** přidává fázi *upřesnění rozdělení*. **Čtyři kategorie metod**: *uzlově orientované* (kliky — NP-těžké, **CPM** pro *překrývající se* komunity, k -klika/klub/klan, k -jádro a k -plex), *skupinově orientované* (γ -husté kvazikliky), *síťově orientované* (podobnost vrcholů + k -means, MDS, blokové modely, spektrální shlukování přes laplacián s *nejmenšími* vlastními čísly, maximalizace modularity s *největšími* — vše jako maticová faktorizace $X \approx S \Sigma S^T$), *hierarchicky orientované* (divizivní GN, aglomerativní Louvain). **Tematické komunity** $K = (T, M)$ se mohou *překrývat*; *bipartitní jádra* (vějíře = huby, středy = authority).

Predikce vazeb

Obsahové míry (homofilie) vs. strukturní (tranzitivní uzávěry — silnější). *Společní sousedé* $|S_i \cap S_j|$ (ignoruje stupně), *Jaccard* $\frac{|S_i \cap S_j|}{|S_i \cup S_j|}$, *Adamic-Adar* $\sum_k \frac{1}{\log |S_k|}$ (váha klesá se stupněm společného souseda).

Katzova míra $K_{ij} = \sum_t \beta^t W_{ij}^{(t)}$, maticově $K = (I - \beta A)^{-1} - I$ (pro dostatečně malé β) — pro *řídke* sítě s málo společnými sousedy. **Klasifikační pojetí**: pozitivně-neoznačovaná úloha, vzorek negativ, logistická regrese; klasifikátor se sám naučí relevanci příznaků a zvládne *asymetrické* příznaky u orientovaných sítí.

Otázka 7. Praktické využití technik pro dobývání znalostí a analýzu sociálních sítí

Jak odpovídat

Ke každé aplikaci umět říct **trojici**: *typ úlohy* (deskriptivní / prediktivní, s učitelem / bez učitele), *použitá metoda*, *způsob vyhodnocení*. Zkoušející neověřuje výčet aplikací, ale schopnost přiřadit k úloze metodu a metriku.

Vlajkové aplikace dobývání znalostí

- **Analýza nákupního košíku** — asociační pravidla; vyhodnocení supportem, confidence a liftem; pozor na nadprodukcii pravidel.
- **Detekce podvodů** (příklad zdravotní pojišťovny) — stroj *zaostřuje* pozornost experta, nenahrazuje jej; nevyvážená data, hodnotí se lift a náklady chyb.
- **Kreditní skórování** — rozhodovací stromy a Bayes; klíčový požadavek *srozumitelnosti* (rozhodnutí je nutné umět odůvodnit žadateli i regulátorovi).
- **Segmentace zákazníků** — klastrování; centroid = typický zákazník; vyhodnocení interpretovatelností segmentů, ne přesností.
- **Churn a cílený marketing** — klasifikace na nevyvážených datech $\Rightarrow$ ROC/AUC a *lift*; ekonomická úvaha o počtu kontaktovaných zákazníků.
- **Klasifikace textu** — SVM (vysoká dimenze, řídká data).
- **Predikce časových řad** — posuvné okno (převod na tabulku objekty $\times$ atributy).
- **Web usage mining** — sekvenční vzory nad logy.

Vlajkové aplikace SNA

- **Klíčoví hráči v kriminálních a teroristických sítích** — míry centrality (mezilehlá pro spojky, vlastní pro vliv).
- **Doporučování přátel** — predikce vazeb (společní sousedé, Adamic–Adar).

- **Optimalizace komunikačních sítí** — koheze, úzká hrdla, mezilehlost.
- **Epidemiologie** (Rockdale County 1996) — struktura kontaktní sítě vysvětlí šíření lépe než počet kontaktů.
- **Vakcinace cílená na huby** — přímý důsledek vlastností bezškálových sítí.
- **Marketing a kaskádové finanční krachy** — modely šíření vlivu (LTM, ICM).
- **Segmentace zákazníků operátora** podle jazykových komunit — Louvain nad sítí volání (2 mil. zákazníků; ukázka škálovatelnosti).

Klíčová vlastnost SF sítí pro praxi

Odolnost proti *náhodným* poruchám (sít vydrží až 80 % odstraněných uzlů) vs. zranitelnost *cíleným* útokem (stačí 5–15 % hubů). Z toho plyne jak strategie vakcinace a ochrany infrastruktury, tak nemožnost vymýtit internetové viry běžnými prostředky.

Nasazení není konec

Monitoring driftu (rozdělení dat se v čase mění, model stárne), *zpětná vazba modelu do dat* (doporučení ovlivní chování, které se pak učí znovu), **soukromí** (i anonymizovaný graf lze deanonymizovat porovnáním struktury), **spravedlnost** (chráněný atribut lze rekonstruovat z ostatních, takže jeho vynechání nestačí), právní rámec — **GDPR čl. 22** (automatizované rozhodování a právo na vysvětlení) a **AI Act**.

Vazby na ostatní otázky

Volba metody vychází z typu úlohy (otázka 1), kvalita výsledku stojí na přípravě dat (otázka 2), metriky a ROC/lift pocházejí z otázky 5, komunity a centrality z otázky 6.