



František Mráz, KSVI MFF UK

EVOLUČNÁ ROBOTIKA

2. ČASŤ

EVOLUČNÉ A NEURÓNOVÉ TECHNIKY



- **Základné okruhy**
 - ◆ **evolučné algoritmy – genetické algoritmy**
 - ◆ **neurónové siete**
 - ◆ **kombinácie evolučných algoritmov a neurónových sietí**
 - ◆ **genetické programovanie**

- **Evolúcia riadiacich systémov pre roboty už bola aplikovaná na**
 - ◆ riadenie neurónovými sieťami
 - ◆ parametre pevného riadiaceho programu
 - ◆ samotný počítačový program



EVOLUČNÉ ALGORITMY

4

HILLCLIMBER - GRADIENTNÝ ALGORITMUS

8

JEDNODUCHÝ GENETICKÝ ALGORITMUS

16

SCHÉMY

25

VYLEPŠENIA GENETICKÝCH ALGORITMOV

32



EVOLUČNÉ ALGORITMY

Evolučné algoritmy

Genetické algoritmy (GA)

- ⊗ Genetické algoritmy – Holland 60. roky 20. stor.
- **Populácia** umelých chromozómov sa cyklicky podrobuje
 - ♦ selektívnej reprodukcií preferujúcej výkonnejších jedincov a
 - ♦ náhodným zmenám
- **Umelý chromozóm** (genotyp) = reťazec symbolov kódujúci vlastnosti jedinca (fenotyp)
 - ♦ napr. binárna hodnota premennej alebo postupnosť hodnôt premenných
 - ♦ mnoho typov kódovaní
 - ♦ binárne, Grayov kód, reálne hodnoty
 - ♦ abecedy – napr. binárna, ternárna, ...


GA – fitness funkcia

- **Fitness funkcia (účelová, cieľová funkcia)** – kritérium výkonnosti, zobrazenie: genotyp $\rightarrow$ reálne (celé) číslo
 - ♦ čím vyššia hodnota, tým je jedinec lepší

$$\Phi: \text{genotyp} \rightarrow R$$

populácia

fitness



Evolučné algoritmy

- vytvor populáciu N náhodne vygenerovaných chromozómov
 $x_1, x_2, \dots, x_N$
- opakuj
 - ◆ dekóduj všetky chromozómy a spočítaj ich fitness $f_i = \Phi(x_i)$
 - ◆ vytvor novú populáciu
- skonči, keď sa objaví hľadaný jedinec, alebo fitness najlepšieho nerastie



HILLCLIMBER - GRADIENTNÝ ALGORITMUS

Hillclimber – gradientný algoritmus

- vytvor populáciu N náhodne vygenerovaných chromozómov

$x_1, x_2, \dots, x_N$

$N = 1$

- opakuj

- ◆ dekóduj všetky chromozómy a spočítaj ich fitness $f_i = \Phi(x_i)$

- ◆ vytvor novú populáciu

Zmutuj chromozóm a
nahrad' ním starý
chromozóm, ak má
lepšiu fitness

- skonči, keď sa objaví hľadaný jedinec, alebo fitness najlepšieho nerastie

Hillclimber

príklad

- Chromozóm je bitový vektor dĺžky n

- ◆ $[0\ 1\ 1\ 0\ 1\ 0\ 0\ 1\ 0\ 1]$

- Fitness je súčet prvkov vektora

$$\Phi(v) = \sum_{i=1}^n v_i$$

Generácia 0:

$[0\ 1\ 1\ 0\ 1\ 0\ 0\ 1\ 0\ 1]$

- ◆ Mutuj – každú pozíciu s (malou) pravdepodobnosťou μ

$[1\ 1\ 1\ 0\ 1\ 0\ 0\ 1\ 0\ 1]$

$$\Phi([0\ 1\ 1\ 0\ 1\ 0\ 0\ 1\ 0\ 1]) = 5$$

$$\Phi([1\ 1\ 1\ 0\ 1\ 0\ 0\ 1\ 0\ 1]) = 6$$

Hillclimber

príklad

Generácia 0:

[0 1 1 0 1 0 0 1 0 1]

♦ Mutuj

[1 1 1 0 1 0 0 1 0 1]

♦ Porovnaj fitness

$$\Phi([0 1 1 0 1 0 0 1 0 1]) = 5$$

$$\Phi([1 1 1 0 1 0 0 1 0 1]) = 6$$

Generácia 1:

[1 1 1 0 1 0 0 1 0 1]

Koľko generácií bude trvať, než sa nájde optimálny jedinec?

Hillclimber

príklad

Koľko generácií bude trvať, než sa nájde optimálny jedinec?


- Počiatočný chromozóm dĺžky n má očakávaný počet jedničiek $\frac{n}{2}$
- Nech má chromozóm k jedničiek. Aká je pravdepodobnosť, že sa počet jedničiek zvýši z k na $k + 1$?

- Horný odhad očakávaného počtu generácií na dosiahnutie optima

$$\sum_{k=\frac{n}{2}}^n \left\lceil \frac{1}{p_k(\mu)} \right\rceil$$


Hillclimber – vylepšenia fitness krajina

- Nájde iba lokálne maximum



Hillclimber – vylepšenia fitness krajina

- Nájde iba lokálne maximum
- Občas musíme povoliť zhoršenie fitness
 - ◆ S nenulovou pravdepodobnosťou
 - ◆ „riskantné“ kroky skôr na začiatku, neskôr už prevažne iba zlepšujúce kroky
- Reštarty – začať z rôznych pozícií



Simulované žíhanie



- Veľkosť kroku i smer závisí na teplote, ktorá sa postupne znižuje
- Pravdepodobnosť prijatia zhoršenia fitness sa s časom znižuje
- Na začiatku sú kroky skoro náhodné
- Po „ochladení“ takmer deterministické



JEDNODUCHÝ GENETICKÝ ALGORITMUS

Genetické algoritmy


- **Jednoduchý genetický algoritmus** (Goldberg 1989)
 - ♦ vytvor populáciu N náhodne vygenerovaných chromozómov
 $P(1) := \{x_1, x_2, \dots, x_N\};$
 $t = 1$
 - ♦ opakuj
 - ♦ dekóduj všetky chromozómy a spočítaj ich fitness $f_i = \Phi(x_i)$
 - ♦ vytvor novú populáciu $P(t + 1)$ selektívnou reprodukciou
 - ♦ rekombinuj chromozómy – kríženie
 - ♦ mutuj chromozómy
 - ♦ $t := t + 1$
 - ♦ skonči, keď sa objaví hľadaný jedinec, alebo fitness najlepšieho nerastie

Jednoduchá selekcia

- Zo starej populácie vytvárame novú kopírovaním chromozómov tak, že čím lepší jedinec, tým viacej jeho kópií sa môže objaviť v novej populácii
- reprodukcia **ruletou**:
 - ◆ každý jedinec dostane na kole rulety priehradku veľkosti p_i úmernej hodnote jeho fitness funkcie – to bude pravdepodobnosť, že bude reprodukováný

$$p_i = \frac{f_i}{\sum_{j=1}^n f_j}$$

- ◆ ruletou sa otočí N krát



$$p_1 = 0.25$$

$$p_2 = 0.1$$

Varianty selekcie 1

■ Problémy jednoduchkej selekcie

a) keď všetci jedinci majú podobnú fitness

náhodné prehládávanie s genetickým posunom

b) keď jeden až dvaja jedinci majú fitness o mnoho vyššiu než zvyšok populácie


takmer všetci jedinci v novej generácii budú kópiou toho istého jedinca, predčasná konvergencia

■ Riešenie:

1. **škálovanie [scaling]** (typicky lineárna transformácia)

pre a) zväčšiť rozdiely, pre b) zmenšiť

2. **selekcia podľa poradia [rank based]** – jedinci sa zoradia podľa fitness a pravdepodobnosť reprodukcie je úmerná poradiu jedinca, nie jeho fitness




Varianty selekcie 2

3. **S orezávaním [truncation]** – jedincov usporiadame podľa veľkosti fitness, M najlepších jedincov skopírujeme O krát tak, aby $N = M \times O$
 4. **Turnajom [tournament]** – náhodne sa vyberú 2 jedinci a vygeneruje sa náhodné číslo $r \in \langle 0,1 \rangle$, ak je $r < T$, kde $T \in \langle 0,1 \rangle$ je preddefinovaný parameter, tak bude skopírovaný jedinec s vyššou fitness inak ten druhý
- Pri ďalších genetických operáciách sa môže doteraz najlepší jedinec stratiť. Pomoc: **elitizmus [elitism]** – s najlepších jedincov je bez zmeny skopírovaných do novej generácie


Kríženie

- Jedinci sú náhodne spárovaní a každý pár je s danou pravdepodobnosťou skrížený

Jednobodové
kríženie



Viacbodové
kríženie



Mutácia



- Jedinci sú náhodne menení
 - ◆ Uniformná mutácia – každý znak každého jedinca je s pravdepodobnosťou p_m zamenený náhodným znakom

Nedeterminizmus





- celý GA je nedeterministický, používa náhodné veličiny
- typicky sa sleduje priemerná a maximálna fitness, GA sa zastaví, keď je dosiahnutá dopredu zadaná hodnota fitness, alebo zadaný počet generácií, alebo sa fitness v priebehu niekoľkých generácií nemení.
- celý GA sa spúšťa opakovane s rovnakými alebo s pozmenenými parametrami
- výsledkom je najlepší jedinec vybraný z finálnych generácií zo všetkých behov GA

Fitness krajina

– „fitness landscape“

- Fitness si môžeme predstaviť ako mnohorozmernú nadrovinu udávajúcu hodnotu fitness vo všetkých možných hodnotách genotypu – fitness krajina s kopcami a údoliami; pre chromozóm dĺžky 1 je to funkcia jednej premennej





SCHÉMY

Schémy

- **Chromozóm** = reťazec dĺžky m nad k -prvkovou abecedou Σ
- **Schéma** = reťazec dĺžky m nad $(k + 1)$ -prvkovou abecedou $\Sigma \cup \{*\}$
 - ♦ schéma s r hviezdikami reprezentuje k^r reťazcov
 - ♦ každý reťazec dĺžky m je reprezentovaný 2^m schémami
 - ♦ **rád** schémy S : $o(S)$ = počet pevných symbolov (rôznych od $*$)
 - ♦ (definičná) **dĺžka** schémy S : $\delta(S)$ = vzdialenosť medzi prvou a poslednou pevnou pozíciou v schéme
 - ♦ Príklad:

	rád $o(S)$	definičná dĺžka $\delta(S)$
$S_1 = (**001*110)$	6	6
$S_2 = (****00**0*)$	3	4
$S_3 = (11101**001)$	8	9

Schémy

- N = počet jedincov v populácii
- $\xi(S, t)$ = počet reťazcov v populácii $P(t)$, ktoré sú reprezentované schémou S
- $\Phi(S, t)$ = fitness schémy v čase t = priemerná fitness reťazcov reprezentovaných schémou S

$$\Phi(S, t) = \frac{1}{\xi(S, t)} \sum_{j=1}^{\xi(S, t)} \Phi(x_{i_j})$$

kde $\{x_{i_1}, \dots, x_{i_{\xi(S, t)}}\}$ sú reťazce z $P(t)$ pokryté schémou S

- pravdepodobnosť, že $x \in P(t)$ bude vybrané selekciou do $P(t + 1)$ je $p = \frac{\Phi(x)}{F(t)}$, kde $F(t) = \sum_{j=1}^N \Phi(x_i)$ je fitness populácie

Schémy a selekcia

- Po selekcii očakávame $\xi(S, t + 1)$ reťazcov pokrytých schémou S

tol'kokrát sa
„losuje“

časť rulety
pokrytá schémou S

$$\xi(S, t + 1) = \text{pop_vel} \cdot \frac{\xi(S, t) \cdot \Phi(S, t)}{F(t)} = \xi(S, t) \cdot \frac{\Phi(S, t)}{\bar{F}(t)}$$

kde $\bar{F}(t)$ je priemerná fitness populácie $P(t)$

- teda „nadpriemerná“ schéma pokryje v nasledujúcej generácii viacej reťazcov – ak by platilo pre prvých t generácií

$$\Phi(S, t) \geq \bar{F}(t) \cdot (1 + \varepsilon) \text{ pre nejaké } \varepsilon > 0$$

- tak $\xi(S, t) \geq \xi(S, 0) \cdot (1 + \varepsilon)^t$ tj. počet reťazcov reprezentovaných „nadpriemernou“ schémou by rástol geometrickou postupnosťou

Schémy a kríženie

- Pravdepodobnosť, že schéma bude zmenená (zničená) krížením

$$\frac{\delta(S)}{m-1}$$



- teda pravdepodobnosť zachovania príslušnosti k schéme bude

$$p_z \geq 1 - p_k \cdot \frac{\delta(S)}{m-1}$$

◆ pretože:

- ◆ kríženie nastáva iba s pravdepodobnosťou p_k
- ◆ aj keď je bod kríženia "vo vnútri schémy", tak schéma môže prežiť

- teda pravdepodobnosť zachovania schémy po selekcii a krížení je

$$\xi(S, t+1) \geq \xi(S, t) \cdot \frac{\Phi(S, t)}{\bar{F}(t)} \cdot \left(1 - p_k \frac{\delta(S)}{m-1}\right)$$

Schémy a mutácia

- Ak mutácia zmení v reťazci jeden z pevných symbolov schémy, tak reťazec nebude schémou pokrytý; pravdepodobnosť, že mutácia nezmení žiaden z pevných symbolov schémy je

$$(1 - p_m)^{o(S)} \approx 1 - o(S) \cdot p_m \text{ pretože } p_m \ll 1$$

- selekcia + kríženie + mutácia:

$$\begin{aligned} \xi(S, t + 1) &\geq \xi(S, t) \cdot \frac{\Phi(S, t)}{\bar{F}(t)} \cdot \left(1 - p_k \frac{\delta(S)}{m - 1}\right) \cdot [1 - o(S) \cdot p_m] \\ &\geq \xi(S, t) \cdot \frac{\Phi(S, t)}{\bar{F}(t)} \cdot \left[1 - p_k \frac{\delta(S)}{m - 1} - o(S) \cdot p_m\right] \end{aligned}$$

- schéma S "prežíva" dobre, ak je krátka ($\delta(S)$) a malého rádu ($o(S)$)

Veta o schémach

- **Veta o schémach (Schema Theorem):** Schémy, ktoré sú krátke, majú nízky rád a sú nadpriemerné, pokrývajú exponenciálne rastúci počet reťazcov v po sebe idúcich generáciách genetického algoritmu.
- **Hypotéza o stavebných blokoch (Building block Hypothesis):** Genetický algoritmus hľadá riešenie blízke optimu reťazením krátkych schém s nízkym rádom nazývaných stavebné bloky.
 - ◆ nie je to veta!
 - ◆ niekedy stavebné bloky znemožnia nájdenie optima
 - ◆ Holland spočítal, že za určitých podmienok môže genetický algoritmus v jednom kroku spracovať až N^3 krátkych schém, ale funguje to, iba ak je možné „dobré“ vlastnosti kódovať takýmito schémami – variácie GA



VYLEPŠENIA GENETICKÝCH ALGORITMOV

Sú GA dobrou simuláciou biologickej evolúcie?

- Evolúcia nekončí a nezačína vždy od nuly (bootstrapping)
 - ◆ **SAGA** – Species Adaptation Genetic Algorithm: premenlivá dĺžka genotypu, značne skonvergovaná populácia sa mení postupnými mutáciami, nie krížením
 - ◆ **Neutrálne siete** – drobné náhodné zmeny v genotype nemusia meniť fitness, ale môžu populáciu posunúť inam
 - ◆ fitness krajina môže byť sústava prepojených neutrálnych sietí s rôzne vysokými hodnotami fitness
 - ◆ „prázdne“ úseky DNA
 - ◆ Napr. “**Analog Genetic Encoding**” – genetický kód popisuje pravidlá prepojenia neurónovej siete

Sú GA dobrou simuláciou biologickej evolúcie?



- Ďalšie variácie GA – spojenie s „dospievaním“ a učením – fitness sa mení v priebehu života jedinca
- **ČO SA NEMENÍ:** a) genetická reprezentácia jedinca
b) autonómna interakcia s prostredím

Vylepšenia genetických algoritmov

■ Delenie na druhy

- ◆ na genotype sa definuje vzdialenosť = miera podobnosti jedincov
- ◆ 1 druh = množina podobných jedincov
- ◆ Špeciálny typ kríženia – iba v rámci druhu (predpoklad, že krížením podobných jedincov vznikne podobný, teda funkčný jedinec)
- ◆ Ochrana nových druhov
 - ◆ Po obmedzenú dobu od vzniku nového druhu jedinci pri selekcii sú vyberaní iba na základe fitness pre jedincov ich vlastného druhu

■ Premennivá veľkosť populácie

- ◆ Optimálna veľkosť populácie sa ťažko určuje
- ◆ Starnutie
 - ◆ pri vzniku nového jedinca je mu (podľa jeho fitness) nastavený max. vek = max. počet generácií, než bude jedinec z populácie vyradený – **veľmi ťažko sa nastavujú parametre!**

Vylepšenia genetických algoritmov

■ Kódovanie

- ◆ Konečná doména
 - ◆ pevný počet bitov – čo ak počet prvkov domény nie je mocnina 2?
- ◆ Celé čísla
 - ◆ binárne
 - ◆ Grayov kód
- ◆ Reálne čísla
 - ◆ s obmedzeným rozsahom – binárne kódovanie rovnomerne rozdelených deliacich bodov
 - ◆ čísla s pevným počtom desatinných miest
 - ◆ čísla s plávajúcou desatinnou čiarkou – ako robiť kríženie a mutácie?