

Evolučná robotika

5. časť



Vizuálna navigácia
Re-adaptácia
Reaktívna inteligencia

František Mráz, KSVI MFF UK

VIZUÁLNA NAVIGÁCIA




■ Ciele

- ◆ Problém Bootstrappingu
- ◆ Zrýchlenie evolúcie
 - ◆ Simulovaná
 - ◆ Doladenie na reálnom robotovi



VIZUÁLNA NAVIGÁCIA

- Zrak je jeden z najdôležitejších zmyslov
- zložitosť spracovania
 - ◆ Klasicky – predspracovanie, segmentácia, hľadanie vzorov, ...
 - ◆ **Evolučne – vývoj riadenia zviazaný s vývojom spracovania obrazu**
- hardware
- Harvey, 1994 – portálový robot (“*gantry robot*”)
 - ◆ kamera zavesená z portálového žeriavu riadeného počítačom
 - ◆ obraz cez naklonené zrkadlo + 4 dotykové senzory
 - ◆ 64 x 64 bodový monochromatický obraz, 50 Hz
 - ◆ fyzická evolúcia
 - ◆ vývoj SAGA – Species Adaptation Genetic Algorithm – premenná dĺžka genotypu, do značnej miery geneticky skonvergovaná populácia
 - ◆ redukovaný vizuálny vstup – recepčné polia




Portálový robot



Portálový robot




Portálový robot



Recepčné polia

Vizuálna navigácia – senzory a riadenie



Vizuálna navigácia – evolúcia riadenia

■ Súčasná evolúcia

◆ Recepčných polí

- ◆ polomer a poloha vzhľadom k stredu (polomer, vzdialenosť od stredu, uhol)
- ◆ z celého poľa za rovnomerne vyberie 25 pixelov, ich jas sa spriemeruje a prevedie na 4-bitové číslo

◆ Neurónovej siete

- ◆ 7 vstupov
- ◆ 4 výstupy – signál do jedného motora je rozdiel dvoch výstupov
- ◆ počet skrytých neurónov premenlivý
- ◆ neuróny majú oddelené excitačné a inhibičné kanály (viz. výstup)

■ Riešené úlohy

- ◆ Vyhýbanie sa prekážkam
- ◆ Sledovanie pohyblivých cieľov
- ◆ *Rozlišovanie objektov*

Vizuálna navigácia - bootstrapping




- **Úloha: Nájsť biely trojuholník a zostať pri ňom, vyhýbať sa bielemu obdĺžniku**
- Premennivé svetelné podmienky
- **Bootstrapping –**
 - ◆ Priama evolúcia neúspešná
 - ◆ Evolúcia navigácie v 3 štádiách s rôznymi fitness funkciami i prostredím

Štádium 1

- Jedna dlhá stena celá biela (150 x 22 cm)

- Fitness

$$\Phi_1 = \sum_{i=1}^{20} Y_i$$



- Y_i – vzdialenosť od steny protiľahlej k cieľu meraná 20-krát v priebehu jedného experimentu (25 s)
- každý jedinec testovaný 4-krát z toho istého rohu, ale náhodne otočený
- inicializácia počiatkovej konfigurácie
 - ◆ náhodne sa generovali jedinci a vybraný bol jeden so „zaujímavým“ chovaním a ten sa naklonoval
- asi po 10 generáciách bol nájdený jedinec, ktorý sa najprv rozhliadol okolo seba a potom sa vydal k cieľovej stene


Štádium 2

- Cieľ – 22 cm pruh v 2/3 tej istej steny

- Fitness

$$\Phi_2 = \sum_{i=1}^{20} (-d_i)$$


- d_i – vzdialenosť robota od stredu pruhu
- pokračuje z poslednej generácie Štádia 1
- po 6 generáciách sa našiel jedinec, ktorý našiel cieľ



Štádium 3

- Ciele: rovnoramenný trojuholník a obdĺžnik, oba 21 cm široké, 29.5 cm vysoké
- robot začína v 4 rôznych polohách s náhodnou orientáciou pri protiľahlej stene
- fitness

$$\Phi_3 = \sum_{i=1}^{20} [\beta(D_{1i} - d_{1i}) - \sigma(D_{2i} - d_{2i})]$$



- D_{1i} (D_{2i}) – vzdialenosť trojuholníka (obdĺžnika) od rohu portálu; konštanty
- d_{1i} (d_{2i}) – vzdialenosť robota od trojuholníka (obdĺžnika)
- $\beta, \sigma > 0$ sú váhy

Zjednodušte Φ_3

Výsledok



- Extrémne minimalistický systém
 - ◆ 2-3 pixely stačia na spoľahlivé riešenie úlohy
- Hlavná nevýhoda:
 - ◆ Inkrementálna evolúcia – musí ju navrhnúť experimentátor

RE-ADAPTÁCIA



- ako modifikovať riadiaci systém pri zmenách vonkajších podmienok
- 2 úrovne
 - ◆ jedinec – využije robustnosť a generalizáciu NS
 - ◆ populácia – využije sa rôznorodosť jedincov v populácii
 - ◆ pri zmene podmienok sa dokáže rýchlo adaptovať (napr. vizuálna navigácia – tam sa ešte využívali zásahy človeka, zmeny fitness).
 - ◆ Adaptácia pri zmene robota – s pevnou fitness
 - ◆ adaptácia na fyzického robota po simulácii evolúcie – s pevnou fitness


Adaptácia pri zmene robota

- Riadiaci systém pre jednoduchú navigáciu Khepery v bludisku
 - ◆ adaptovaný na prostredie i na morfológiu a senzory Khepery
- Ale Khepera sa nehodí do terénu a je príliš slabá $\Rightarrow$ riadiaci systém bol prenesený na Koalu; zmena senzorov a motorov je tiež zmena prostredia; Koala sa podobá Khepere:
 - ◆ 6 kôl, ale prostredné sú nižšie uložené
 - ◆ infra senzory majú väčší dosah (50 cm), ale má ich 16
 - ◆ software je totožné
- Koalu umiestnili do zväčšeného bludiska pre Kheperu; ako vstup vzali iba 8 zo 16 infra senzorov




Zmena robota

- 106 generácií na Kheperu
- ďalej do 150. generácie na Koale



- po prenose na Koalu fitness poklesla, ale rýchle sa vrátila na úroveň poslednej generácie pre Kheperu



Simulácia → realita

■ Výhody simulácie

- ◆ rôzne experimentálne podmienky
- ◆ rôzne fitness funkcie
- ◆ 100 gen. 1 hod., na reálnom robote 66 hod.


} dá sa toho vyskúšať
viac, než sa prejde na
reálneho robota

■ prechod zo simulácie do reality je tiež krok inkrementálnej evolúcie

■ Pr. Khepera v obdĺžnikovom bludisku s 3 valcami

- ◆ 100 jedincov v populácii
- ◆ 200 generácií simulovaných
- ◆ následne na fyzickom robote
- ◆ 3 experimenty

1. Bez šumu
2. Náhodný šum $\langle 0; 0,4 \rangle$ na senzoroch
3. Konzervatívny šum – senzory dávajú hodnoty akoby bol robot posunutý náhodne v rozsahu $\langle -30; 30 \rangle$ mm pre x i pre y



Simulácia → realita



■ Prechod na reálneho robota

1. Bez šumu – veľká zmena prostredia – mierny pokles fitness, ale po niekoľkých generáciách návrat na úroveň najlepšieho simulovaného jedinca
2. Náhodný šum – realistickejšia simulácia, ale výsledok podobný variantu bez šumu
3. Konzervatívny šum – žiaden pokles, iba vylepšenie, ešte bližšie realite, pretože
 - simuluje aj odchýlky senzorov spôsobené chybami v motorickom systéme
 - náhodný šum je na susedných senzoroach nezávislý
 - vonkajšie príčiny odchýlok ovplyvňujú pravdepodobne všetky senzory podobne

Záver



- Umelá evolúcia dokáže vytvoriť riadiaci systém porovnateľný s ručným kódom
- získaný systém je schopný ďalšieho vývinu
- pre zložitejšie úlohy je vhodné použiť **inkrementálny** postup riadený užívateľom, prípadne najprv simuláciu a **doladenie** na reálnom robote
- evolúcia robotov je kontinuálny proces s otvoreným koncom

REAKTÍVNA INTELIGENCIA

- **Reaktívne systémy:** senzory sú priamo prepojené na motory a na rovnaký stav senzorov systém reaguje rovnako. Ak má systém stavy, tak iba pomocné na určenie motorických akcií
- **Vtelené systémy (embodied):** majú telo, získavajú vstupy zo senzorov v tele a produkujú výstupy, ktoré riadia motorické akcie tela
- **Situačné systémy (situational):** nachádzajú sa v externom prostredí a môžu interagovať s týmto prostredím
- O mnohých úlohách sa predpokladá, že na ich riešenie je nutná interná reprezentácia:
 - ◆ klasická umelá inteligencia – explicitná reprezentácia externého sveta
 - ◆ vtelené situačné systémy – čiastočný model sveta, iba tie aspekty, ktoré sú potrebné pre agentov, aby dosiahli svoje ciele
- vtelené a situačné systémy napriek intuícii dokážu riešiť aj zložité úlohy bez vnútorných stavov a bez vnútornej reprezentácie – využívajú koordináciu vnímania a akcií nazývanú **senzorovo-motorická koordinácia**.


REAKTÍVNA INTELIGENCIA – Senzorovo-motorická koordinácia

- **Senzorovo-motorická koordinácia** = schopnosť agenta využiť interakciu s prostredím – agent môže čiastočne ovplyvniť senzorové signály tým, že vykoná nejakú akciu, ktorá zmení jeho polohu, alebo zmení okolité prostredie.
- **Využitie:**
 1. Vyberať a využívať senzorické vzory, ktoré sú jednoznačné
 2. Využívať také senzorické vzory, že skupiny vzorov, ktoré vyžadujú rôzne reakcie, sa neprekrývajú (alebo prekrývajú iba slabo)
 3. Využívať emergentné správania, ktoré vzniknú iba interakciou agenta s prostredím
- **ALE: existujú úlohy, na ktoré senzorovo-motorická koordinácia nestačí.**

Problém nejednoznačnosti vnemov

- *Dva (alebo viaceré) objekty generujú tie isté senzorové vnemy, ale vyžadujú rôzne odozvy.*
- Riešenie: vykonať akcie tak, aby sa našli jednoznačné vnemy
- Pr. Khepera v prostredí s dvomi typmi prekážok, ktoré sa líšia farbou špičky. Objektom s tmavou špičkou sa má vyhýbať, k ostatným sa má priblížiť. Khepera je vybavená 8 infra senzormi a 64-pixelovou lineárnou kamerou s uhlom záberu 36°
 - ◆ keď prekážku nevidí kamerou, tak je vnem nejednoznačný, ale stačí, aby sa otočila a dostala prekážku do zorného poľa – tzv. **aktívne**

vnímanie



1. **Vyberať a využívať senzorické vzory, ktoré sú jednoznačné**
2. Využívať také senzorické vzory, že skupiny vzorov, ktoré vyžadujú rôzne reakcie, sa neprekrývajú (alebo prekrývajú iba slabó)
3. Využívať emergentné správania, ktoré vzniknú iba interakciou agenta s prostredím

Aktívne vnímanie





- Rôzne akcie môžu mať rôzne efekty:
 - ◆ niektoré vedú k jednoznačným vnemom, iné nie (ísť rovno, otáčať sa)
 - ◆ niektoré sú efektívnejšie (otáčanie smerom k objektu, alebo vždy tým istým smerom)
- Akcia
 - ◆ čiastočne určuje ako robot plní ciele
 - ◆ čiastočne určuje senzorové vnemy v nasledujúcom kroku
- je možné iba vtedy, keď robot dokáže nájsť aspoň jeden stav senzorov, ktorý je jednoznačný

Senzorovo-motorická koordinácia a zjednodušovanie ťažkých problémov



- Skupiny senzorových signálov, ktoré vyžadujú rôzne motorické reakcie sa môžu čiastočne prekrývať
 - ◆ problémy typu 1 (ľahké) – v signáloch zo senzorov je mnoho priamo pozorovateľných príznakov, ktoré umožňujú určiť správnu reakciu
 - ◆ problémy typu 2 (ťažké) – rozlišujúce príznaky sú slabé, skryté
- Čo s tým?
 1. problémy typu 2 sa niekedy dajú redukovať na problémy typu 1 **prekódovaním stavov** senzorov, aby sa zosilnili užitočné príznaky
 - ◆ napr. neurónová BP-sieť sa najprv učí na jednoduchšej podúlohe, až potom na zložitej úlohe; prvá fáza ovplyvní kódovanie signálov vo vnútornej reprezentácii
 2. **aktívna senzorovo-motorická koordinácia** (je možná iba pre vtelené a situačné systémy)
 - ◆ napr. Khepera sa má približovať k veľkým (priemer 5,5 cm) a vyhýbať sa malým (priemer 2,3 cm) valcom; používa iba predných 6 infra senzorov

Pasívne rozpoznávanie malých a veľkých valcov

- 6 vstupných neurónov, 1 výstupný (malý/veľký)
- 3 rôzne architektúry:
 - ◆ a) bez skrytých neurónov
 - ◆ b) skrytá vrstva – 4 neuróny
 - ◆ c) skrytá vrstva – 8 neurónov
- trénovacia množina 2 (objekty) x 20 (vzdialeností) x 180 uhlov = 7200 vzorov



Pasívne rozpoznávanie malých a veľkých valcov



- Vzájomné polohy Khepery a objektu, pre ktoré NS správne rozlíšila malý valec od steny
 - ♦ obr. nesymetrické – senzory nie sú identické
 - ♦ VÝSLEDOK: **pasívna sieť nie** je schopná rozlíšiť objekty (problém typu 2, ale uvidíme, že pomocou sensorovo-motorickej koordinácie sa dá riešiť)


Pasívne x aktívne vnímanie

- **Úloha:** priblížiť sa k veľkému valcu a vyhnúť sa malému valcu
- robot sa dokázal pomocou **aktívneho vnímania** naučiť rozlíšiť malé a veľké valce
 - ◆ v 86 % prípadov: robot sa pohybuje, dokiaľ nenarazí na objekt; začne sa okolo neho otáčať a, ak je to malý valec, tak ho opustí
 - ◆ v 14% zastaví pred objektom, ale rozlíšenie je horšie
 - ◆ krúživé pohyby vyvolávajú rozdielne signály pre malé a veľké valce
 - ◆ *paradoxne: relatívnych polôh robota a objektu, pri ktorých robot správne rozlíši malý a veľký valec je menej ako u pasívnej siete*

Index geometrickej separability

- [Thorton, 1997] Zaznamenáme stavy senzorov v N krokoch robota
– $x_1, x_2, \dots, x_N$
- pre každý z nich určíme najbližší (Euklidovsky) vzor $x'_1, \dots, x'_N$
- Ak je x_i a x'_i z rovnakej triedy, tak pripočítame 1, inak 0. Výslednú hodnotu vydáme N .

$$IGS(f) = \frac{\sum_{i=1}^N (f(x_i) + f(x'_i) + 1) \bmod 2}{N}$$



Tučne sú vyznačené stavy senzorov zaznamenané v jednotlivých experimentoch


- Pre pasívnu sieť
 - ◆ IGS stena/malý valec – 0,56
 - ◆ IGS malý/veľký valec – 0,50

- Pre robota
 - IGS okolo 0,9

Index geometrickej separability

- Zaznamenáme stavy senzorov v N krokoch robota – $x_1, x_2, \dots, x_N$
- pre každý z nich určíme najbližší (Euklidovsky) vzor $x'_1, \dots, x'_N$
- Ak je x_i a x'_i z rovnakej triedy, tak pripočítame 1, inak 0. Výslednú hodnotu vydáme N .
- Pre robota
 - ◆ IGS okolo 0,9

1. Vyberať a využívať senzorické vzory, ktoré sú jednoznačné
2. **Využívať také senzorické vzory, že skupiny vzorov, ktoré vyžadujú rôzne reakcie, sa neprekrývajú (alebo prekrývajú iba slab)**
3. Využívať emergentné správanie, ktoré vzniknú iba interakciou agenta S prostredím




gsi = priemerný IGS v jednotlivých generáciách v 10 behoch

% correct = úspešnosť najlepšieho jedinca po 500 cykloch


Riešenie pomocou atraktora správania

- **Úloha:** Khepera má rozlíšiť steny od malého valca a zostať pri valci
 - ◆ aréna 60×35 cm, náhodne umiestnený valec ($\varnothing 2,3$ cm)
 - ◆ NS: 6 vstupných neurónov (infra), 2 výstupné (motory)
- vyvinutí jedinci nekrúžia okolo, ale posúvajú sa vpred/vzad alebo doľava/doprava, pritom zostávajú pod určitým uhlom a v určitej vzdialenosti
- pozícia, na ktorej začne robot oscilovať, je atraktor a robot sa do nej dostane nezávisle na tom pod akým uhlom sa k cieľu priblížil
- IGS je stabilizované asi na 0,8 – tzn. že rozlíšenie cieľa závisí menej na schopnosti aktívne vyberať signály, ktoré sú ľahko rozlíšiteľné
- riešenie je založené na takých reakciách na signály zo senzorov, ktoré spôsobia vytvorenie atraktoru v blízkosti valca, ale nie v blízkosti steny

Atraktor správania



1. Vyberať a využívať senzorické vzory, ktoré sú jednoznačné
2. Využívať také senzorické vzory, že skupiny vzorov, ktoré vyžadujú rôzne reakcie, sa neprekrývajú (alebo prekrývajú iba slabó)
3. **Využívať emergentné správania, ktoré vzniknú iba interakciou agenta S prostredím**



Pohyb
khepery
blízko
steny


Pohyb
khepery
blízko
valca

Ďalší príklad atraktora správania

■ Simulovaný agent

- ♦ v kruhovom páse zo 40 buniek (20 vľavo + 20 vpravo);
- ♦ bunky na každej strane sú náhodne očíslované 0-19;
- ♦ agent je v jednej bunke a na vstupe má číslo bunky, v ktorej sa nachádza
- ♦ môže sa pohnúť o 1 bunku v smere/proti smeru hodinových ručičiek
- ♦ cieľ agenta je zostať v ľavej polovici
- ♦ NS – 20 vstupov: číslo bunky (práve jeden neurón má 1); 1 binárny výstup (v smere/proti smeru); váhy iba 0/1
- ♦ vnemy z ľavej a pravej polovice sa úplne prekrývajú – senzorovo-motorická koordinácia nestačí
- ♦ riešenie: v ľavej časti sa vyvinú atraktory


Ďalší atraktor správania




- Reakcia, že v bunke 3 má robot ísť v smere hodinových ručičiek, sama o sebe nemá žiadnu funkciu, ale dohromady s ostatnými dáva zmysel
- V tomto prípade sa nejedná o nejednoznačnosť vnemov, lebo vnemy v ľavej a pravej časti sa nedajú rozlíšiť a vyvolávajú jednoznačnú odpoveď
- evolúcia vyberá
 - ◆ jedincov s čo najúspešnejšou stratégiou
 - ◆ u jedincov s vybranou stratégiou vyberá tých, ktorí vedia využívať senzorovú a motorickú koordináciu

Využívanie obmedzení

- Klasický inžiniersky prístup: prostredie a štruktúra (tela) robota sú obmedzenia a riešenie je treba postaviť na základe modelu prostredia a tela robota podľa obmedzení
- umelá evolúcia vidí obmedzenia ako príležitosti
- Pr. krysy hľadajú potravu; najprv odkrytú, potom na tom istom mieste zahrabanú, potom bludisko náhodne otočili
 - ◆ 35% krýs hľadalo potravu správne, 31% sa pozeralo na symetricky opačný kút – tzv. **rotačná chyba**
 - ◆ niekoľko autorov to považovalo za dôkaz, že krysy museli mať postavenú mapu prostredia a používať ju pre navigáciu





Využívanie obmedzení




■ Khepera

- ◆ začínala iba z vyznačených 8 pozícií
- ◆ NS s 8 vstupnými neurónmi (infra) a 2 výstupnými neurónmi (motory) – *čisto reaktívne riadenie*
- ◆ podobne ako krysy v 41% prípadoch Khepera našla správne miesto, v 41% urobila rotačnú chybu, v 18% oblasť nenašla
- ◆ princíp: rozlíšenie dlhej a krátkej steny; stačí, aby robot sledoval dlhú stenu a v 50% nájde správne miesto, v 50% urobí iba rotačnú chybu
- ◆ Khepera nemôže rozlíšiť dlhú a krátku stenu! Pomôže senzorovo-motorická koordinácia – **pohybuje sa po zakrivenej dráhe a nutne narazí na dlhú stenu**
- ◆ *NEZNAMENÁ to, že krysy nepoužívajú mapu*




Využívanie obmedzení



■ Khepera

- ♦ začínala iba z vyznačených 8 pozícií
- ♦ princíp: rozlíšenie dlhej a krátkej steny; stačí, aby robot sledoval dlhú stenu a v 50% nájde správne miesto, v 50% urobí iba rotačnú chybu
- ♦ Khepera nemôže rozlíšiť dlhú a krátku stenu! Pomôže senzoro-motorická koordinácia – **pohybuje sa po zakrivenej dráhe a nutne narazí na dlhú stenu**
- ♦ *NEZNAMENÁ to, že krysy nepoužívajú mapu*



Reaktívne riešenie

- Keď sa aréna zväčšila 2x, tak v 2 prípadoch (z 8) Khepera iba jazdila v kruhu
- keď sa aréna 2x zmenšila, tak v 2 prípadoch (z 8) Khepera narazila na kratšiu stenu a potom ju sledovala
- Čo sa stane, keď prostredie nebude tak obmedzené?
 - ◆ Khepera štartuje z náhodného miesta v náhodnej orientácii
 - ◆ Veľkosť arény premenlivá (pomer dĺžky stien zachovaný) – 25% chýb
 - ◆ Mení sa i pomer veľkostí strán arény – 33% chýb
- Záver: čím menej obmedzení, tým ťažšia úloha

Diskusia



- Väčšinou v robotickom výskume sa problémy riešia rozložením na jednoduchšie podúlohy, ktoré sa implementujú do samostatných modulov; napr. v metódach založených na správaniach sa robí dekompozícia na úrovni správaní
 - a) rozložiť správanie na elementárne správania
 - b) implementovať základné správania
 - c) koordinácia jednotlivých modulov (vrstiev) správaní
- b) a c) sa často dá naučiť (samo-organizácia)
- a) sa robí ručne – **v evolučnej robotike nie je treba**

Diskusia



- Pr. robot, ktorý sa má vyhýbať stenám a zostať pri valci
 - ◆ základné správania:
 - ◆ prehľadávanie prostredia – pohyb
 - ◆ vyhýbanie sa prekážkam
 - ◆ priblíženie a zotrvanie v blízkosti objektu
 - ◆ rozlíšenie objektov – **toto je ale ťažšie než zvyšok**
 - ◆ takáto dekompozícia problém nezjednodušila!
 - ◆ Vyššie sme videli, že evolúcia vytvorila správanie, ktoré rozlíšenie objektov umožnilo
- rozklad na základné správania je ťažký a umelá evolúcia často nájde riešenie, ktoré človek sotva navrhne
 - ◆ dáva viacej rôznych riešení naraz
 - ◆ často vyberá riešenia založené na vyvinutých správaniach